

**DETEKSI KEJANGGALAN ENGAGEMENT
KONTEN ENDORSEMENT TIKTOK
BRAND SKINCARE DENGAN
PENDEKATAN ISOLATION FOREST**

SKRIPSI



Oleh
SHAFA NASYWA DHIYA
NIM 22031554013

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA SAINS DATA
2025

DETEKSI KEJANGGALAN ENGAGEMENT KONTEN ENDORSEMENT TIKTOK BRAND SKINCARE DENGAN PENDEKATAN ISOLATION FOREST

SKRIPSI

Diajukan kepada Universitas Negeri Surabaya untuk Memenuhi
Persyaratan Penyelesaian Program Sarjana Matematika

Oleh
SHAFa NASYWA DHIYA
NIM 22031554013

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA SAINS DATA

2025

ABSTRAK

Shafa Nasywa Dhiya

DETEKSI KEJANGGALAN ENGAGEMENT KONTEN ENDORSEMENT TIKTOK BRAND SKINCARE DENGAN PENDEKATAN ISOLATION FOREST

Skripsi

Universitas Negeri Surabaya, Fakultas Matematika dan Ilmu
Pengetahuan Alam, 2025

TikTok menjadi salah satu platform media sosial yang banyak dimanfaatkan dalam kegiatan pemasaran digital melalui konten *endorsement*. Tingginya nilai *engagement* sering digunakan sebagai indikator keberhasilan promosi, namun tidak seluruh *engagement* mencerminkan interaksi yang wajar. Penelitian ini bertujuan untuk mendeteksi anomali *engagement* pada konten *endorsement* TikTok menggunakan metode *Isolation Forest*. Dataset yang digunakan terdiri dari 150 konten *endorsement* TikTok yang dikelompokkan ke dalam lima tingkatan *Key Opinion Leader* (KOL).

Tahapan penelitian meliputi pra-pemrosesan data, perhitungan fitur *engagement*, eksplorasi kombinasi fitur, dan pemodelan menggunakan *Isolation Forest*. Hasil eksplorasi menunjukkan bahwa kombinasi fitur *Engagement Rate* (ER) dan *Like-to-View Ratio* (LVR) dipilih sebagai fitur utama. Model diterapkan pada masing-masing tingkatan KOL dengan parameter *contamination* sebesar 0,05. Hasil penelitian menunjukkan bahwa dari 150 konten yang dianalisis, 140 konten terindikasi normal dan 10 konten terindikasi anomali. Temuan ini menunjukkan bahwa sebagian besar konten memiliki pola *engagement* yang normal, sedangkan sebagian kecil menunjukkan karakteristik yang berbeda dari mayoritas data.

Kata kunci: TikTok, *engagement*, anomali, *Isolation Forest*, *endorsement*.

ABSTRACT

Shafa Nasywa Dhiya

DETECTION OF ENGAGEMENT IRREGULARITIES IN TIKTOK ENDORSEMENT CONTENT FOR THE SKINCARE BRAND USING AN ISOLATION FOREST APPROACH

Undergraduate Thesis

State University of Surabaya, Faculty of Mathematics and Natural
Sciences, 2025

TikTok has become one of the most widely used social media platforms for digital marketing through *endorsement* content. High *engagement* values are often used as indicators of promotional success; however, not all *engagement* reflects natural user interactions. This study aims to detect *engagement* anomalies in TikTok *endorsement* content using the *Isolation Forest* method. The dataset consists of 150 pieces of TikTok *endorsement* content categorized into five *Key Opinion Leader* (KOL) tiers.

The research process includes data preprocessing, *engagement* feature calculation, feature combination exploration, and anomaly detection modeling using *Isolation Forest*. The results indicate that *Engagement Rate* (ER) and *Like-to-View Ratio* (LVR) were selected as the primary features. The model was applied to each KOL tier using a *contamination* parameter of 0.05. Out of 150 analyzed contents, 140 were identified as normal and 10 as anomalous. These findings indicate that most contents exhibit normal *engagement* patterns, while a small portion demonstrates characteristics that differ from the majority of the data.

Keywords: TikTok, *engagement*, anomaly detection, *Isolation Forest*, *endorsement*.

HALAMAN PERSETUJUAN TUGAS

AKHIR BENTUK: SKRIPSI

Nama Mahasiswa : Shafa Nasywa Dhiya
NIM : 22031554013
Judul Penelitian : Deteksi Kejanggalan Engagement Konten
Endorsement Tiktok Brand Skincare
dengan Pendekatan Isolation Forest

ini telah disetujui dan dinyatakan memenuhi syarat untuk diajukan
dalam ujian skripsi.

Surabaya, 17 Juni 2026
Pembimbing I,



Ibnu Febry K., S.Kom., M.Sc.,
Ph.D.
NIP 198802182015041001

Pembimbing II,



Fadhilah Qalbi Annisa, S.T.,
M.Sc.
NIP 202210163

PRAKATA

Puji syukur kehadiran Allah Swt. atas segala rahmat, nikmat, dan pertolongan-Nya sehingga penulis dapat menyelesaikan skripsi ini. Dalam proses penyusunannya, penulis menyadari bahwa banyak pihak yang telah memberikan dukungan, bantuan, dan semangat. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Prof. Dr. Wasis, M.Si. selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya.
2. Ibu Yuliani Puji Astuti, S.Si., M.Si. selaku Koordinator Program Studi Sains Data Universitas Negeri Surabaya.
3. Bapak Ibnu Febry Kurniawan, S.Kom., M.Sc., Ph.D. dan Ibu Fadhilah Qalbi Annisa, S.T., M.Sc. selaku dosen pembimbing yang telah memberikan arahan, masukan, dan kesabaran selama proses penyusunan skripsi ini.
4. Dr. Atik Wintarti, M.Kom. dan Ibu Riskyana Dewi Intan Puspitasari, M.Kom. selaku dosen penguji yang telah memberikan kritik dan saran yang membangun untuk penyempurnaan penelitian ini.
5. Seluruh dosen dan tenaga kependidikan Program Studi Sains Data Universitas Negeri Surabaya yang telah memberikan ilmu, pengalaman, dan bantuan selama masa perkuliahan.
6. Ayah dan Ibu, yang selalu memberikan doa, kasih sayang, dukungan moral maupun finansial, serta menjadi tempat pulang terbaik di setiap proses kehidupan penulis. Terima kasih karena selalu percaya bahwa penulis mampu sampai di titik ini.
7. Adik penulis dan kucing-kucing kesayangan yang selalu menjadi sumber kebahagiaan di tengah berbagai tekanan selama penyusunan skripsi.

8. Dayen dan Sala, sahabat yang telah menemani hampir seluruh perjalanan perkuliahan penulis. Terima kasih telah hadir dalam setiap cerita, tawa, tangis, perjuangan skripsi, hingga berbagai momen yang membuat perjalanan ini terasa lebih ringan.
9. Alin, Nuhaa, Filda, dan Devina yang selalu membawa semangat, tawa, dan warna di tengah padatnya kehidupan perkuliahan.
10. Jopi, yang selalu menjadi seseorang yang bisa penulis *lean on*, bercerita, dan berbagi berbagai hal dalam kehidupan, tidak hanya tentang skripsi, tetapi juga tentang proses bertumbuh selama ini.
11. Dyah, Farabi, Didah, dan Farah (*Berboncengan*), serta Icha, Naura, Wawa, dan Nadira (*Saylerrmun*), yang telah menjadi bagian dari perjalanan penulis sejak masa sekolah dan tetap hadir hingga saat ini.
12. Kak Diva, Andin, dan Nabila (*Arkadia*), yang selalu menjadi tempat berbagi cerita, keluh kesah, dan berbagai dinamika kehidupan.
13. Dina, teman sekamar yang telah menemani berbagai cerita, perjuangan, dan dinamika kehidupan selama masa perkuliahan.
14. Seluruh teman angkatan 2022 Program Studi Sains Data Universitas Negeri Surabaya yang tidak dapat disebutkan satu per satu.
15. Seseorang yang pernah hadir dalam perjalanan ini. Terima kasih atas nasihat, perhatian, dan pelajaran yang diberikan. Tidak semua orang ditakdirkan untuk tinggal, tetapi beberapa hadir untuk mengajarkan sesuatu. Terima kasih karena pernah menjadi salah satunya.

16. Naju dan Midi yang selalu berhasil membuat hari-hari berat terasa lebih ringan. *Thank you for keeping me sane through all the stress, deadlines, and overthinking moments.*
17. SEVENTEEN, S.Coups, Jeonghan, Joshua, Jun, Hoshi, Wonwoo, Woozi, DK, Minghao, Mingyu, Vernon, Seungkwan, dan Dino, yang melalui karya, musik, dan semangatnya telah menjadi salah satu sumber kekuatan penulis selama menyelesaikan skripsi ini. Secara khusus, Joshua, *thank you for being my comfort person from afar.*
18. Terakhir, untuk diri penulis sendiri. Terima kasih karena telah bertahan, berjuang, dan terus melangkah hingga sampai di tahap ini. Tidak semua proses berjalan mudah, tetapi semua usaha yang telah dilakukan berhasil membawa penulis menyelesaikan perjalanan ini. *I am proud of you, Sap. You did well.*

DAFTAR ISI

SAMPUL	i
ABSTRAK	ii
ABSTRACT	iii
PRAKATA	v
DAFTAR ISI	vii
DAFTAR TABEL	x
DAFTAR GAMBAR	xii
DAFTAR SIMBOL	xv
Bab I PENDAHULUAN	1
A. Latar Belakang	1
B. Rumusan Masalah	5
C. Tujuan Penelitian	6
D. Manfaat Penelitian	6
E. Batasan Penelitian	8
Bab II KAJIAN PUSTAKA	9
A. Penelitian Terkait	9
B. Kajian Teori	11
1. Media Sosial	11
2. <i>Engagement</i> pada Media Sosial	13
3. <i>Engagement</i> TikTok	16

4. Rule-Based Metric.....	17
5. Isolation Forest	19
Bab III METODE PENELITIAN.....	27
A. Dataset	27
1. Fitur Asli	28
2. Fitur Turunan.....	29
B. Alur Penelitian	31
C. Jadwal Penelitian	39
Bab IV HASIL PENELITIAN DAN PEMBAHASAN	41
A. Hasil Penelitian.....	41
1. Pra-pemrosesan Data.....	41
2. Analisis Statistik Deskriptif	43
3. Analisis Distribusi dan Kewajaran Data	46
4. Eksplorasi Hubungan Antar Metrik <i>Engagement</i>	52
5. Implementasi Deteksi Anomali menggunakan Isolation Forest	57
6. Evaluasi Model	69
B. Pembahasan.....	74
1. Analisis Karakteristik Postingan yang Terindikasi Anomali.....	74
C. Keterbatasan Penelitian	80
Bab V SIMPULAN DAN SARAN	82

A.	Simpulan	82
B.	Implikasi	83
C.	Saran	84
DAFTAR PUSTAKA		85

DAFTAR TABEL

Tabel 2.1	Penelitian Terkait	10
Tabel 3.1	Daftar Variabel Dataset Penelitian	27
Tabel 3.2	Cuplikan Data Metrik Asli	29
Tabel 3.3	Cuplikan Data Metrik Turunan	30
Tabel 3.4	Pelaksanaan Penelitian	40
Tabel 4.1	Tahapan Pra-pemrosesan Data	41
Tabel 4.2	Karakteristik Distribusi Metrik <i>Engagement</i>	47
Tabel 4.3	Karakteristik Distribusi Metrik Turunan <i>Engagement</i>	49
Tabel 4.4	Hasil Perhitungan IQR dan Upper Bound Metrik Turunan	50
Tabel 4.5	Jumlah Indikasi Outlier Awal Berdasarkan IQR .	51
Tabel 4.6	Ringkasan Temuan pada Kombinasi Fitur Turunan <i>Engagement</i>	55
Tabel 4.7	Perbandingan Hasil Kombinasi berdasarkan Scatterplot	56
Tabel 4.9	Perbandingan Irisan Deteksi Anomali pada Berbagai Kombinasi Fitur	58
Tabel 4.11	Perbandingan Hasil Deteksi Outlier Berdasarkan Nilai <i>Contamination</i>	62
Tabel 4.12	Analisis Sensitivitas Parameter <i>max_samples</i>	64

Tabel 4.13	Konfigurasi Parameter Model Akhir	65
Tabel 4.14	Hasil Deteksi Anomali pada Setiap Tingkatan KOL	66
Tabel 4.15	Sampel Hasil Deteksi Menggunakan Isolation Forest	68
Tabel 4.16	Perbandingan Rata-rata Karakteristik <i>Engagement</i>	72
Tabel 4.17	Karakteristik Postingan yang Terindikasi Anomali	74

DAFTAR GAMBAR

Gambar 2.1	Statistik Platform Media Sosial yang Paling Banyak Digunakan di Indonesia (DataReportal, 2025)	12
Gambar 2.2	Rata-Rata Waktu Penggunaan Aplikasi Media Sosial per Pengguna di Indonesia (DataReportal, 2025)	12
Gambar 2.3	Sosial Media Engagement	14
Gambar 2.4	Ilustrasi struktur <i>isolation tree</i> dengan ukuran sub-sampling $\psi = 8$	22
Gambar 2.5	Ilustrasi perbedaan <i>path length</i> antara data normal dan data anomali pada <i>isolation tree</i>	23
Gambar 2.6	Anomali (x_0) diisolasi lebih cepat daripada data normal (x_1)	24
Gambar 3.1	Alur Penelitian	31
Gambar 3.2	Flowchart off-page Analisis Awal	33
Gambar 3.3	Flowchart off-page Deteksi Anomali	36
Gambar 4.1	Distribusi Jumlah Data pada Setiap Tingkatan KOL	42
Gambar 4.2	Distribusi Metrik <i>Engagement</i>	43
Gambar 4.3	Distribusi Metrik Turunan	45
Gambar 4.4	Distribusi Data Metrik Views dan Likes	46
Gambar 4.5	Distribusi Data Metrik Comments dan Shares ..	47
Gambar 4.6	Distribusi Data Metrik ER dan LVR	48

Gambar 4.7	Distribusi Data Metrik CVR dan LVR	48
Gambar 4.8	Visualisasi IQR ER dan LVR	50
Gambar 4.9	Visualisasi IQR CVR dan SVR	50
Gambar 4.10	Scatterplot ER-LVR dan ER-CVR	53
Gambar 4.11	Scatterplot ER-SVR dan LVR-CVR	54
Gambar 4.12	Scatterplot LVR-SVR dan CVR-SVR	54
Gambar 4.13	Heatmap Korelasi Antar Metrik Turunan <i>Engagement</i>	61
Gambar 4.14	Distribusi Indikasi Anomali	70
Gambar 4.15	Distribusi Skor Anomali	71
Gambar 4.16	Postingan Terindikasi Anomali Tingkat Nano...	75
Gambar 4.17	Postingan Terindikasi Anomali Tingkat Macro ..	76
Gambar 4.18	Postingan Terindikasi Anomali Tingkat Mega ..	77

DAFTAR SIMBOL

ψ	Ukuran <i>subsampling</i> pada <i>Isolation Forest</i>
n	Jumlah sampel data
$H(n)$	Bilangan harmonik ke- n
$\ln(n)$	Logaritma natural dari n
γ	Konstanta Euler-Mascheroni
$c(n)$	<i>Expected path length</i> pada <i>Binary Search Tree</i>
x	Titik data yang dievaluasi
$h(x)$	<i>Path length</i> titik data x
$E(h(x))$	Rata-rata <i>path length</i> titik data x
$s(x, n)$	Skor anomali titik data x
t	Jumlah <i>isolation tree</i>
f	Fungsi pemisahan (<i>split function</i>)

BAB I

PENDAHULUAN

A. Latar Belakang

Kemajuan teknologi digital telah mengubah cara pandang pemasaran secara signifikan. Perkembangan *platform* daring, peningkatan akses internet, serta perubahan perilaku konsumen membuat pemasaran digital menjadi strategi utama bagi banyak *brand*. Tren pemasaran saat ini tidak hanya berfokus pada penyampaian informasi, tetapi juga pada pengalaman yang interaktif sehingga mampu menarik perhatian publik dalam waktu singkat.

Media sosial kemudian menjadi salah satu pusat aktivitas pemasaran digital karena mampu menghubungkan *brand* dengan konsumen secara langsung melalui komunikasi interaktif dan dua arah (Rachmadina, 2025). Pengguna media sosial sebagai audiens akan menunjukkan respons terhadap konten melalui berbagai bentuk interaksi, seperti memberikan likes, menuliskan komentar, serta berpartisipasi dalam aktivitas yang ditawarkan oleh konten tersebut. Bentuk-bentuk interaksi ini merepresentasikan tingkat keterlibatan audiens terhadap pesan yang disampaikan dan mencerminkan hubungan antara konten dengan penggunanya (Ratnasari, 2024). Oleh karena itu, tingkat *engagement* kerap digunakan sebagai indikator untuk menilai efektivitas konten maupun keberhasilan kampanye pemasaran di media sosial, karena menggambarkan sejauh mana pesan mampu menarik perhatian dan mendorong partisipasi audiens.

Dalam pemasaran digital, banyak *brand* bekerja sama dengan *Key Opinion Leader* (KOL) sebagai strategi promosi. Dalam konteks media sosial, KOL sering diposisikan sebagai *influencer*, yaitu kreator konten yang memiliki audiens dan daya pengaruh tertentu dalam memengaruhi persepsi serta keputusan audiens terhadap suatu

produk atau layanan. Pada praktiknya, *brand* dapat melibatkan beberapa KOL dari berbagai tingkat, mulai dari nano hingga mega, sesuai dengan skala kampanye yang dijalankan. Oleh karena itu, kredibilitas serta kualitas interaksi KOL menjadi pertimbangan utama dalam pemilihan talent sebagai bagian dari strategi pemasaran.

Akan tetapi, meningkatnya kompetisi di kalangan kreator mendorong munculnya praktik *engagement boosting*, seperti penggunaan layanan *fake engagement* dan bot untuk menghasilkan interaksi buatan (Nevado-Catallan dkk.2023). Kondisi ini menimbulkan tantangan bagi *brand* karena pola interaksi yang dihasilkan dapat menyerupai aktivitas pengguna asli, sehingga sulit dibedakan hanya berdasarkan jumlah interaksi. Akibatnya, metrik *engagement* yang digunakan sebagai dasar evaluasi berpotensi tidak merepresentasikan respons audiens yang sebenarnya.

Selain itu, perbedaan tingkat antar keterlibatan KOL juga memengaruhi proses perbandingan performa. KOL dengan pengikut lebih sedikit cenderung memiliki audiens yang lebih aktif terlibat, sedangkan KOL dengan pengikut besar umumnya memperoleh jumlah interaksi yang lebih tinggi namun dengan persentase keterlibatan lebih kecil. Oleh karena itu, evaluasi performa tidak dapat dilihat hanya dari satu nilai mentah saja, tetapi perlu menggunakan metrik berbasis rasio seperti *engagement rate* agar perbandingan dapat dilakukan secara lebih proporsional.

Pengguna yang ingin mempopulerkan kontennya seringkali membeli layanan peningkatan interaksi tanpa menyadari bahwa aktivitas tersebut berasal dari bot atau *buzzer*, bukan pengguna asli. Menurut Varol dkk. (2017) akun bot merupakan akun yang dikendalikan oleh perangkat lunak dan menggunakan algoritma untuk menghasilkan konten serta melakukan interaksi di media sosial. Selain bot, terdapat pula jasa interaksi berbayar yang dilakukan oleh manusia, tetapi tetap tidak mencerminkan respons

asli pengguna karena dilakukan dengan terarah dan bukan respon alami. Seorang *buzzer* dikatakan berhasil apabila topik atau produk yang mereka promosikan berhasil menjadi trending atau mendapat banyak pembicaraan di ruang publik digital (Putri Handayani dkk., 2024).

TikTok kemudian menjadi *platform* yang relevan untuk mengamati fenomena tersebut. Dengan 108 juta pengguna berusia 18 tahun ke atas di Indonesia per awal 2025 (DataReportal, 2025), TikTok tumbuh sebagai salah satu *platform* pemasaran berbasis konten paling dominan. Saat ini, TikTok menjadi salah satu sumber utama perekonomian dengan strategi pemasaran berbasis konten, khususnya dalam industri kecantikan yang bergantung pada daya tarik. TikTok memiliki karakteristik utama berupa konten singkat yang menarik dan algoritma yang dibentuk berdasarkan pola interaksi pengguna, membuat *platform* ini tepat untuk menganalisis perilaku pengguna terkait *engagement*.

Dalam konteks bisnis, konten singkat yang menarik di TikTok terbukti mampu meningkatkan perhatian publik dan membangun *brand awareness* secara efektif. Peran KOL dalam proses ini juga sangat penting, karena penelitian oleh Alike dkk. (2024) menunjukkan bahwa kepercayaan dan daya tarik seorang kreator memiliki pengaruh besar terhadap keputusan pembelian para pengikutnya. Hal ini menandakan bahwa pemasaran digital melalui KOL dapat berdampak tidak langsung terhadap keputusan pembelian melalui peningkatan *brand awareness*. Penelitian sebelumnya menunjukkan bahwa pemanfaatan media sosial TikTok dalam pemasaran memiliki pengaruh positif terhadap keputusan pembelian produk, khususnya melalui konten yang meningkatkan brand image dan keterlibatan audiens. (Dewi, 2023). Temuan tersebut mengindikasikan bahwa aktivitas pemasaran di platform ini mampu mendorong respons konsumen yang lebih tinggi terhadap promosi produk, sehingga mendukung pemilihan brand *skincare* sebagai objek penelitian dalam studi ini.

Pada penelitian sebelumnya dengan judul "*Examining the correlation between metrics in the Instagram social network to identify fake pages and improve marketing*" yang telah dilakukan oleh Saeidi dan Baradari (2023) menunjukkan bahwa metrik keterlibatan seperti jumlah posting, like, dan komentar memiliki peran penting dalam mengidentifikasi aktivitas tidak alami di media sosial. Dalam studi mereka terhadap 1.860 halaman publik instagram, ditemukan bahwa kombinasi indikator tersebut dapat digunakan untuk membedakan akun asli dan palsu dengan tingkat akurasi mencapai 94%. Penelitian ini memperkuat pandangan bahwa perilaku interaksi digital dapat mencerminkan keaslian aktivitas pengguna, serta memberikan dasar bagi penelitian lanjutan mengenai deteksi tingkat kejanggalan engagement dan implikasinya terhadap distribusi konten.

Perilaku interaksi pada konten yang benar-benar organik umumnya menunjukkan pola yang konsisten dan proporsional. Misalnya, konten dengan jumlah *views* tinggi biasanya diikuti oleh jumlah *likes* dan *comments* yang sebanding, serta pertumbuhan interaksi yang meningkat secara bertahap dalam rentang waktu tertentu. Sebaliknya, konten yang mengandung indikasi *fake engagement* cenderung memperlihatkan ketidakseimbangan antar metrik, seperti lonjakan *likes* yang tidak diikuti oleh kenaikan *views*, rasio komentar yang tidak wajar, atau pola pertumbuhan interaksi yang tiba-tiba dan tidak konsisten.

Ketidaksesuaian pola interaksi pada konten *endorsement* tidak selalu muncul sebagai nilai ekstrem pada satu metrik tertentu, melainkan sering kali berbentuk kombinasi interaksi yang jarang dan berbeda dari pola mayoritas. Dalam hal tersebut, pendekatan berbasis ambang batas atau indikator tunggal menjadi kurang memadai karena tidak mampu menangkap kejanggalan yang bersifat struktural dan multivariat. Li dkk. (2016) menegaskan bahwa perbedaan antara interaksi organik dengan non-organik hanya dapat dipahami melalui analisis pola interaksi secara keseluruhan, bukan hanya berdasarkan satu metrik tertentu.

Dalam penelitian ini, permasalahan utama bukanlah mencari nilai *engagement* yang paling tinggi atau paling rendah, melainkan mengidentifikasi konten dengan pola interaksi yang berbeda dari sebagian besar konten lainnya. Untuk kondisi data yang tidak memiliki label dan memiliki sebaran yang tidak beraturan, diperlukan metode yang mampu mengenali pola yang jarang muncul tanpa bergantung pada asumsi distribusi tertentu. Isolation Forest dipilih karena bekerja dengan memisahkan data yang berbeda dari mayoritas secara bertahap, sehingga konten dengan pola interaksi yang tidak wajar dapat dikenali lebih cepat dibandingkan konten yang bersifat normal.

Dengan karakteristik data *engagement* TikTok yang bersifat dinamis dan beragam, pendekatan *unsupervised anomaly detection* menggunakan Isolation Forest dinilai sesuai untuk membantu mengidentifikasi indikasi kejanggalan *engagement* secara objektif pada konten endorsement, khususnya pada kampanye *brand skincare*.

B. Rumusan Masalah

Berdasarkan uraian pada bagian latar belakang, maka dapat dirumuskan permasalahan yang ada dalam penelitian ini sebagai berikut :

1. Bagaimana mengidentifikasi dan menganalisis karakteristik *engagement* yang berpotensi mengindikasikan praktik *engagement boosting* pada konten *endorsement* TikTok berdasarkan data interaksi implisit?
2. Bagaimana pola interaksi pengguna pada konten *endorsement brand skincare* TikTok jika dianalisis menggunakan metrik *engagement* seperti *Engagement Rate* (ER), *Like View Ratio* (LVR), *Comment View Ratio* (CVR), dan *Share View Ratio* (SVR)?
3. Bagaimana mengembangkan model deteksi berbasis Isolation Forest untuk mengidentifikasi pola *engagement* yang menyimpang dan berasosiasi dengan indikasi *engagement*

boosting pada konten *endorsement* TikTok?

C. Tujuan Penelitian

Berdasarkan rumusan masalah, maka penelitian ini memiliki beberapa tujuan seperti berikut :

1. Mengidentifikasi dan menganalisis karakteristik *engagement* yang berpotensi mengindikasikan praktik *engagement boosting* pada konten *endorsement* TikTok berdasarkan data interaksi implisit.
2. Menganalisis pola interaksi pengguna pada konten *endorsement* TikTok menggunakan metrik *Engagement Rate* (ER), *Like View Ratio* (LVR), *Comment View Ratio* (CVR), dan *Share View Ratio* (SVR) untuk memperoleh gambaran pola *engagement* normal maupun menyimpang.
3. Mengembangkan model deteksi berbasis *unsupervised learning* menggunakan Isolation Forest untuk mengidentifikasi pola *engagement* yang menyimpang dan berasosiasi dengan indikasi *engagement boosting* pada konten *endorsement* TikTok.

D. Manfaat Penelitian

Adapun manfaat yang diharapkan dapat diperoleh dari penelitian ini adalah sebagai berikut :

1. Manfaat Teoretis
 - a. Memberikan bukti empiris terhadap teori media sosial dan pemasaran digital, khususnya terkait peran metrik *engagement* dalam menggambarkan kualitas interaksi antara pengguna dan konten di *platform* TikTok.
 - b. Memperkuat kajian mengenai *fake engagement* dengan menunjukkan bagaimana kombinasi metrik rasio (LVR, CVR, SVR, dan ER) dan algoritma Isolation forest dapat

digunakan untuk mengidentifikasi kegagalan interaksi pada konten KOL.

- c. Memperkaya literatur Data Science dan Social Media Analytics melalui studi kasus lokal pada kampanye *brand skincare* sehingga memberikan konteks empiris baru bagi penelitian yang mengkaji deteksi anomali di media sosial.

2. Manfaat Praktis

2.1. Bagi Penulis

- a. Menjadi sarana untuk mengimplementasikan pengetahuan Data Science yang diperoleh selama perkuliahan ke dalam kasus nyata di bidang pemasaran digital.
- b. Memberikan pengalaman langsung dalam membangun alur analisis mulai dari pengumpulan data, pengolahan, pemodelan, sampai interpretasi hasil untuk pemecahan masalah riil terkait *fake engagement*.

2.2. Bagi Peneliti selanjutnya

- a. Sebagai referensi untuk penelitian lanjutan yang ingin mengembangkan sistem serupa dengan cakupan yang lebih luas.
- b. Sebagai pijakan dalam studi tentang deteksi tingkat kegagalan *engagement*, deteksi anomali digital, dan pengukuran kredibilitas konten.

2.3. Bagi *stakeholder* terkait

Stakeholder yang dimaksud disini mencakup *agensi digital*, *brand owner*, *konten creator*, dan *platform* media sosial.

- 1. Bagi *agensi digital* dan *brand owner*, hasil penelitian ini dapat membantu dalam merancang strategi pemasaran yang lebih efektif untuk meningkatkan *engagement* secara alami.

2. Bagi *konten creator*, penelitian ini dapat membantu memahami kualitas *engagement* yang alami, serta menjadi acuan dalam membangun branding profesional di ranah ini.
3. Bagi *platform* TikTok, penelitian ini dapat menjadi masukan dalam memperkuat deteksi aktivitas manipulatif yang dapat mempengaruhi kredibilitas algoritma distribusi konten.

E. Batasan Penelitian

Dalam penelitian ini, batasan masalah ditetapkan sebagai berikut.

1. Penelitian hanya difokuskan pada konten promosi *endorsement* TikTok *brand skincare* selama periode Juni-Oktober 2025.
2. Data yang digunakan merupakan dataset yang dikumpulkan dengan metode *scraping*.
3. Fokus penelitian terbatas pada pola kegagalan *engagement* berdasarkan data numerik, tanpa mempertimbangkan isi konten.
4. Penelitian ini hanya menggunakan data interaksi pengguna di media sosial, tanpa membahas aspek psikologis, motivasi, atau strategi pemasaran KOL.
5. Evaluasi penelitian ini didasarkan pada analisis distribusi skor anomali, penetapan ambang berbasis persentil, serta pemeriksaan pola metrik *engagement* pada data yang terdeteksi sebagai anomali yang dihasilkan oleh model *unsupervised learning*.

BAB II

KAJIAN PUSTAKA

A. Penelitian Terkait

Bab ini memberikan gambaran umum mengenai perkembangan penelitian dalam bidang analisis interaksi dan deteksi perilaku anomali pada media sosial. Seluruh interaksi pengguna terdokumentasi dalam bentuk data digital sehingga pendekatan berbasis data science dan pembelajaran mesin *unsupervised* banyak diterapkan untuk mengidentifikasi pola perilaku tidak wajar. Fang dkk. (2022) menggunakan Isolation Forest untuk mendeteksi perilaku anomali melalui perhitungan skor anomali dan penentuan ambang tanpa memerlukan data berlabel. Sementara itu, Zouzou dan Varol (2024) menunjukkan bahwa kampanye akun palsu yang terkoordinasi dapat diidentifikasi melalui indikator metrik abnormal menggunakan pendekatan *unsupervised*. Sejalan dengan itu, Chua dkk. (2024) menerapkan Isolation Forest untuk mendeteksi anomali pada data trafik web berbasis aktivitas pengguna dengan pendekatan *unsupervised learning*.

Kajian terdahulu menegaskan bahwa kombinasi interaksi eksplisit seperti *likes*, *comments*, *views*, serta struktur dan sebaran perilaku pengguna merupakan indikator penting dalam mengidentifikasi aktivitas digital yang menyimpang (Fang, dkk., 2022; Zouzou & Varol, 2024; Chua, dkk., 2024). Namun, penelitian yang secara khusus membahas deteksi kejanggalan *engagement* pada platform TikTok, khususnya dalam konteks konten endorsement influencer, masih relatif terbatas.

Berdasarkan kajian penelitian sebelumnya, belum ditemukan studi yang secara eksplisit menggabungkan *rule-based metrics* dan pendekatan *unsupervised anomaly detection* untuk menilai kejanggalan *engagement* pada konten endorsement TikTok. Penelitian ini mengisi

celah tersebut dengan menawarkan pendekatan kuantitatif yang memanfaatkan kombinasi analisis rasio dan Isolation Forest untuk mengidentifikasi pola interaksi yang berpotensi tidak wajar.

Ringkasan penelitian terdahulu yang relevan dengan penelitian ini ditampilkan pada Tabel 2.1.

Tabel 2.1: Penelitian Terkait

Studi	Fokus Studi	Metode	Keterangan
Judul: Anomalous Behavior Detection Based on the Isolation Forest Model with Multiple Perspective Business Processes. Penulis: Fang dkk. (2022)	Deteksi perilaku anomali	Isolation Forest	Menggunakan Isolation Forest untuk menghitung skor anomali dan menentukan data menyimpang melalui strategi penetapan ambang (<i>threshold</i>) tanpa memerlukan data berlabel.
Judul: Web Traffic Anomaly Detection Using Isolation Forest Penulis: Chua dkk. (2024)	Penerapan <i>unsupervised learning</i> Isolation Forest untuk mendeteksi anomali trafik web tanpa label data.	Isolation Forest	Mendeteksi pola aktivitas abnormal pada data trafik berbasis perilaku menggunakan Isolation Forest sebagai metode <i>unsupervised anomaly detection</i> .
Judul: Unsupervised Detection of Coordinated Fake-follower Campaigns on Social Media. Penulis: Zouzou & Varol (2024)	Deteksi kampanye <i>fake-follower</i>	Isolation Forest, Local Outlier Factor (LOF), Empirical Cumulative Distribution based Outlier Detection (ECOD), Gen2Out	Mendeteksi perilaku akun palsu yang terkoordinasi melalui indikator metrik abnormal.


B. Kajian Teori

1. Media Sosial

Media sosial merupakan platform digital yang memungkinkan penggunanya untuk berkomunikasi, bebas berekspresi dan berinteraksi dengan pengguna lain kemudian membentuk sebuah ikatan sosial secara virtual. Media sosial tanpa disadari telah menjadi alat komunikasi yang memiliki dampak besar di kehidupan sosial (Rafiq, 2020). Secara konseptual, media sosial dapat diartikan sebagai kumpulan aplikasi berbasis internet yang berlandaskan prinsip Web 2.0, di mana pengguna dapat menciptakan sekaligus bertukar konten dengan bebas (Handayani, 2024). Media sosial telah menjadi bagian penting dalam dunia digital karena kemampuannya untuk penyebaran informasi.


Salah satu platform media sosial yang saat ini banyak digunakan adalah TikTok. TikTok tidak hanya sebagai sarana hiburan, namun juga sebagai alat untuk memasarkan produk, membangun citra, dan berinteraksi dengan pengguna secara langsung. Saat ini hampir seluruh pengguna platform ini bersaing membuat konten dengan algoritma berbasis For Your Page (FYP) yang memungkinkan konten mendapatkan lebih banyak engagement karena berinteraksi dengan publik.

Sebagai salah satu platform dengan jumlah pengguna terbesar di Indonesia, TikTok memiliki posisi strategis dalam ekosistem media sosial. Laporan Digital 2025 oleh We Are Social dan Meltwater menunjukkan bahwa TikTok digunakan oleh 77,4% pengguna internet setiap bulan, yang membuatnya ditempatkan sebagai platform keempat yang paling sering digunakan setelah WhatsApp, Instagram, dan Facebook (We Are Social, 2025). Tingginya tingkat penggunaan ini menunjukkan bahwa TikTok telah menjadi salah satu saluran utama konsumsi konten digital dan pemasaran daring di Indonesia.



Gambar 2.1: Statistik Platform Media Sosial yang Paling Banyak Digunakan di Indonesia (DataReportal, 2025)

Dominasi TikTok tidak hanya terlihat dari jumlah penggunaannya, tetapi juga dari intensitas waktu penggunaan. Laporan yang sama menunjukkan bahwa pengguna TikTok di Indonesia menghabiskan rata-rata 44 jam 54 menit per bulan, menjadikannya sebagai platform dengan durasi penggunaan tertinggi di Indonesia (We Are Social, 2025). Tingginya durasi penggunaan aplikasi ini menandakan bahwa TikTok memiliki tingkat keterlibatan pengguna yang kuat, sehingga dinamika engagement, baik alami maupun manipulasi, lebih mudah untuk diamati. Hal ini menjadikan TikTok sebagai platform yang relevan untuk dianalisis pola interaksi antar penggunaannya.



Gambar 2.2: Rata-Rata Waktu Penggunaan Aplikasi Media Sosial per Pengguna di Indonesia (DataReportal, 2025)


2. *Engagement* pada Media Sosial

Engagement merupakan bentuk interaksi pengguna terhadap konten, seperti likes, comments, shares, dan views. Dalam pemasaran digital, engagement tidak hanya menggambarkan popularitas, tetapi juga menjadi indikator seberapa jauh audiens merespons pesan yang disampaikan. Levesque (2023) menjelaskan bahwa engagement pengikut di media sosial merupakan struktur multidimensi yang mencakup keterlibatan emosional dan tindakan nyata pengguna terhadap konten, sehingga tingkat engagement yang tinggi dapat mengindikasikan adanya hubungan yang lebih kuat antara audiens dan konten yang mereka tonton.

Namun, fenomena fake engagement membuat metrik tersebut tidak selalu mencerminkan interaksi yang nyata. Nevado-Catalán dkk. (2023) menemukan bahwa pengguna dapat membeli interaksi buatan melalui bot atau layanan berbayar, sehingga performa konten tampak meningkat secara tidak sah. Praktik ini mengaburkan kualitas interaksi yang sebenarnya dan dapat menyesatkan proses evaluasi performa digital, sehingga diperlukan metode analisis yang mampu membedakan interaksi organik dan tidak organik dengan lebih akurat.

Beberapa studi menegaskan bahwa engagement di media sosial tidak hanya dipandang sebagai angka interaksi, tetapi juga sebagai konsep multidimensional yang melibatkan perilaku, konteks platform, dan cara pengukurannya. Hal ini digambarkan oleh Trunfio dan Rossi (2021) melalui kerangka "social media engagement areas of investigation", yang membagi engagement menjadi empat dimensi: conceptualisation, platforms, measurement, dan behaviours. Kerangka ini menunjukkan bahwa yang harus dipahami dalam engagement tidak hanya dari tindakan seperti likes atau comments, melainkan juga bagaimana karakteristik platform membentuk pola interaksi pengguna, bagaimana metrik dihitung, serta bagaimana perilaku pengguna memengaruhi keterlibatan

tersebut.



Gambar 2.3: Sosial Media Engagement

Sumber: Trunfio & Rossi (2021)

Struktur konseptual ini menunjukkan bahwa pengukuran engagement tidak dapat dilepaskan dari konteks teknis platform. Perilaku pengguna yang cenderung menonton secara cepat, maupun kemungkinan adanya praktik boosting. Oleh karena itu, analisis keterlibatan tidak cukup melihat satu metrik secara terpisah, tetapi harus mempertimbangkan hubungan antar metrik dan pola interaksi pengguna secara keseluruhan. Pemahaman ini penting agar interpretasi data tidak bias dan tetap menggambarkan kondisi interaksi yang sebenarnya. Setelah kerangka engagement dipahami, langkah selanjutnya adalah melakukan pengukuran engagement secara kuantitatif. Salah satu pendekatan yang umum digunakan adalah pengukuran rasio antara total interaksi dan basis audiens. Liang dan Wolfe (2022) dalam studi “Getting a Feel of Instagram

Reels : The Effects of Posting Format on Online Engagement” menggunakan metrik Engagement Score yang dirumuskan sebagai berikut:

$$Engagement\ Score = \frac{(Likes + (2 \times Comments))}{Followers} \times 100 \quad (2.1)$$

Sumber: Liang & Wolfe (2022)

Liang dan Wolfe (2022) menggunakan metrik *Engagement Score* sebagaimana ditunjukkan pada Persamaan 2.1 untuk mengukur tingkat interaksi pengguna pada konten instagram reels. Dalam rumus metrik tersebut, komentar diberikan bobot yang lebih besar dibandingkan dengan likes, karena aktivitas memberikan komentar umumnya membutuhkan lebih banyak waktu dan usaha daripada hanya sekedar menyukai sebuah postingan. Oleh karena itu, konten dengan jumlah komentar yang lebih tinggi mencerminkan tingkat interaksi pengguna yang lebih dalam. Selain itu, penggunaan jumlah pengikut sebagai penyebut didasarkan pada karakteristik Instagram sebagai platform berbasis feed, di mana pengikut merepresentasikan pengguna utama konten.

Namun, karakteristik TikTok berbeda dengan Instagram. Distribusi konten TikTok tidak bergantung pada jumlah pengikut, melainkan pada sistem rekomendasi For You Page (FYP), sehingga jumlah pengikut tidak selalu mencerminkan jumlah pengguna yang melihat konten. Oleh karena itu, penelitian ini mengadaptasi Persamaan 2.1 dengan mengganti penyebut jumlah pengikut menjadi jumlah penayangan (views), serta menyederhanakan bobot interaksi agar sesuai dengan karakteristik data yang dianalisis.

$$ER = \frac{Likes + Comments + Shares}{Views} \times 100\% \quad (2.2)$$

Engagement Rate pada Persamaan 2.2 merepresentasikan tingkat interaksi pengguna terhadap konten yang benar-benar terekspos. Dengan menggunakan jumlah penayangan (views) sebagai penyebut, metrik ini menggambarkan proporsi interaksi yang terjadi relatif terhadap jumlah pengguna yang melihat konten tersebut. Pendekatan ini memungkinkan perbandingan tingkat engagement antar konten secara lebih adil, meskipun memiliki perbedaan jangkauan penayangan.

Pada platform berbasis video pendek seperti TikTok, jumlah views menjadi indikator utama eksposur konten karena distribusi konten tidak bergantung secara langsung pada jumlah pengikut akun. Oleh karena itu, Engagement Rate berbasis views dinilai lebih representatif dalam menggambarkan perilaku interaksi pengguna dibandingkan metrik berbasis jumlah pengikut. Metrik ini kemudian digunakan sebagai dasar untuk perhitungan metrik turunan dan analisis pola engagement pada tahap selanjutnya.

3. *Engagement* TikTok

TikTok merupakan salah satu platform yang paling rentan terhadap fenomena *fake engagement* karena algoritma TikTok berfokus pada distribusi konten berdasarkan interaksi awal (*early engagement signals*). Salah satu pola yang paling sering ditemui adalah ketidakseimbangan antara jumlah *views* yang sangat tinggi dengan jumlah *likes* atau *comments* bahkan *shares* yang rendah. Pola ini dapat menunjukkan rendahnya *engagement* suatu konten atau adanya indikasi *boosting*, yaitu suatu cara untuk meningkatkan metrik penayangan dengan cara yang tidak alami. Menurut Kumar dan Shah (2018) pola tersebut sering kali dihasilkan oleh aktivitas akun otomatis (bot) atau sistem otomatis yang dirancang untuk meningkatkan *engagement* tanpa memerlukan aktivitas langsung dari pengguna. Oleh karena itu, algoritma TikTok sering kali dapat

tertipu oleh peningkatan *engagement* palsu ini sehingga konten yang sebenarnya memiliki *engagement* rendah tetap mendapatkan jangkauan penayangan yang luas.

Untuk mengidentifikasi adanya kejanggalan dalam interaksi pengguna, penelitian ini menggunakan berbagai *engagement-based ratio*. Nilai rasio yang jauh dari batas wajar menunjukkan adanya ketidakseimbangan antara metrik satu dengan metrik lainnya dalam interaksi alami pengguna, yang dapat menjadi indikasi terjadinya *fake engagement*. Pendekatan berbasis rasio ini menjadi landasan dalam pengembangan *rule-based metric* yang akan digunakan. Melalui kombinasi antara *Engagement Rate (ER)* dengan rasio metrik interaksi, analisis tingkat kejanggalan ini dapat dilakukan secara menyeluruh untuk membedakan interaksi yang alami dengan interaksi yang dihasilkan secara artifisial.

4. Rule-Based Metric

Pendekatan Rule-Based Metric digunakan untuk mendeteksi pola kejanggalan keterlibatan yang tidak wajar di media sosial dengan menetapkan aturan berdasarkan metrik perilaku. Ferrara, dkk. (2016) menyebutkan bahwa pendekatan berbasis aturan efektif untuk mendeteksi pola aktivitas otomatis karena indikatornya yang mudah diinterpretasikan dan mudah dianalisis. Metode ini bekerja dengan membandingkan nilai individu dengan pola distribusi normal untuk mendapatkan pola anomali yang signifikan. Dalam konteks pengukuran keterlibatan, metrik seperti *like*, *comment*, *share* dan *views* merupakan representasi langsung dari kontribusi pengguna terhadap suatu konten di media sosial (Trunfio & Rossi, (2021).

Keempat metrik ini dapat diadaptasi menjadi perhitungan kuantitatif untuk menilai kewajaran interaksi. Pendekatan yang serupa ini diadaptasi dalam industri pemasaran digital seperti

HypeAuditor (2025) yang menggunakan rasio antar metrik untuk mengidentifikasi *influencer fraud*.

RivallIQ (2024) menjelaskan *Engagement Rate by View* sebagai jumlah total interaksi (*likes, comments, dan shares*) yang dibagi dengan total penayangan (*views*). Definisi ini menjadi dasar bagi penelitian ini untuk menurunkan metrik turun seperti Like-to-View Ratio (LVR), Comment-to-View (CVR), dan Share-to-View Ratio (SVR). Penggunaan rasio ini juga sejalan dengan temuan Cheng dan Li (2024), yang menyatakan bahwa pembagian *likes, comments, dan shares* terhadap *views* memberikan perkiraan yang lebih akurat untuk menilai keberhasilan dan keterlibatan pada TikTok, mengingat setiap video yang muncul di *For Your Page* langsung dihitung sebagai *views* meski belum tentu menghasilkan interaksi aktif.

Secara matematis, metrik-metrik tersebut dirumuskan sebagai berikut:

$$LVR = \frac{\text{Likes}}{\text{Views}} \times 100\% \quad (2.3)$$

$$CVR = \frac{\text{Comments}}{\text{Views}} \times 100\% \quad (2.4)$$

$$SVR = \frac{\text{Shares}}{\text{Views}} \times 100\% \quad (2.5)$$

Sumber: Cheng & Li (2024)

Ketiga rasio ini digunakan untuk menilai proporsi interaksi terhadap tingkat paparan konten. LVR digunakan untuk menjelaskan seberapa banyak penonton yang memberikan *likes*, CVR menggambarkan proporsi penonton yang memberikan komentar, sedangkan SVR merepresentasikan proporsi penonton yang membagikan konten. Metrik rasio tersebut digunakan

sebagai indikator awal untuk menggambarkan pola keterkaitan antar metrik interaksi, namun tidak dijadikan sebagai penentu akhir adanya praktik engagement boosting. Metrik-metrik ini berfungsi untuk mengidentifikasi pola interaksi yang berpotensi menyimpang sebelum dianalisis lebih lanjut menggunakan metode deteksi anomali.

Tidak seluruh konten dengan nilai engagement tinggi dapat langsung dianggap sebagai anomali. Konten yang bersifat viral secara alami umumnya menunjukkan peningkatan interaksi yang relatif proporsional, di mana jumlah likes, komentar, dan share meningkat sejalan dengan jumlah view. Sebaliknya, praktik engagement boosting cenderung menghasilkan pola interaksi yang tidak seimbang, misalnya jumlah penayangan yang sangat tinggi tetapi tidak diikuti oleh peningkatan interaksi secara wajar. Oleh karena itu, penentuan anomali dalam penelitian ini tidak didasarkan pada besarnya nilai engagement semata, melainkan pada pola keterkaitan antar metrik interaksi yang dianalisis secara multivariat, sehingga model dapat membedakan antara konten viral yang tumbuh secara organik dan konten dengan indikasi manipulasi.

5. Isolation Forest

Isolation forest merupakan algoritma deteksi anomali yang pertama kali dikenalkan oleh Liu, Tang dan Zhou (2008). Algoritma ini dikembangkan berdasarkan prinsip bahwa data anomali memiliki karakteristik yang berbeda dari data normal, yaitu jumlahnya relatif sedikit dan posisinya cenderung berada jauh dari mayoritas data. Dengan karakteristik tersebut, data anomali secara alami dapat dipisahkan melalui pemisahan acak dibandingkan titik data normal (Liu dkk.,2008).

Berbeda dengan metode deteksi anomali pada umumnya yang membangun model distribusi data normal terlebih dahulu, Isolation

Forest tidak bergantung pada estimasi kepadatan, jarak antar data, maupun asumsi bentuk distribusi tertentu. Sebaliknya, Isolation Forest secara langsung memanfaatkan mekanisme isolasi, di mana suatu titik data dianggap anomali apabila dapat dipisahkan dari kumpulan data lainnya dalam jumlah langkah yang relatif lebih sedikit (Liu, 2008). Pendekatan ini membuat Isolation Forest sangat sesuai untuk data berdimensi tinggi, tidak berlabel, serta memiliki distribusi yang tidak beraturan, seperti data interaksi pada media sosial.

Selain itu, Isolation Forest memiliki beberapa keunggulan dibandingkan metode deteksi anomali lainnya. Algoritma ini memiliki kompleksitas komputasi yang rendah dan dapat bekerja secara efisien pada dataset berukuran besar. Isolation Forest juga tidak memerlukan proses pelatihan berbasis distribusi data normal maupun penentuan jarak antar titik data, sehingga lebih stabil pada data berdimensi tinggi. Kemampuan untuk mendeteksi anomali tanpa memerlukan data berlabel menjadikan metode ini sesuai untuk konteks data interaksi media sosial yang bersifat dinamis dan sulit diklasifikasikan secara manual.

Konsep utama dalam Isolation Forest adalah proses *isolasi*, yaitu memisahkan suatu data dari data lainnya melalui pembentukan partisi secara acak. Data yang bersifat anomali cenderung lebih mudah terisolasi karena memiliki karakteristik yang jarang muncul dibandingkan mayoritas data. Isolation Forest (*iForest*) bekerja dengan membangun sekumpulan pohon isolasi (*isolation trees*) sebagai sebuah *ensemble*, di mana suatu data dianggap sebagai anomali apabila memiliki panjang jalur rata-rata yang lebih pendek dibandingkan sebagian besar data lainnya. Setiap pohon dibangun secara independen dari sampel acak berukuran ψ , dengan jumlah pohon dan ukuran subsampling sebagai parameter utama dalam proses pembentukan model.


Pada setiap node dalam pohon, algoritma memilih satu fitur

secara acak, kemudian menentukan nilai batas pemisahan (*split value*) secara acak dari rentang nilai minimum hingga maksimum fitur tersebut (Liu dkk., 2008). Berbeda dengan metode pohon keputusan pada Random Forest yang menentukan pemisahan terbaik berdasarkan kriteria impurity seperti Gini Index atau Entropy, Isolation Forest tidak mengevaluasi kualitas pemisahan pada setiap node. Pada setiap proses split, satu fitur dipilih secara acak, kemudian nilai batas pemisahan diambil secara acak dengan peluang yang sama pada seluruh rentang nilai minimum hingga maksimum fitur tersebut tanpa mempertimbangkan distribusi kelas maupun penurunan impurity (Liu dkk., 2008).

Pendekatan pemisahan acak ini bertujuan bukan untuk membangun model klasifikasi yang optimal, melainkan untuk mempercepat proses isolasi titik data. Data yang berada pada daerah jarang atau memiliki nilai ekstrem cenderung terpisah lebih awal hanya dengan beberapa kali pemisahan acak, sehingga menghasilkan panjang jalur yang lebih pendek dibandingkan data normal. Karakteristik inilah yang dimanfaatkan Isolation Forest untuk membedakan data anomali dan data normal berdasarkan perbedaan *path length*.

Data kemudian dipisahkan ke dalam dua subset berdasarkan nilai pemisahan yang dipilih. Proses pemisahan ini dilakukan secara rekursif hingga salah satu dari dua kondisi tercapai, yaitu data pada node tidak dapat dipisahkan lebih lanjut atau kedalaman maksimum pohon telah tercapai. Struktur iTree berbentuk pohon biner, di mana node internal merepresentasikan proses pemisahan, sedangkan node eksternal (*leaf node*) menunjukkan titik di mana proses isolasi berhenti. Liu dkk. (2008) menunjukkan bahwa titik data yang bersifat anomali cenderung mencapai leaf node lebih cepat karena posisinya yang terpencil, sementara data normal membutuhkan lebih banyak pemisahan untuk dapat terisolasi.

Struktur *isolation tree* pada Isolation Forest dapat divisualisasikan dalam bentuk pohon biner dengan kedalaman terbatas oleh ukuran sub-sampling ψ . Gambar 2.4 merupakan ilustrasi konseptual untuk menunjukkan mekanisme pemisahan acak dan perbedaan jalur isolasi antara data normal dan data anomali.




Gambar 2.4: Ilustrasi struktur *isolation tree* dengan ukuran sub-sampling $\psi = 8$

Ilustrasi disusun berdasarkan konsep Isolation Forest oleh Liu dkk. (2008)

Gambar 2.4 memperlihatkan bagaimana node internal melakukan pemisahan acak, sedangkan node eksternal adalah *leaf node* tempat data berhenti bekerja. Data anomali cenderung mencapai node eksternal dengan cepat dibandingkan data normal. Karena titik anomali jumlahnya sedikit dan berada di area jarang, pemisahan menjadi lebih mengisolasi titik tersebut. Sebaliknya, data normal membutuhkan lebih banyak pemisahan sebelum mencapai *leaf node*. Oleh karena itu, panjang jalur dari akar menuju *leaf node* menjadi indikator utama untuk menilai apakah suatu titik berpotensi anomali.

Namun, ilustrasi pada Gambar 2.4 belum secara eksplisit menunjukkan perbedaan perilaku isolasi antara data normal dan data anomali. Untuk memperjelas perbedaan proses isolasi antara data normal dan data anomali, Gambar 2.5 menampilkan ilustrasi satu *isolation tree* dengan penandaan titik normal dan titik anomali beserta perbedaan panjang jalurnya.



Gambar 2.5: Ilustrasi perbedaan *path length* antara data normal dan data anomali pada *isolation tree*


Ilustrasi disusun berdasarkan konsep Isolation Forest oleh Liu dkk. (2008)

Pada Gambar 2.5, jalur yang berwarna merah merepresentasikan jalur isolasi anomali, sedangkan jalur berwarna biru menunjukkan jalur data normal. Titik anomali cenderung lebih cepat terpisah dari kelompok utama sehingga mencapai *leaf node* hanya dalam beberapa kali pemisahan dan memiliki *path length* yang lebih pendek. Sebaliknya, data normal membutuhkan lebih banyak pemisahan sebelum terisolasi sehingga memiliki *path length* yang lebih panjang. Perbedaan panjang jalur inilah yang menjadi dasar utama dalam perhitungan skor anomali pada Isolation Forest.

Meskipun beberapa *leaf node* pada ilustrasi hanya berisi satu

titik data, penentuan anomali tidak didasarkan pada jumlah titik dalam leaf node, melainkan pada panjang jalur isolasi (path length) yang ditempuh titik tersebut. Titik data yang mencapai leaf node melalui jalur yang panjang tetap dikategorikan sebagai data normal karena berada di area dengan kepadatan data tinggi, sedangkan titik yang terisolasi dalam jalur yang sangat pendek memiliki skor anomali yang lebih tinggi.

Untuk memperjelas perbedaan proses isolasi antara data normal dan data anomali, Gambar 2.6 memberikan ilustrasi proses isolasi secara visual.



Gambar 2.6: Anomali (x_0) diisolasi lebih cepat daripada data normal (x_1)

Sumber: Liu, dkk. (2008)

Pada Gambar 2.6 menunjukkan bahwa titik yang berada jauh dari pola mayoritas akan lebih cepat mencapai *leaf node* sehingga memiliki *path length* yang lebih pendek. *Path length* didefinisikan sebagai jumlah *edge* yang dilalui dari node akar hingga mencapai *leaf node* tempat suatu titik data berhenti. Untuk suatu titik data x , nilai *path length* dilambangkan sebagai $h(x)$. Semakin pendek nilai $h(x)$, semakin cepat titik tersebut terisolasi, dan semakin besar kemungkinan titik tersebut merupakan anomali. Hal ini menjadi dasar utama dari mekanisme deteksi anomali pada Isolation forest.

Untuk menentukan panjang suatu titik wajar atau tidak, Liu dkk. (2008) memperkenalkan konsep *expected path length* yang

dinyatakan dengan fungsi $c(n)$ dimana n adalah jumlah sampel data yang digunakan untuk membangun satu iTree. Nilai $c(n)$ merepresentasikan ekspektasi panjang jalur rata-rata pada sebuah binary search tree acak dan dirumuskan sebagai berikut:

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n} \quad (2.6)$$

Sumber: Liu, dkk. (2008)

dengan keterangan:

- n adalah jumlah sampel data yang digunakan dalam satu *isolation tree*.
- $H(n)$ adalah bilangan harmonik ke- n , yang dalam pendekatan kontinu dapat dihampiri dengan:

$$H(n) \approx \ln(n) + \gamma \quad (2.7)$$

di mana $\ln(n)$ menyatakan logaritma natural dengan basis bilangan e , sedangkan γ merupakan konstanta Euler Mascheroni dengan nilai mendekati 0.57721.

Nilai $c(n)$ digunakan sebagai pembanding untuk mengetahui apakah suatu titik memiliki panjang jalur lebih pendek dari distribusi normal.

Berdasarkan nilai *path length* dan *expected path length*, Liu dkk. (2008) mendefinisikan skor anomali untuk suatu titik data x sebagai:

$$s(x, n) = 2 \left(-\frac{E(h(x))}{c(n)} \right) \quad (2.8)$$

Sumber: Liu, dkk. (2008)

dengan keterangan:

- x : titik data yang sedang dievaluasi.
- $E(h(x))$: nilai rata-rata *path length* titik x pada seluruh *isolation tree*.
- $s(x, n)$: skor anomali yang berada pada rentang 0–1.

Nilai $s(x, n)$ yang mendekati 1 menunjukkan bahwa titik tersebut memiliki *path length* yang jauh lebih pendek sehingga berpotensi menjadi anomali. Sebaliknya, nilai yang mendekati 0 mengindikasikan bahwa titik tersebut mengikuti pola distribusi normal.

Dalam konteks media sosial, aktivitas manipulatif seperti *fake engagement* sering kali muncul dalam bentuk pola interaksi yang menyimpang tanpa adanya label *ground truth* yang jelas. Zouzou dan Varol (2024) menunjukkan bahwa pendekatan *unsupervised anomaly detection* lebih sesuai untuk mendeteksi pola semacam ini karena mampu mengidentifikasi penyimpangan berbasis struktur data tanpa ketergantungan pada pelabelan manual. Sejalan dengan temuan tersebut, Isolation forest relevan digunakan dalam penelitian ini karena memanfaatkan perbedaan panjang jalur isolasi dan skor anomali untuk mengungkap indikasi keterlibatan yang tidak wajar pada konten TikTok secara objektif.

BAB III

METODE PENELITIAN

A. Dataset

Dataset penelitian ini terdiri atas data konten dan metrik interaksi Key Opinion Leader (KOL) pada platform TikTok yang diperoleh melalui proses *web scraping*. Data mencakup informasi konten serta performanya, seperti jumlah *followers*, *likes*, *comments*, dan metrik interaksi lainnya. Dataset tersebut digunakan sebagai dasar perhitungan metrik turunan sekaligus sebagai input dalam proses deteksi anomali menggunakan algoritma Isolation Forest.

Struktur dataset mencakup variabel yang merepresentasikan identitas konten, atribut akun KOL, metrik interaksi, serta metrik turunan. Rincian nama variabel, tipe data, dan deskripsi setiap atribut disajikan pada Tabel 3.1.

Tabel 3.1: Daftar Variabel Dataset Penelitian

Nama Variabel	Tipe Data	Deskripsi
Post_Code	String	Kode unik setiap konten.
Post_Date	Date	Tanggal unggah konten.
Followers	Integer	Jumlah pengikut akun KOL.
KOL_Tier	String	Tingkatan kategori KOL.
Is_Endorse	String	Penanda apakah konten merupakan konten endorse atau tidak.
Views	Integer	Jumlah tayangan pada konten.
Likes	Integer	Jumlah suka pada konten.
Comments	Integer	Jumlah komentar pada konten.
Shares	Integer	Jumlah bagikan pada konten.
LVR	Float	Like-to-View Ratio.
CVR	Float	Comment-to-View Ratio.
SVR	Float	Share-to-View Ratio.
ER	Float	Engagement Rate total pada konten.

Berdasarkan Tabel 3.1, variabel dalam dataset terdiri atas atribut identitas konten, atribut akun KOL, metrik interaksi, serta metrik turunan hasil perhitungan rasio. Variabel identitas dan atribut kategorikal digunakan sebagai informasi pendukung untuk keperluan pelacakan dan interpretasi data, sedangkan variabel numerik berupa metrik interaksi dan metrik turunan digunakan sebagai variabel masukan dalam tahap analisis awal dan pemodelan deteksi anomali. Pemisahan ini bertujuan memastikan bahwa model hanya memproses data numerik yang relevan, sementara atribut non-numerik tetap dipertahankan sebagai konteks dalam analisis hasil.

1. Fitur Asli

Fitur asli (*raw feature*) ini merupakan dasar untuk memahami karakteristik engagement pada setiap postingan sebelum dilakukan proses pembersihan dan perhitungan metrik turunan. Pada tahap ini, data masih menampilkan nilai mentah sebagaimana adanya di platform TikTok, termasuk variasi jumlah interaksi, perbedaan jumlah pengikut antar KOL, serta tingkatan KOL yang dapat memengaruhi performa konten. Adanya fitur asli ini penting sebagai acuan awal untuk melihat skala dan ketimpangan distribusi data sebelum dilakukan normalisasi atau pembentukan rasio.

Melalui cuplikan data pada ?? dan ??, terlihat bahwa setiap KOL memiliki pola interaksi yang berbeda-beda. Beberapa konten memperoleh jumlah views yang sangat tinggi, sementara yang lain hanya mendapatkan sedikit interaksi. Perbedaan ini penting untuk diperhatikan karena menjadi faktor yang berpengaruh dalam proses evaluasi engagement serta pendeteksian anomali pada tahap analisis berikutnya, terutama dalam membedakan pola interaksi yang wajar dengan pola yang berpotensi menyimpang akibat interaksi tidak alami.

Tabel 3.2: Cuplikan Data Metrik Asli

Post Date	Followers	Tier	Endorse	Likes	Comments	Shares	Views
30/08/2025	1,353	Nano	No	69	3	0	576
28/09/2025	44,300	Micro	No	20	1	2	270
02/10/2025	101,100	Midi	Yes	269	0	6	11,700
04/08/2025	742,500	Macro	Yes	2,868	40	83	150,400
04/10/2025	3,800,000	Mega	Yes	2,202	103	32	238,600

2. Fitur Turunan

Selain data mentah, penelitian ini juga menghasilkan sejumlah variabel turunan (*feature engineering*) yang dihitung menggunakan kombinasi metrik dasar. Pembentukan variabel turunan ini dilakukan untuk menghasilkan representasi interaksi yang lebih proporsional sehingga setiap metrik dapat dibandingkan secara seimbang. Dengan adanya variabel turunan ini, pola interaksi yang tidak wajar menjadi lebih mudah diamati dibandingkan jika hanya menggunakan nilai mentah.

Variabel turunan tersebut mencakup Like-to-View Ratio (LVR), Comment-to-View Ratio (CVR), Share-to-View Ratio (SVR), dan Engagement Rate (ER). Keempat metrik ini berfungsi sebagai indikator awal dalam mendeteksi potensi fake engagement, karena rasio-rasio tersebut dapat memperlihatkan ketidakseimbangan antara jumlah interaksi dengan jangkauan konten.

$$ER = \frac{Likes + Comments + Shares}{Views} \times 100\% \quad (3.1)$$

$$LVR = \frac{Likes}{Views} \times 100\% \quad (3.2)$$

$$CVR = \frac{Comments}{Views} \times 100\% \quad (3.3)$$

$$SVR = \frac{\text{Shares}}{\text{Views}} \times 100\% \quad (3.4)$$

Setelah metrik dasar diperoleh, dilakukan pembentukan variabel turunan melalui perhitungan rasio interaksi terhadap jumlah penayangan sebagaimana dirumuskan pada Persamaan (3.1) hingga (3.4). Pembentukan rasio ini bertujuan untuk menormalkan perbedaan skala antar konten serta merepresentasikan pola interaksi pengguna secara lebih proporsional. Dengan menggunakan rasio terhadap jumlah *views*, setiap metrik tidak lagi dipengaruhi secara langsung oleh besarnya jangkauan konten, sehingga memungkinkan perbandingan yang lebih adil antar konten dan antar tingkat KOL. Variabel turunan ini selanjutnya digunakan sebagai representasi fitur dalam tahap analisis berikutnya karena mampu menangkap karakteristik interaksi yang tidak terlihat apabila hanya menggunakan nilai metrik mentah. Cuplikan data turunan ditunjukkan pada Tabel 3.3.


Tabel 3.3: Cuplikan Data Metrik Turunan

LVR	CVR	SVR	ER
1.2×10^{-1}	5×10^{-3}	0	1.25×10^{-1}
7.4×10^{-2}	4×10^{-3}	7×10^{-3}	8.5×10^{-2}
2.3×10^{-2}	4×10^{-5}	1×10^{-3}	2.4×10^{-2}
1.9×10^{-2}	3×10^{-4}	1×10^{-3}	2×10^{-2}
9.2×10^{-3}	4×10^{-4}	1.3×10^{-3}	1×10^{-2}

Nilai rasio LVR, CVR, SVR, dan ER yang diperoleh umumnya berada pada rentang bilangan desimal yang sangat kecil, khususnya pada metrik CVR dan SVR yang merepresentasikan proporsi interaksi terhadap jumlah penayangan. Perbedaan skala antar nilai tersebut mencerminkan variasi tingkat keterlibatan pengguna pada setiap konten serta menunjukkan bahwa sebagian besar interaksi hanya melibatkan sebagian kecil dari total penonton.

Penyajian nilai rasio dalam Tabel 3.3 digunakan sebagai gambaran awal karakteristik distribusi metrik engagement pada setiap KOL sebelum dilakukan analisis kewajaran dan pemodelan deteksi anomali. Variabel turunan ini selanjutnya digunakan sebagai fitur masukan pada tahap analisis berikutnya untuk mengidentifikasi pola interaksi yang wajar maupun menyimpang secara lebih objektif.

B. Alur Penelitian



Gambar 3.1: Alur Penelitian

Alur penelitian disusun untuk menggambarkan proses penelitian mulai dari pengambilan data hingga interpretasi hasil deteksi anomali engagement pada konten endorsement TikTok. Alur penelitian ini disajikan dalam bentuk flowchart utama yang memuat tahapan analisis awal secara terintegrasi, serta dilengkapi dengan satu sub-flowchart, untuk menjelaskan proses deteksi anomali engagement menggunakan metode Isolation forest secara lebih

rinci. Berdasarkan Gambar 3.1, tahapan penelitian yang dilakukan adalah sebagai berikut.

1. Identifikasi Masalah

Penelitian diawali dengan mengidentifikasi permasalahan terkait potensi fake engagement pada kampanye endorsement TikTok *brand skincare*. Dari hasil pengamatan awal, ditemukan beberapa konten KOL yang menunjukkan pola interaksi tidak seimbang, misalnya rasio likes, comments, atau views yang tampak tidak konsisten dengan performa wajar. Temuan ini menjadi dasar untuk merumuskan fokus penelitian, yaitu menganalisis dan mendeteksi indikasi kegagalan engagement dengan pendekatan kombinasi rule-based metrics dan model deteksi anomali.

2. Pengumpulan Data

Setelah permasalahan terdefinisi, peneliti mengumpulkan data konten KOL yang terlibat dalam kampanye *brand skincare*. Peneliti menggunakan teknik scraping dengan Selenium Webdriver untuk mengisi metrik engagement konten tiap KOL. Scraping dilakukan dengan memanfaatkan browser Chrome dalam mode debugging untuk memastikan browser stabil dan tidak mengalami pemutusan sesi selama proses pengambilan data metrik engagement. Setiap halaman video TikTok dimuat secara otomatis oleh Selenium, kemudian metrik engagement diekstraksi menggunakan XPath dari elemen HTML yang relevan. Proses ini dilakukan untuk seluruh sampel secara berurutan.


3. Pra-Pemrosesan Data

Dataset hasil scraping selanjutnya melalui tahap pra-pemrosesan. Pada tahap ini dilakukan perbaikan format numerik, penanganan data duplikat, serta pengecekan kelengkapan data. Hasil dari tahap ini adalah dataset yang telah siap digunakan untuk proses analisis statistik dan pemodelan.

Selain itu, dilakukan proses normalisasi data untuk menyamakan skala antar variabel sebelum digunakan sebagai input model. Normalisasi diperlukan karena setiap metrik memiliki rentang nilai yang berbeda, terutama akibat variasi tingkat popularitas konten dan perbedaan *tier* kreator. Pada penelitian ini digunakan metode *min-max normalization* untuk memetakan seluruh nilai fitur ke dalam rentang $[0,1]$, sehingga setiap variabel memiliki kontribusi yang seimbang dalam proses deteksi anomali.

Variabel tingkat kreator (*tier*) juga diproses pada tahap pra-pemrosesan sebagai dasar segmentasi data. Variabel ini dikodekan menggunakan teknik *one-hot encoding* untuk merepresentasikan kategori kreator tanpa memberikan makna numerik berurutan. Pengkodean ini tidak digunakan sebagai label maupun sebagai fitur input model, melainkan sebagai dasar untuk melakukan pemisahan dataset berdasarkan *tier*.

4. Tahap Analisis Awal



Gambar 3.2: Flowchart off-page Analisis Awal

Tahap analisis awal dijelaskan lebih rinci pada offpage flowchart A. Pada tahap ini, data hasil pra-pemrosesan digunakan sebagai

input untuk dilakukan analisis statistik deskriptif dan analisis distribusi engagement. Analisis mencakup sebaran *views*, *likes*, *comments*, dan *shares* untuk memahami karakteristik dasar data. Selain itu, pada tahap ini dilakukan perhitungan rasio metrik (*rule-based metrics*) yang terdiri dari Engagement Rate (ER), Like-to-View Ratio (LVR), Comment-to-View (CVR) dan Share-to-View (SVR) sebagaimana ditunjukkan pada persamaan (3.1) hingga (3.4). Metrik-metrik ini digunakan untuk merepresentasikan interaksi secara lebih proporsional dan memungkinkan perbandingan performa antar konten dan antar tingkat KOL secara adil.

Untuk mengidentifikasi indikasi awal kegagalan, nilai metrik turunan tersebut diuji kewajarannya menggunakan pendekatan Interquartile Range (IQR) sebagaimana persamaan (3.5) dan (3.6). Pendekatan ini digunakan karena data engagement media sosial umumnya tidak mengikuti distribusi normal dan cenderung menunjukkan variasi yang besar antar pengguna maupun kelompok konten. Analisis empiris terhadap pola interaksi pada komunitas media sosial menunjukkan bahwa jumlah interaksi dapat sangat berbeda antar kelompok pengguna dan aktivitas konten, yang mencerminkan sebaran metrik yang luas dan beragam (Liang dkk., 2015).

$$IQR = Q3 - Q1 \quad (3.5)$$

$$Batas\ atas = Q3 + 1.5 \times IQR \quad (3.6)$$

Berbeda dengan metode berbasis rata-rata dan simpangan baku, IQR hanya bergantung pada kuartil sehingga tidak sensitif terhadap nilai ekstrem. Karakteristik ini menjadikan IQR lebih sesuai untuk mengevaluasi kewajaran metrik *engagement* yang secara alami memiliki variasi tinggi dan rentang nilai yang lebar. Oleh karena itu, penggunaan IQR pada tahap analisis awal bertujuan untuk memberikan batas kewajaran statistik yang stabil sebelum data diproses lebih lanjut menggunakan


model deteksi anomali berbasis *unsupervised learning*.

Berdasarkan hasil analisis awal tersebut, fitur masukan yang digunakan pada tahap pemodelan terdiri dari metrik asli, yaitu *views*, *likes*, *comments*, dan *shares*, serta metrik turunan berupa Engagement Rate (ER), Like-to-View Ratio (LVR), Comment-to-View Ratio (CVR), dan Share-to-View Ratio (SVR). Pemilihan fitur ini bertujuan merepresentasikan pola interaksi secara lebih proporsional serta menangkap ketidakseimbangan antara metrik interaksi yang tidak dapat dijelaskan hanya melalui data mentah, sehingga sesuai digunakan sebagai input pada proses deteksi anomali menggunakan Isolation Forest.

Pada tahap pemodelan, hanya fitur numerik yang digunakan sebagai masukan, yaitu metrik interaksi dan metrik turunan (ER, LVR, CVR, dan SVR). Sementara itu, atribut berbentuk teks atau kategori (*string*) tidak digunakan sebagai fitur input karena tidak dapat langsung diproses oleh mekanisme pemisahan acak pada Isolation Forest tanpa transformasi numerik. Kolom *string* tetap dipertahankan pada dataset untuk keperluan pelacakan dan interpretasi konten yang teridentifikasi sebagai anomali.

Dengan pembatasan tersebut, penelitian ini berfokus pada analisis pola kegagalan *engagement* berdasarkan metrik interaksi numerik tanpa mempertimbangkan isi, sentimen, maupun konteks semantik konten. Oleh karena itu, penelitian ini tidak membedakan apakah suatu konten bersifat positif atau negatif, melainkan menekankan pada ketidakseimbangan pola interaksi sebagai indikator awal adanya *engagement* yang tidak wajar.

5. Deteksi Anomali Engagement



Gambar 3.3: Flowchart off-page Deteksi Anomali

Tahap perancangan model deteksi anomali pada penelitian ini mengikuti alur yang ditunjukkan pada off-page flowchart B. Proses diawali dengan penentuan variabel masukan yang digunakan oleh model Isolation forest. Variabel yang digunakan bukan berupa data mentah, melainkan metrik turunan hasil perhitungan pada tahap analisis awal, seperti Engagement Rate (ER), Like-to-View Ratio (LVR), Comment-to-View Ratio (CVR), dan Share-to-View Ratio (SVR). Penggunaan metrik turunan ini bertujuan untuk merepresentasikan pola interaksi secara proporsional serta mengurangi pengaruh perbedaan skala akibat variasi jumlah pengikut dan jumlah tayangan antar KOL, sehingga pola kegagalan dapat diamati secara lebih adil.

Pada penelitian ini, algoritma Isolation Forest diimplementasikan berdasarkan parameter utama yang diperkenalkan oleh Liu dkk. (2008), yaitu jumlah pohon isolasi (t) dan ukuran subsampling data (ψ) pada setiap pohon. Parameter t digunakan untuk menentukan jumlah *isolation tree* yang dibangun, sedangkan parameter ψ menentukan jumlah sampel acak yang digunakan dalam pembentukan setiap

pohon. Pembatasan kedalaman pohon ditentukan berdasarkan nilai $\lceil \log_2 \psi \rceil$ untuk menjaga efisiensi komputasi dan kestabilan model.

Setelah variabel masukan ditentukan, Isolation forest membangun model dengan melakukan pengambilan sampel acak (*subsampling*) dari dataset untuk setiap pohon yang akan dibentuk. *Subsampling* dilakukan dengan ukuran tetap pohon yang dibentuk. *Subsampling* dilakukan dengan ukuran tetap ψ dan bertujuan untuk meningkatkan efisiensi komputasi sekaligus memperkuat kemampuan model dalam mengisolasi data yang jarang muncul. Dari setiap subsample, dibangun sebuah *isolation tree* melalui pemisahan data secara acak, di mana pada setiap node dipilih satu fitur dan satu nilai batas pemisah secara acak. Proses ini dilakukan secara berulang hingga data tidak dapat dipisahkan lagi atau kedalaman maksimum pohon tercapai, sehingga terbentuk leaf node sebagai titik akhir pemisahan.

Karakteristik utama yang diamati pada setiap *isolation tree* adalah *path length*, yaitu jumlah node yang dilalui suatu titik data dari akar hingga leaf node. Data yang menyimpang dari mayoritas pola cenderung lebih cepat terisolasi dan memiliki *path length* yang lebih pendek, sedangkan data normal membutuhkan lebih banyak pemisahan. Nilai *path length* ini kemudian dirata-ratakan pada seluruh pohon untuk memperoleh $E(h(x))$ sebagai ukuran tingkat isolasi data.

Seluruh *isolation tree* selanjutnya digabungkan menjadi sebuah Isolation forest. Berdasarkan nilai $E(h(x))$ dan fungsi normalisasi $c(n)$, dihitung skor anomali dengan rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan tingkat kejanggalan yang lebih tinggi. Skor ini kemudian digunakan sebagai dasar dalam penentuan ambang anomali untuk mengidentifikasi konten yang berpotensi memiliki pola engagement tidak wajar.

6. Evaluasi Hasil Deteksi Anomali

Setelah proses deteksi anomali dilakukan menggunakan Isolation Forest, tahap selanjutnya adalah mengevaluasi hasil deteksi untuk menilai kualitas pemisahan antara data normal dan data anomali. Karena penelitian ini menggunakan pendekatan *unsupervised* dan tidak memiliki label, proses evaluasi tidak dilakukan menggunakan metrik klasifikasi, melainkan melalui analisis distribusi skor anomali dan pendekatan berbasis ambang keputusan sebagaimana direkomendasikan dalam literatur deteksi anomali (Liu dkk.,2008).

Evaluasi awal dilakukan dengan menganalisis distribusi skor anomali untuk mengamati pemisahan antara mayoritas data yang memiliki skor tinggi dan sebagian kecil data dengan skor rendah yang berada pada ekor distribusi. Selanjutnya, dilakukan analisis karakteristik metrik engagement antara data normal dan data yang terdeteksi sebagai anomali untuk memastikan bahwa konten anomali menunjukkan pola interaksi yang menyimpang dari mayoritas data (Zouzou dan Varol, 2024).

Setelah anomaly score diperoleh, proses identifikasi data anomali dilakukan menggunakan parameter *contamination* pada model Isolation Forest. Pada penelitian ini digunakan nilai contamination sebesar 5% untuk menentukan proporsi data yang diperkirakan sebagai anomali pada setiap tier KOL. Melalui parameter tersebut, model secara otomatis memisahkan data normal dan data anomali berdasarkan tingkat penyimpangan anomaly score terhadap distribusi utama data. Pendekatan ini dinilai sesuai untuk penelitian berbasis *unsupervised anomaly detection* karena tidak memerlukan ground truth label dalam proses identifikasi anomali.

7. Visualisasi Pola Anomali

Setelah proses deteksi anomali dilakukan, data divisualisasikan melalui grafik seperti histogram, boxplot, dan scatterplot untuk

melihat apakah konten yang terindikasi sebagai potensial anomali menunjukkan pola yang berbeda dibanding mayoritas data. Visualisasi ini juga menjadi langkah validasi untuk memastikan bahwa hasil model sejalan dengan kondisi nyata dari distribusi metrik di dataset.

8. Interpretasi Hasil dan Penarikan Kesimpulan

Tahap terakhir dilakukan dengan menginterpretasikan seluruh hasil analisis yang diperoleh dari kombinasi fitur engagement, anomaly score, dan visualisasi data. Berdasarkan hasil tersebut, peneliti dapat mengidentifikasi postingan yang memiliki pola engagement menyimpang dibanding mayoritas data serta memahami karakteristik interaksi pada data yang terindikasi sebagai potensial anomali. Hasil penelitian ini memberikan gambaran mengenai pola engagement pada konten endorsement TikTok dan menunjukkan bagaimana pendekatan Isolation Forest dapat digunakan untuk mendeteksi anomali engagement pada data tanpa label.

C. Jadwal Penelitian

Jadwal penelitian disusun berdasarkan alur pelaksanaan penelitian yang berlangsung selama empat bulan, mulai dari September hingga Desember. Pembagian waktu dilakukan secara mingguan untuk memberikan gambaran yang lebih rinci mengenai distribusi kegiatan, mulai dari studi literatur, pengambilan data, pengolahan data, analisis, hingga penyusunan laporan skripsi. Penjadwalan ini bersifat realistis dan mencerminkan aktivitas penelitian yang dilakukan secara bertahap sesuai perkembangan tiap fase.

Tabel 3.4: Pelaksanaan Penelitian

Kegiatan	Kuartal															
	I				II				III				IV			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Studi Literatur	■	■	■													
Pengambilan Data			■	■	■	■										
Pengolahan Data						■	■	■	■							
Analisis Data									■	■	■	■				
Penarikan Kesimpulan												■	■	■		
Penulisan Skripsi									■	■	■	■	■	■	■	■

BAB IV

HASIL PENELITIAN DAN PEMBAHASAN

A. Hasil Penelitian

Bab ini menyajikan hasil penelitian yang diperoleh berdasarkan tahapan metodologi pada Bab III, mulai dari pra-pemrosesan data, analisis statistik deskriptif, analisis distribusi data, eksplorasi fitur, implementasi Isolation Forest, evaluasi hasil deteksi, hingga visualisasi hasil model.

1. Pra-pemrosesan Data


Sesuai dengan tahapan metodologi penelitian pada Gambar 3.1, proses penelitian diawali dengan tahap pra-pemrosesan data untuk memastikan dataset siap digunakan pada proses analisis dan pemodelan. Dataset yang digunakan terdiri dari 150 konten *endorsement* skincare di TikTok periode Juni hingga Oktober 2025. Tahap ini meliputi pemeriksaan data duplikat dan nilai hilang, normalisasi format data, pembentukan fitur turunan, serta pengelompokan data berdasarkan tingkatan. Normalisasi menggunakan StandardScaler selanjutnya diterapkan pada tahap eksplorasi fitur dan pemodelan Isolation Forest untuk menyamakan rentang nilai antar fitur.

Tabel 4.1: Tahapan Pra-pemrosesan Data

Tahapan	Hasil
Pemeriksaan Data Duplikat	Tidak ditemukan data duplikat
Pemeriksaan <i>Missing Value</i>	Tidak ditemukan <i>missing value</i>
Filter Variabel Endorse	Data non-endorsement dihapus
Rekayasa Fitur	ER, LVR, CVR, dan SVR dibentuk
Pengelompokan Tingkatan KOL	Dataset dipisahkan berdasarkan tingkatan

Berdasarkan hasil pra-pemrosesan pada Tabel 4.1, tidak ditemukan data duplikat maupun missing value pada dataset sehingga seluruh data dapat digunakan untuk proses analisis dan pemodelan. Selain itu, proses feature engineering berhasil membentuk empat fitur turunan yaitu Engagement Rate (ER), Like View Ratio (LVR), Comment View Ratio (CVR), dan Share View Ratio (SVR) yang digunakan sebagai representasi pola *engagement* pada penelitian ini. Tahap filtering juga menghasilkan dataset yang hanya terdiri dari konten endorsement sesuai dengan fokus penelitian. Selanjutnya, data dikelompokkan berdasarkan kategori tingkatan *Key Opinion Leader* (KOL) untuk mengurangi perbedaan distribusi *engagement* antar kelompok KOL pada proses pemodelan.

Variabel tingkatan (*tier*) digunakan sebagai dasar pengelompokan data dalam proses pemodelan untuk mengurangi perbedaan distribusi *engagement* antar kategori *Key Opinion Leader* (KOL). Model dijalankan secara terpisah pada masing-masing tingkatan (*tier*) agar proses deteksi anomali dilakukan sesuai dengan karakteristik distribusi setiap tingkatan.




Gambar 4.1: Distribusi Jumlah Data pada Setiap Tingkatan KOL

Berdasarkan Gambar 4.1, jumlah data pada setiap tingkatan KOL menunjukkan distribusi yang seimbang, di mana masing-masing kategori terdiri dari 30 data konten *endorsement* yang berasal dari 10 KOL dengan 3 postingan per KOL. Kondisi ini menunjukkan bahwa dataset telah disusun secara seimbang pada setiap tingkatan sehingga proses deteksi anomali dapat dilakukan secara lebih konsisten tanpa dipengaruhi ketimpangan jumlah data. Pengelompokan berdasarkan tingkatan juga digunakan untuk mengurangi perbedaan distribusi *engagement* antar kategori KOL pada proses pemodelan Isolation Forest.

2. Analisis Statistik Deskriptif

Analisis statistik deskriptif dilakukan untuk memberikan gambaran umum mengenai karakteristik data *engagement* yang digunakan pada penelitian. Analisis ini bertujuan untuk memahami pola distribusi dan variasi data sebelum dilakukan proses deteksi anomali. Statistik deskriptif dilakukan terhadap metrik *engagement* utama, yaitu *views*, *likes*, *comments*, dan *shares*, serta metrik turunan berupa ER, LVR, CVR, dan SVR.




Gambar 4.2: Distribusi Metrik *Engagement*

Berdasarkan Gambar 4.2, seluruh metrik *engagement* menunjukkan sebaran data yang cukup lebar dengan keberadaan sejumlah nilai ekstrem pada bagian atas distribusi. Hal ini terlihat dari banyaknya titik yang berada di luar rentang utama boxplot, terutama pada metrik views dan likes. Variabel views memiliki median sebesar 59,3 ribu dengan nilai maksimum mencapai 23,3 juta, sedangkan likes memiliki median sebesar 1.314 dengan nilai maksimum mencapai 1,8 juta. Perbedaan yang cukup besar antara nilai tengah dan nilai maksimum menunjukkan bahwa sebagian besar postingan memiliki *engagement* yang relatif rendah hingga sedang, sementara hanya sebagian kecil postingan yang memperoleh *engagement* sangat tinggi.

Selain itu, variabel comments dan shares juga menunjukkan pola distribusi yang serupa. Median comments tercatat sebesar 25,5 dengan nilai maksimum mencapai 17.700, sedangkan median shares sebesar 40 dengan nilai maksimum mencapai 60.800. Perbedaan rentang nilai yang cukup besar ini menunjukkan bahwa performa *engagement* antar postingan tidak tersebar secara merata dan dipengaruhi oleh sejumlah kecil konten dengan interaksi yang jauh lebih tinggi dibanding mayoritas data.

Keberadaan nilai ekstrem pada seluruh metrik mengindikasikan adanya variasi performa yang cukup besar antar postingan. Secara umum, distribusi data cenderung bersifat *right-skewed*, yaitu sebagian besar postingan memiliki nilai *engagement* yang rendah hingga sedang, sementara hanya sebagian kecil postingan yang memperoleh *engagement* sangat tinggi. Karakteristik distribusi seperti ini umum ditemukan pada data media sosial dan menunjukkan bahwa pola interaksi pengguna tidak tersebar secara merata pada seluruh konten. Dalam penelitian ini, keberadaan sejumlah kecil postingan dengan karakteristik yang berbeda dari mayoritas data menjadi indikasi awal adanya kandidat anomali yang selanjutnya dianalisis menggunakan Isolation Forest.



Gambar 4.3: Distribusi Metrik Turunan


Berdasarkan Gambar 4.3, terlihat bahwa metrik ER dan LVR memiliki rentang distribusi yang lebih lebar dibanding CVR dan SVR. Nilai median ER dan LVR masing-masing sebesar 0,0258 dan 0,0230, sedangkan median CVR dan SVR hanya sebesar 0,0003 dan 0,0007. Perbedaan ini menunjukkan bahwa variasi *engagement* pada dataset lebih banyak dipengaruhi oleh interaksi likes dibanding komentar maupun share. Selain itu, terdapat beberapa titik yang berada di luar rentang utama boxplot pada seluruh metrik, yang mengindikasikan adanya nilai ekstrem pada sebagian kecil postingan.

Distribusi ER dan LVR juga menunjukkan pola yang relatif serupa karena likes merupakan komponen utama dalam pembentukan *engagement*. Nilai maksimum ER dan LVR masing-masing mencapai 0,3145 dan 0,3129, jauh lebih tinggi dibanding nilai median pada kedua metrik tersebut. Kondisi ini menunjukkan bahwa sebagian besar postingan memiliki tingkat *engagement* yang relatif rendah, namun terdapat beberapa postingan dengan tingkat interaksi yang jauh lebih tinggi dibanding mayoritas data.


Sementara itu, CVR dan SVR cenderung terkonsentrasi pada nilai yang rendah dengan median masing-masing sebesar 0,0003 dan 0,0007. Meskipun demikian, masih terdapat beberapa nilai ekstrem dengan maksimum sebesar 0,0594 pada CVR dan 0,0188 pada SVR. Perbedaan karakteristik distribusi antar metrik tersebut menunjukkan bahwa setiap fitur memiliki kontribusi yang berbeda dalam merepresentasikan pola *engagement*, sehingga diperlukan tahap eksplorasi fitur untuk mengidentifikasi kombinasi fitur yang paling representatif dalam proses pemodelan.

3. Analisis Distribusi dan Kewajaran Data

Tahap analisis distribusi dilakukan untuk memahami pola persebaran data *engagement* sebelum proses pemodelan dilakukan. Analisis ini bertujuan untuk melihat karakteristik data, mengetahui tingkat variasi antar data, serta mengidentifikasi kemungkinan adanya nilai ekstrem yang dapat memengaruhi proses deteksi anomali. Analisis distribusi pada penelitian ini, dilakukan menggunakan visualisasi histogram, boxplot, serta pendekatan *interquartile range* (IQR) terhadap metrik utama *engagement* maupun metrik turunan hasil perhitungan rasio *engagement*.



Gambar 4.4: Distribusi Data Metrik Views dan Likes




Gambar 4.5: Distribusi Data Metrik Comments dan Shares

Berdasarkan histogram distribusi metrik *engagement* pada Gambar 4.4 dan Gambar 4.5, karakteristik distribusi masing-masing variabel dirangkum dalam Tabel 4.2.


Tabel 4.2: Karakteristik Distribusi Metrik *Engagement*

Fitur	Pola Distribusi	Deskripsi
Views	<i>Right-skewed</i>	Mayoritas data berada pada nilai rendah, dengan beberapa nilai sangat tinggi.
Likes	<i>Right-skewed</i>	Mayoritas data berada pada nilai rendah, dengan beberapa nilai sangat tinggi.
Comments	<i>Right-skewed</i>	Sebagian besar data terkonsentrasi pada nilai rendah.
Shares	<i>Right-skewed</i>	Sebagian besar data terkonsentrasi pada nilai rendah.

Berdasarkan Tabel 4.2, seluruh metrik *engagement* utama menunjukkan pola distribusi *right-skewed*, yaitu mayoritas data terkonsentrasi pada nilai rendah dengan sejumlah kecil data bernilai tinggi. Kondisi ini menunjukkan adanya perbedaan performa interaksi antar konten serta mengindikasikan keberadaan nilai ekstrem yang relevan untuk dianalisis lebih lanjut pada proses deteksi anomali.



Gambar 4.6: Distribusi Data Metrik ER dan LVR



Gambar 4.7: Distribusi Data Metrik CVR dan LVR

Berdasarkan histogram metrik turunan pada Gambar 4.6 dan Gambar 4.7, karakteristik distribusi masing-masing variabel turunan dirangkum dalam Tabel 4.3

Tabel 4.3: Karakteristik Distribusi Metrik Turunan *Engagement*


Fitur	Pola Distribusi	Deskripsi
ER	<i>Right-skewed</i>	Mayoritas data berada pada nilai ER rendah hingga sedang, namun terdapat beberapa postingan dengan nilai ER jauh lebih tinggi.
LVR	<i>Right-skewed</i>	Pola distribusi mengikuti ER karena likes menjadi komponen dominan dalam pembentukan <i>engagement</i> .
CVR	<i>Right-skewed</i>	Sebagian besar data memiliki rasio komentar sangat rendah dan terkonsentrasi mendekati nol, dengan sedikit postingan memiliki CVR tinggi.
SVR	<i>Right-skewed</i>	Mayoritas data memiliki rasio share rendah, namun terdapat beberapa nilai yang lebih tinggi sehingga membentuk ekor distribusi ke kanan.

Berdasarkan Tabel 4.3, seluruh metrik turunan *engagement* menunjukkan pola distribusi *right-skewed*. Kondisi ini menunjukkan bahwa sebagian besar postingan memiliki nilai rasio *engagement* yang relatif rendah hingga sedang, sedangkan hanya sebagian kecil postingan yang memiliki nilai rasio jauh lebih tinggi dibanding mayoritas data lainnya. Pola distribusi seperti ini umum ditemukan pada data media sosial dan mengindikasikan bahwa interaksi pengguna tidak tersebar secara merata pada seluruh konten.


Keberadaan sejumlah kecil data dengan nilai yang jauh lebih tinggi tersebut mengindikasikan adanya variasi performa *engagement* antar postingan. Dalam konteks penelitian ini, karakteristik tersebut menjadi indikasi awal adanya kandidat anomali yang perlu dianalisis lebih lanjut menggunakan pendekatan *Interquartile Range* (IQR) dan Isolation Forest. Oleh karena itu, dilakukan perhitungan IQR untuk menentukan batas distribusi normal (*upper bound*) pada masing-masing metrik.

Tabel 4.4: Hasil Perhitungan IQR dan Upper Bound Metrik Turunan

Metrik	Q1	Q3	IQR	Upper Bound
ER	0.013689	0.045480	0.031792	0.093167
LVR	0.010762	0.041147	0.030385	0.086723
SVR	0.000170	0.000621	0.000451	0.001298
CVR	0.000322	0.001536	0.001214	0.003356



Gambar 4.8: Visualisasi IQR ER dan LVR



Gambar 4.9: Visualisasi IQR CVR dan SVR

Berdasarkan boxplot pada Gambar 4.8 dan Gambar 4.9, setiap metrik menunjukkan karakteristik distribusi yang berbeda. ER dan LVR memiliki rentang distribusi yang lebih lebar dibanding CVR dan SVR. Selain itu, keberadaan beberapa titik di luar whisker mengindikasikan adanya nilai yang berada di luar rentang distribusi mayoritas data.

Perhitungan *Interquartile Range* (IQR) pada Tabel 4.4 digunakan untuk menentukan batas atas distribusi normal (*upper bound*) pada masing-masing metrik. Berdasarkan hasil perhitungan, ER dan LVR memiliki nilai IQR yang lebih besar dibanding CVR dan SVR, yang menunjukkan bahwa variasi rasio *engagement* pada kedua metrik tersebut relatif lebih tinggi.

Keberadaan nilai ekstrem pada seluruh metrik mengindikasikan adanya variasi performa yang cukup besar antar postingan. Secara umum, distribusi data cenderung bersifat *right-skewed*, yaitu sebagian besar postingan memiliki nilai *engagement* yang rendah hingga sedang, sementara hanya sebagian kecil postingan yang memperoleh *engagement* sangat tinggi. Karakteristik distribusi seperti ini umum ditemukan pada data media sosial dan menunjukkan bahwa interaksi pengguna pada tiap konten tidak tersebar secara merata. Dalam penelitian ini, keberadaan sejumlah kecil postingan dengan karakteristik yang berbeda dari mayoritas data menjadi indikasi awal adanya kandidat anomali yang selanjutnya dianalisis menggunakan Isolation Forest.

Selanjutnya, batas *upper bound* yang diperoleh digunakan untuk mengidentifikasi jumlah data yang berada di luar rentang distribusi normal pada masing-masing metrik.

Tabel 4.5: Jumlah Indikasi Outlier Awal Berdasarkan IQR

Variabel	Jumlah Indikasi Outlier Awal
ER	13
LVR	15
SVR	23
CVR	16

Berdasarkan hasil identifikasi menggunakan pendekatan IQR, didapat sejumlah data yang berada di atas batas distribusi normal

(*upper bound*) pada masing-masing variabel. Variabel ER memiliki 13 data yang terindikasi sebagai outlier awal, sedangkan variabel LVR memiliki 15 data. Variabel CVR memiliki jumlah indikasi outlier terbanyak, yaitu sebanyak 23 data, sementara variabel SVR memiliki 16 data yang berada di luar rentang distribusi normal.

Jumlah indikasi outlier yang berbeda pada setiap variabel menunjukkan bahwa masing-masing rasio *engagement* memiliki karakteristik distribusi yang tidak sama. Variabel CVR yang memiliki jumlah outlier paling banyak menunjukkan bahwa rasio komentar terhadap views cenderung memiliki variasi cenderung memiliki variasi yang lebih tidak stabil dibanding variabel lainnya. Sementara ER dan LVR menunjukkan adanya sejumlah data dengan rasio interaksi yang jauh lebih tinggi dibanding mayoritas konten dalam dataset.

Keberadaan data yang melewati batas *upper bound* tidak secara langsung dikategorikan sebagai interaksi palsu, namun menunjukkan adanya pola rasio interaksi yang berbeda dari distribusi normal mayoritas data. Oleh karena itu, hasil identifikasi awal ini digunakan sebagai indikasi awal adanya kemungkinan anomali pada data *engagement* yang selanjutnya akan dianalisis lebih lanjut menggunakan metode Isolation Forest.

4. Eksplorasi Hubungan Antar Metrik *Engagement*


a. Analisis Sebaran Kombinasi *Engagement*

Tahap eksplorasi fitur dilakukan untuk menganalisis karakteristik dan hubungan antar fitur *engagement* sebelum proses pemodelan utama. Proses ini bertujuan untuk memahami pola persebaran data pada masing-masing kombinasi metrik serta mengidentifikasi postingan yang terlihat terpisah dari mayoritas data secara visual. Selain itu, eksplorasi fitur juga digunakan untuk memberikan gambaran awal mengenai metrik yang berpotensi


dalam membedakan pola *engagement* pada dataset.

Pada penelitian ini, eksplorasi difokuskan pada metrik turunan *engagement* yaitu ER, LVR, CVR, SVR. Keempat fitur tersebut dipilih karena dinilai lebih representatif dalam menggambarkan kewajaran pola interaksi dibanding metrik mentah seperti views, likes, comments, dan shares yang masih dipengaruhi oleh ukuran akun maupun popularitas konten.


Setiap fitur kemudian dikombinasikan secara berpasangan sehingga menghasilkan 6 kombinasi fitur yang digunakan dalam proses eksplorasi awal model. Kombinasi fitur tersebut digunakan untuk melihat hubungan antar fitur serta kemampuan masing-masing kombinasi dalam memisahkan pola *engagement* normal dan pola *engagement* yang menyimpang.



Gambar 4.10: Scatterplot ER-LVR dan ER-CVR



Gambar 4.11: Scatterplot ER-SVR dan LVR-CVR



Gambar 4.12: Scatterplot LVR-SVR dan CVR-SVR

Berdasarkan visualisasi scatterplot kombinasi metrik turunan *engagement* pada Gambar 4.10, Gambar 4.11, dan Gambar 4.12, terlihat bahwa distribusi data pada setiap kombinasi fitur memiliki karakteristik yang berbeda. Sebagian besar data terkonsentrasi pada rentang nilai rasio yang relatif rendah, namun terdapat beberapa titik yang berada cukup jauh dari kelompok utama. Keberadaan titik-titik tersebut menunjukkan adanya postingan dengan pola interaksi yang berbeda dibanding mayoritas data sehingga terlihat terpisah dari kelompok utama pada visualisasi scatterplot.

Di antara seluruh kombinasi fitur, pasangan ER dan LVR menunjukkan hubungan linear positif yang paling jelas. Sementara itu, kombinasi yang melibatkan CVR dan SVR cenderung

memiliki mayoritas data yang terkonsentrasi di sekitar nilai nol dengan beberapa titik yang tersebar jauh dari kelompok utama. Ringkasan karakteristik sebaran pada masing-masing kombinasi fitur ditunjukkan pada Tabel 4.6

Tabel 4.6: Ringkasan Temuan pada Kombinasi Fitur Turunan *Engagement*

Kombinasi Fitur	Temuan Utama
ER-LVR	Menunjukkan hubungan linear positif paling jelas dibanding kombinasi lainnya.
ER-CVR	Mayoritas data terkonsentrasi pada nilai rendah.
ER-SVR	Mayoritas data berada pada area dengan nilai ER dan SVR yang rendah.
LVR-CVR	Sebagian besar data terkonsentrasi di sekitar nilai rendah dengan beberapa titik yang tersebar jauh dari kelompok utama.
LVR-SVR	Terdapat beberapa titik yang terpisah dari kelompok utama.
CVR-SVR	Sebaran data paling bervariasi dan tidak membentuk pola linear yang kuat.

Berdasarkan karakteristik sebaran pada Tabel 4.6, terlihat bahwa beberapa kombinasi fitur menunjukkan pola hubungan dan karakteristik distribusi yang berbeda. Perbedaan tersebut menunjukkan bahwa masing-masing kombinasi metrik memberikan sudut pandang yang berbeda dalam menggambarkan pola *engagement* pada dataset. Oleh karena itu, dilakukan analisis lanjutan terhadap postingan yang terlihat menyimpang secara visual pada setiap kombinasi metrik untuk memahami konsistensi kemunculan postingan tersebut serta memperoleh indikasi awal mengenai metrik yang berpotensi relevan untuk digunakan dalam proses pemodelan Isolation Forest.

b. Analisis Karakteristik Hubungan Antar Metrik

Berdasarkan hasil scatterplot pada enam kombinasi metrik *engagement*, dilakukan analisis lebih lanjut untuk mengidentifikasi hubungan antar metrik serta pola sebaran data yang terbentuk. Analisis ini dilakukan dengan pengamatan visual terhadap distribusi titik pada setiap kombinasi untuk melihat pola sebaran serta mengidentifikasi postingan yang terlihat terpisah dari mayoritas data. Hasil analisis ini digunakan sebagai eksplorasi awal untuk memahami hubungan antar metrik *engagement* dan menjadi salah satu pertimbangan dalam proses pemilihan fitur yang representatif untuk digunakan dalam pemodelan Isolation Forest.

Tabel 4.7: Perbandingan Hasil Kombinasi berdasarkan Scatterplot

No	Kombinasi	Jumlah Outlier	Postingan Menyimpang Secara Visual
1	ER-LVR	5	post_62, post_288, post_174, post_171, post_173
2	ER-CVR	5	post_288, post_174, post_171, post_173, post_62
3	ER-SVR	8	post_35, post_194, post_62, post_288, post_174, post_171, post_173, post_34
4	LVR-CVR	5	post_288, post_174, post_171, post_173, post_62
5	LVR-SVR	8	post_35, post_194, post_62, post_34, post_288, post_174, post_171, post_173
6	CVR-SVR	4	post_35, post_194, post_34, post_62

Berdasarkan Tabel 4.7, setiap kombinasi metrik menunjukkan karakteristik sebaran yang berbeda serta menghasilkan jumlah postingan yang terlihat menyimpang secara visual yang bervariasi. Kombinasi ER-LVR, ER-CVR, dan LVR-CVR sama-sama menghasilkan lima postingan yang terlihat terpisah dari mayoritas data. Kemunculan postingan yang sama pada ketiga kombinasi ini menunjukkan bahwa beberapa postingan memiliki pola *engagement* yang konsisten terlihat berbeda sehingga muncul di setiap kombinasi.

Sementara itu, kombinasi yang melibatkan SVR menghasilkan lebih banya postingan yang terlihat menyimpang secara visual. Pada kombinasi ER-SVR, dan LVR-SVR, selain muncul lima postingan yang sama seperti sebelumnya, terlihat ada postingan lain seperti post_34, post_34 dan post_194 yang berada terpisah dari mayoritas data. Kondisi ini menunjukkan bahwa metrik SVR mampu memperlihatkan variasi pola sebaran yang tidak selalu terlihat pada kombinasi metrik lainnya.

Secara keseluruhan, terdapat beberapa postingan yang muncul berulang kali sebagai titik yang terlihat jauh dari mayoritas data pada berbagai kombinasi metrik. Post_62 muncul pada seluruh kombinasi yang diamati, sedangkan post_173, post_171, post_174, dan post_288 muncul pada lima kombinasi berbeda. Selain itu, kombinasi ER-LVR, ER-CVR, LVR-CVR menghasilkan kumpulan postingan menyimpang yang sama, menunjukkan bahwa ketiga kombinasi tersebut memiliki kemampuan yang serupa dalam memperlihatkan pemisahan visual antara mayoritas data dan beberapa postingan yang memiliki karakteristik *engagement* berbeda. Hal ini menjadi indikasi awal bahwa metrik ER, LVR dan CVR memiliki peran penting dalam membedakan pola *engagement* pada dataset, sehingga dapat digunakan sebagai salah satu pertimbangan dalam proses pemilihan fitur yang representatif untuk digunakan pada pemodelan Isolation Forest.

5. Implementasi Deteksi Anomali menggunakan Isolation Forest

a. Analisis Pengaruh Kombinasi Fitur terhadap Hasil Deteksi Anomali

Sebelum dilakukan proses deteksi anomali pada pemodelan utama, dilakukan pengujian terhadap beberapa kombinasi fitur untuk melihat pengaruh penggunaan fitur yang berbeda terhadap hasil deteksi menggunakan Isolation Forest. Pengujian dilakukan

secara terpisah pada setiap tingkatan KOL untuk kombinasi seluruh fitur, tiga fitur, kombinasi 3 fitur, serta kombinasi dua fitur yang terdiri dari metrik turunan *engagement*, yaitu ER, LVR, CVR, dan SVR. Hasil deteksi untuk masing-masing kombinasi fitur ditunjukkan pada Tabel 4.9.

Tabel 4.9: Perbandingan Irisan Deteksi Anomali pada Berbagai Kombinasi Fitur

Kombinasi	Jumlah Sama	Postingan Terindikasi Anomali
Seluruh fitur turunan	10	post_83, post_173, post_266, post_296, post_70, post_100, post_194, post_288, post_2, post_62
ER-LVR-CVR	9	post_83, post_173, post_266, post_296, post_98, post_100, post_194, post_288, post_2, post_62
ER-LVR-SVR	7	post_140, post_173, post_239, post_296, post_70, post_100, post_286, post_288, post_2, post_62
ER-CVR-SVR	7	post_140, post_173, post_239, post_266, post_70, post_100, post_194, post_288, post_34, post_62
LVR-CVR-SVR	7	post_140, post_173, post_239, post_266, post_70, post_100, post_194, post_286, post_2, post_62
ER-LVR	5	post_173, post_174, post_240, post_296, post_7, post_100, post_286, post_288, post_1, post_62
ER-CVR	8	post_83, post_173, post_266, post_296, post_98, post_100, post_194, post_288, post_62, post_93
ER-SVR	7	post_140, post_173, post_239, post_296, post_70, post_100, post_194, post_288, post_34, post_62
LVR-CVR	9	post_83, post_173, post_266, post_296, post_98, post_100, post_194, post_288, post_2, post_62
LVR-SVR	7	post_140, post_173, post_239, post_296, post_70, post_100, post_194, post_288, post_34, post_62
CVR-SVR	5	post_140, post_200, post_239, post_266, post_70, post_100, post_194, post_286, post_34, post_62

Berdasarkan Tabel 4.9, penggunaan kombinasi fitur yang berbeda menghasilkan daftar postingan terindikasi anomali yang tidak sepenuhnya sama. Meskipun seluruh kombinasi fitur digunakan pada data yang sama dengan parameter model yang sama, perubahan fitur yang digunakan memengaruhi postingan

mana yang terdeteksi memiliki karakteristik *engagement* yang berbeda dibandingkan mayoritas data.

Kombinasi ER-LVR-CVR dan LVR-CVR menunjukkan tingkat kesamaan tertinggi terhadap hasil deteksi menggunakan seluruh fitur turunan, dengan jumlah irisan masing-masing 9 postingan. Hal ini menunjukkan bahwa kedua kombinasi tersebut mampu mempertahankan sebagian besar informasi yang digunakan pada pemodelan dengan seluruh fitur. Sebaliknya, kombinasi ER-LVR dan CVR-SVR memiliki jumlah irisan paling rendah, yaitu 5 postingan, yang menunjukkan bahwa perubahan fitur yang digunakan dapat menghasilkan perbedaan hasil deteksi yang lebih besar.


Selain itu, terdapat beberapa postingan yang muncul secara konsisten pada hampir seluruh kombinasi fitur, seperti post_62, post_100, dan post_173. Kemunculan yang berulang pada berbagai kombinasi menunjukkan bahwa postingan tersebut memiliki karakteristik *engagement* yang berbeda secara stabil sehingga tetap terdeteksi sebagai anomali meskipun fitur yang digunakan mengalami perubahan. Di sisi lain, beberapa postingan hanya muncul pada kombinasi tertentu, seperti post_174, post_240, post_34, dan post_239. Kondisi ini menunjukkan bahwa setiap fitur memiliki sensitivitas yang berbeda dalam menangkap pola *engagement* yang menyimpang.

Secara umum, hasil ini menunjukkan bahwa pemilihan kombinasi fitur berpengaruh terhadap hasil deteksi anomali yang dihasilkan oleh Isolation Forest. Oleh karena itu, diperlukan analisis lanjutan terhadap hubungan antar metrik dan kontribusi masing-masing fitur untuk menentukan kombinasi fitur yang paling representatif dalam proses deteksi anomali.

b. Analisis Korelasi dan Kontribusi Metrik *Engagement*

Setelah dilakukan pengujian menggunakan berbagai kombinasi fitur pada model Isolation Forest, langkah selanjutnya adalah mengevaluasi hubungan antar metrik *engagement* serta kontribusi masing-masing fitur terhadap proses deteksi anomali. Analisis ini dilakukan untuk memberikan pemahaman yang lebih dalam mengenai keterkaitan antar fitur serta mengidentifikasi fitur yang paling representatif dalam menggambarkan pola *engagement* pada konten *endorsement* TikTok.

Pada penelitian ini, evaluasi dilakukan menggunakan analisis korelasi antar metrik turunan *engagement* dan analisis kontribusi fitur. Analisis korelasi digunakan untuk mengetahui tingkat hubungan antar fitur, sedangkan analisis kontribusi digunakan untuk mengetahui seberapa besar peran masing-masing fitur dalam proses deteksi anomali. Hubungan antar metrik turunan *engagement* dianalisis menggunakan matriks korelasi yang divisualisasikan dalam bentuk heatmap yang ditunjukkan pada Gambar 4.13. Nilai korelasi yang mendekati 1 menunjukkan hubungan linear positif yang kuat, sedangkan nilai yang mendekati 0 menunjukkan hubungan yang lemah.



Gambar 4.13: Heatmap Korelasi Antar Metrik Turunan *Engagement*

Berdasarkan hasil korelasi antar metrik engagement, pasangan fitur ER dan LVR menunjukkan hubungan linear positif yang paling kuat dengan nilai korelasi sebesar 0.99. Hasil ini sejalan dengan temuan pada tahap eksplorasi scatterplot yang menunjukkan bahwa kombinasi ER dan LVR memiliki pola sebaran yang paling jelas dibandingkan kombinasi fitur lainnya. Selain itu, kombinasi ini juga mampu mengidentifikasi sejumlah postingan yang secara konsisten muncul sebagai kandidat anomali pada berbagai pengujian. Oleh karena itu, kombinasi fitur ER dan LVR dipertimbangkan sebagai salah satu kandidat fitur yang representatif untuk digunakan dalam proses pemodelan Isolation Forest. Selanjutnya, dilakukan analisis sensitivitas parameter untuk mengevaluasi pengaruh perubahan parameter model terhadap hasil deteksi anomali.

c. Analisis Sensitivitas Parameter Model

Analisis sensitivitas parameter dilakukan untuk mengevaluasi pengaruh perubahan parameter *contamination* dan *max_samples* terhadap hasil deteksi anomali yang dihasilkan oleh model Isolation Forest. Pengujian ini bertujuan untuk memperoleh konfigurasi parameter yang mampu menghasilkan deteksi anomali yang stabil dan representatif terhadap karakteristik data.

Parameter *contamination* merupakan salah satu parameter penting pada Isolation Forest yang digunakan untuk menentukan proporsi data yang diasumsikan sebagai anomali. Nilai parameter ini memengaruhi batas pemisahan antara data normal dan data anomali sehingga dapat berdampak pada hasil deteksi yang dihasilkan model. Pada penelitian ini pengujian dilakukan menggunakan tiga nilai *contamination*, yaitu 0,03, 0,05, dan 0,10 yang merepresentasikan asumsi proporsi anomali rendah, sedang, dan relatif tinggi. Pengujian dilakukan menggunakan parameter model yang sama dengan pembentukan model sebelumnya, sedangkan nilai *contamination* diubah untuk mengamati perubahan hasil deteksi yang dihasilkan.

Tabel 4.11: Perbandingan Hasil Deteksi Outlier Berdasarkan Nilai *Contamination*

<i>Contamination</i>	Jumlah Outlier	Postingan Terindikasi Outlier
0.03	5	post_62, post_100, post_288, post_173, post_296
0.05	10	post_1, post_62, post_7, post_100, post_288, post_173, post_174, post_240, post_296
0.10	15	post_1, post_2, post_62, post_7, post_100, post_252, post_44, post_286, post_288, post_171, post_173, post_174, post_150, post_240, post_296

Berdasarkan hasil pengujian pada Tabel 4.11, terlihat bahwa perubahan nilai *contamination* memengaruhi jumlah postingan yang

terdeteksi sebagai anomali oleh model. Pada nilai *contamination* sebesar 0,03, model menghasilkan 5 postingan anomali. Ketika nilai *contamination* ditingkatkan menjadi 0,05, jumlah postingan anomali bertambah menjadi 10 postingan. Selanjutnya pada nilai *contamination* sebesar 0,10, jumlah postingan yang terdeteksi sebagai anomali meningkat menjadi 15 postingan.

Hasil tersebut menunjukkan bahwa parameter *contamination* berperan dalam menentukan banyak data yang akan dipisahkan sebagai anomali. Semakin besar nilai *contamination* yang digunakan, semakin banyak data yang dikategorikan sebagai anomali oleh model. Kondisi ini terjadi karena Isolation Forest menyesuaikan ambang deteksi berdasarkan proporsi anomali yang diasumsikan pada awal proses pelatihan model.

Selain memengaruhi jumlah anomali, perubahan nilai *contamination* juga memengaruhi komposisi postingan yang terdeteksi. Beberapa postingan seperti *post_62*, *post_100*, *post_173*, *post_288*, dan *post_296* tetap muncul pada beberapa skenario pengujian. Kemunculan yang konsisten tersebut menunjukkan bahwa postingan-postingan tersebut memiliki karakteristik yang relatif berbeda dibandingkan mayoritas data sehingga tetap terdeteksi sebagai anomali meskipun nilai *contamination* diubah.

Selain melakukan sensitivitas pada *contamination*, dilanjutkan dengan melakukan analisis sensitivitas pada *max_samples*. Parameter ini menentukan jumlah data yang digunakan pada setiap proses pembentukan *isolation tree*. Perubahan nilai *max_samples* dapat memengaruhi struktur pohon yang terbentuk, sehingga berpotensi menghasilkan panjang jalur (*path length*) yang berbeda pada setiap data. Oleh karena itu, dilakukan analisis sensitivitas untuk mengamati pengaruh perubahan nilai *max_samples* terhadap hasil deteksi anomali yang dihasilkan model.

Pada penelitian ini digunakan tiga skenario nilai *max_samples*,

yaitu 15, 24, dan 30. Nilai 15 merepresentasikan penggunaan sekitar 50% data pada setiap tingkatan KOL, nilai 24 merepresentasikan sekitar 80% data, sedangkan nilai 30 menggunakan seluruh data pada masing-masing tingkatan KOL. Pengujian dilakukan dengan mempertahankan parameter lainnya tetap sama, yaitu *contamination* sebesar 0,05, *n_estimators* sebesar 100, dan *random_state* sebesar 42.

Tabel 4.12: Analisis Sensitivitas Parameter *max_samples*

<i>max_samples</i>	Jumlah Outlier	Postingan Terindikasi Outlier
15	10	post_2, post_62, post_100, post_252, post_286, post_288, post_171, post_173, post_240, post_296
24	10	post_2, post_62, post_100, post_252, post_286, post_288, post_171, post_173, post_240, post_296
30	10	post_1, post_62, post_7, post_100, post_286, post_288, post_173, post_174, post_240, post_296

Berdasarkan Tabel 4.12, seluruh skenario pengujian menghasilkan jumlah anomali yang sama, yaitu sebanyak 10 postingan. Hasil tersebut menunjukkan bahwa perubahan jumlah data yang digunakan dalam pembentukan *isolation tree* tidak memberikan pengaruh yang signifikan terhadap hasil deteksi anomali. Konsistensi jumlah anomali yang dihasilkan mengindikasikan bahwa pola anomali yang terdeteksi oleh model relatif stabil meskipun nilai *max_samples* diubah. Dengan kata lain, postingan yang memiliki karakteristik *engagement* berbeda dibanding mayoritas data tetap dapat dikenali oleh model meskipun proses pembentukan pohon dilakukan menggunakan jumlah sampel yang berbeda.

Pada Isolation Forest, nilai *max_samples* memengaruhi proses pembentukan *isolation tree* yang digunakan untuk menghitung panjang jalur (*path length*) setiap data. Semakin sedikit data yang digunakan dalam pembentukan pohon, struktur pohon yang

dihasilkan dapat menjadi lebih sederhana. Sebaliknya, penggunaan jumlah data yang lebih besar menghasilkan pohon yang lebih kompleks. Namun, pada penelitian ini perubahan tersebut tidak menyebabkan perubahan hasil deteksi yang berarti, sehingga model dapat dikatakan cukup stabil terhadap variasi nilai *max_samples*.

Berdasarkan hasil pengujian tersebut, nilai *max_samples* sebesar 30 dipilih pada proses pemodelan akhir. Pemilihan nilai tersebut dilakukan karena seluruh data pada masing-masing tingkatan KOL dapat dimanfaatkan dalam proses pembentukan *isolation tree*, serta menghasilkan hasil deteksi yang konsisten dibandingkan lainnya. Untuk melihat konfigurasi parameter model yang akan digunakan, disajikan Tabel 4.13.

Tabel 4.13: Konfigurasi Parameter Model Akhir

Parameter	Nilai
Fitur Input	ER, LVR
<i>contamination</i>	0.05
<i>max_samples</i>	30
<i>random_state</i>	42
<i>n_estimators</i>	100
Normalisasi	StandarScaler

d. Hasil Deteksi Anomali

Setelah kombinasi fitur dan parameter model ditetapkan berdasarkan hasil pengujian sebelumnya, dilakukan proses deteksi anomali menggunakan metode Isolation Forest pada masing-masing tingkatan KOL. Proses deteksi dilakukan secara terpisah pada setiap tingkatan menggunakan fitur ER dan LVR sebagai input model. Pendekatan ini digunakan karena setiap tingkatan KOL memiliki karakteristik distribusi *engagement* yang berbeda sehingga proses

deteksi perlu dilakukan dalam kelompok yang relatif homogen agar pola anomali dapat diidentifikasi dengan lebih tepat. Hasil deteksi anomali pada tiap tingkatan KOL ditunjukkan pada Tabel 4.14.

Tabel 4.14: Hasil Deteksi Anomali pada Setiap Tingkatan KOL

Tingkatan	Jumlah Data	Jumlah Anomali	Postingan Terindikasi Anomali
Nano	30	2	post_1, post_62
Micro	30	2	post_7, post_100
Midi	30	2	post_286, post_288
Macro	30	2	post_173, post_174
Mega	30	2	post_240, post_296

Berdasarkan Tabel 4.14, model menghasilkan total 10 postingan yang terindikasi anomali dari 150 data endorsement yang dianalisis. Setiap tingkatan KOL menghasilkan dua postingan anomali dari total 30 data pada masing-masing kelompok. Hasil tersebut sesuai dengan parameter *contamination* sebesar 0,05 yang digunakan pada proses pemodelan, sehingga sekitar 5% data pada setiap tingkatan dikategorikan sebagai anomali oleh model.

Keberadaan postingan anomali pada seluruh tingkatan menunjukkan bahwa pola *engagement* yang berbeda dari mayoritas data tidak hanya ditemukan pada KOL dengan jumlah pengikut yang besar, tetapi juga muncul pada KOL dengan jumlah pengikut yang lebih kecil. Temuan ini mengindikasikan bahwa indikasi anomali dalam penelitian tidak bergantung pada ukuran audiens suatu akun, melainkan pada karakteristik hubungan antara metrik *engagement* yang dimiliki oleh setiap postingan.

Selain dapat memisahkan postingan yang terindikasi anomali dengan postingan yang normal, implementasi Isolation Forest juga menghasilkan nilai skor untuk setiap postingan yang dianalisis. Skor tersebut digunakan untuk menunjukkan posisi relatif suatu

postingan terhadap mayoritas data pada tingkatan KOL yang sama berdasarkan pola hubungan fitur ER dan LVR yang dimiliki. Pada penelitian ini, skor diperoleh menggunakan fungsi *decision_function()* dari pustaka Scikit-Learn.

Perlu diperhatikan bahwa nilai skor yang digunakan pada penelitian ini berbeda dengan bentuk *anomaly score* yang diperkenalkan oleh Liu et al. (2008). Baik formulasi asli Isolation Forest maupun implementasi pada pustaka Scikit-Learn sama-sama didasarkan pada konsep *expected path length*, yaitu rata-rata panjang jalur yang diperlukan untuk mengisolasi suatu data pada sekumpulan *isolation tree*. Perbedaannya terletak pada bentuk keluaran skor yang dihasilkan. Pada formulasi asli, Liu et al. menghitung *anomaly score* yang berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan indikasi anomali yang lebih kuat. Sementara itu, implementasi Isolation Forest pada Scikit-Learn mengembalikan nilai skor melalui fungsi *decision_function()*, sehingga skor dapat bernilai positif maupun negatif dengan nilai 0 sebagai batas pemisah antara data yang lebih menyerupai mayoritas data dan data yang lebih mudah terisolasi dari mayoritas data.

Pada implementasi yang digunakan dalam penelitian ini, postingan dengan skor di bawah 0 dikategorikan sebagai postingan yang terindikasi anomali, sedangkan postingan dengan skor di atas 0 dikategorikan sebagai postingan yang terindikasi normal. Semakin rendah nilai skor yang diperoleh, semakin besar indikasi bahwa postingan tersebut memiliki pola *engagement* yang berbeda dibanding mayoritas data pada tingkatan KOL yang sama.

Tabel 4.15: Sampel Hasil Deteksi Menggunakan Isolation Forest

No	Post Code	Tingkatan	Score	Result
1	post_173	Macro	-0.228519	Indikasi Anomali
2	post_288	Midi	-0.127566	Indikasi Anomali
7	post_16	Midi	0.207036	Indikasi Normal
8	post_138	Midi	0.205711	Indikasi Normal

Berdasarkan Tabel 4.15, postingan yang terindikasi anomali memiliki nilai skor negatif, sedangkan postingan yang terindikasi normal memiliki nilai skor positif. Pada implementasi Scikit-Learn, nilai nol digunakan sebagai batas pemisah (*threshold*) antara data normal dan data anomali. Postingan dengan nilai skor di bawah nol dikategorikan sebagai anomali, sedangkan postingan dengan nilai skor di atas nol dikategorikan sebagai data normal.

Nilai skor tersebut tidak diinterpretasikan sebagai tingkat probabilitas maupun persentase anomali. Sebaliknya, skor digunakan untuk menunjukkan posisi relatif suatu data terhadap batas pemisahan yang dibentuk model. Semakin kecil nilai skor yang diperoleh suatu postingan, semakin jauh posisi postingan tersebut dari kelompok data normal dan semakin kuat indikasi bahwa postingan tersebut memiliki karakteristik *engagement* yang berbeda dibanding mayoritas data pada kelompoknya.

Sebaliknya, postingan dengan nilai skor positif yang lebih besar menunjukkan bahwa pola *engagement* yang dimiliki masih berada dalam rentang karakteristik mayoritas data pada tingkatan yang sama. Oleh karena itu, nilai skor dapat digunakan untuk membandingkan tingkat penyimpangan relatif antar postingan, meskipun nilai tersebut tidak secara langsung menunjukkan besarnya peluang suatu postingan merupakan anomali.

Sebagai contoh, post_173 memiliki skor sebesar -0,228519 yang lebih rendah dibandingkan post_288 dengan skor sebesar


-0,127566. Hal ini menunjukkan bahwa post_173 berada lebih jauh dari pola mayoritas data dibandingkan post_288 sehingga memiliki indikasi anomali yang lebih kuat menurut model. Sebaliknya, postingan seperti post_16 dan post_138 memiliki skor positif yang menunjukkan bahwa pola *engagement* yang dimiliki masih konsisten dengan mayoritas data pada tingkatan yang sama.

6. Evaluasi Model

Tahap evaluasi dilakukan untuk menganalisis hasil deteksi anomali yang diperoleh dari model Isolation Forest. Karena penelitian ini menggunakan pendekatan unsupervised learning dan tidak memiliki ground truth label, evaluasi tidak dilakukan menggunakan metrik klasifikasi seperti accuracy, precision, recall, maupun F1-score. Sebagai gantinya, evaluasi dilakukan melalui analisis distribusi hasil deteksi, distribusi skor anomali, serta perbandingan karakteristik *engagement* antara data yang terindikasi normal dan data yang terindikasi anomali.

a. Distribusi Indikasi Anomali

Analisis distribusi hasil deteksi dilakukan untuk melihat proporsi data yang terindikasi normal dan data yang terindikasi anomali berdasarkan hasil pemodelan Isolation Forest.



Gambar 4.14: Distribusi Indikasi Anomali

Berdasarkan hasil distribusi deteksi, mayoritas data berada pada kategori "Indikasi Normal", sedangkan hanya sebagian kecil data yang masuk ke dalam kategori "Indikasi Anomali". Dari total 150 data, sebanyak 140 postingan terindikasi normal dan 10 postingan terindikasi anomali. Perbandingan tersebut menunjukkan bahwa model hanya memisahkan sebagian kecil data yang memiliki pola *engagement* berbeda dibanding mayoritas distribusi data lainnya.


Selain itu, jumlah data anomali yang relatif sedikit juga menunjukkan bahwa sebagian besar postingan masih memiliki pola *engagement* yang berada dalam rentang distribusi normal pada masing-masing tingkatan KOL. Kondisi tersebut sejalan dengan pendekatan Isolation Forest yang berfokus pada pemisahan data dengan karakteristik paling berbeda dibanding mayoritas data pada kelompok yang sama.

Hasil ini juga menunjukkan bahwa model tidak mengelompokkan seluruh postingan dengan *engagement* tinggi sebagai anomali. Sebaliknya, model hanya mendeteksi postingan yang memiliki karakteristik atau pola hubungan antar metrik yang berbeda dari mayoritas data pada tingkatannya. Dengan demikian,

status anomali yang dihasilkan lebih merepresentasikan keberadaan pola *engagement* yang tidak umum dibandingkan sekadar tingginya jumlah interaksi yang diperoleh suatu postingan.

b. Distribusi Skor Anomali

Distribusi skor anomali dianalisis untuk melihat pemisahan antara mayoritas data dan sebagian kecil data yang berada pada ekor distribusi dan terindikasi sebagai anomali.



Gambar 4.15: Distribusi Skor Anomali

Berdasarkan distribusi skor anomali, terlihat bahwa mayoritas data terkonsentrasi pada rentang skor positif, khususnya pada interval sekitar 0,15 hingga 0,20. Kondisi tersebut menunjukkan bahwa sebagian besar postingan memiliki pola *engagement* yang masih berada dalam distribusi normal menurut model Isolation Forest. Sementara itu, sebagian kecil data berada pada rentang skor yang lebih rendah dan membentuk ekor distribusi di sisi kiri histogram, yang menunjukkan adanya postingan dengan karakteristik *engagement* yang berbeda dibanding mayoritas data lainnya.

Garis merah putus-putus pada grafik menunjukkan batas identifikasi anomali berdasarkan parameter contamination sebesar 5%. Data yang berada di sebelah kiri garis tersebut dikategorikan sebagai potential anomaly karena memiliki tingkat penyimpangan yang lebih tinggi dibanding distribusi utama dataset. Terlihat bahwa hanya sebagian kecil data yang berada di bawah batas tersebut, sedangkan mayoritas data tetap terkonsentrasi pada distribusi utama di sisi kanan grafik.

c. Perbandingan Karakteristik Engagement

Tahap ini dilakukan untuk membandingkan karakteristik metrik *engagement* antara data yang terindikasi normal dan data yang terindikasi anomali berdasarkan nilai rata-rata masing-masing fitur.

Tabel 4.16: Perbandingan Rata-rata Karakteristik *Engagement*

Kategori	ER	LVR	CVR	SVR
Indikasi Anomali	1.45×10^{-1}	1.33×10^{-1}	8.80×10^{-3}	3.20×10^{-3}
Indikasi Normal	3.23×10^{-2}	2.98×10^{-2}	8.14×10^{-4}	1.46×10^{-3}

Berdasarkan Tabel 4.16, terlihat bahwa seluruh metrik *engagement* pada kelompok postingan yang terindikasi anomali memiliki nilai rata-rata yang lebih tinggi dibandingkan kelompok postingan yang terindikasi normal. Perbedaan tersebut menunjukkan bahwa postingan yang terindikasi anomali cenderung memiliki pola interaksi yang lebih tinggi dibanding mayoritas data dalam dataset.

Perbedaan paling jelas terlihat pada metrik ER dan LVR. Kelompok postingan yang terindikasi anomali memiliki nilai rata-rata ER sebesar 0.1451, sedangkan kelompok postingan yang terindikasi normal memiliki rata-rata sebesar 0.0323. Pada metrik LVR, kelompok anomali memiliki rata-rata sebesar 0.1330, sementara

kelompok normal sebesar 0.0298. Hasil ini menunjukkan bahwa postingan yang terindikasi anomali cenderung memperoleh jumlah interaksi yang lebih tinggi terhadap jumlah tayangan dibanding mayoritas postingan lainnya.

Pola serupa juga terlihat pada metrik CVR dan SVR. Kelompok postingan yang terindikasi anomali memiliki rata-rata CVR sebesar 8.80×10^{-3} dan SVR sebesar 3.20×10^{-3} , sedangkan kelompok postingan yang terindikasi normal memiliki rata-rata CVR sebesar 8.14×10^{-4} dan SVR sebesar 1.46×10^{-3} . Meskipun selisih kedua metrik tersebut tidak sebesar ER dan LVR, perbedaannya tetap menunjukkan adanya karakteristik interaksi yang berbeda antara kedua kelompok data.

Secara keseluruhan, hasil perbandingan ini menunjukkan bahwa postingan yang terindikasi anomali memiliki karakteristik *engagement* yang berbeda dibanding mayoritas postingan lainnya pada seluruh metrik yang diamati. Hal ini mendukung hasil deteksi Isolation Forest yang mengidentifikasi kelompok postingan dengan pola interaksi yang relatif berbeda dari mayoritas data pada tingkatan KOL yang sama.

B. Pembahasan

1. Analisis Karakteristik Postingan yang Terindikasi Anomali


Tabel 4.17: Karakteristik Postingan yang Terindikasi Anomali

Post Code	Tier	ER	LVR	Kerkun	Hashtag	Ads
post_2	Nano	0.13	0.13	Ada	Pakai	Tidak
post_62	Nano	0.19	0.12	Ada	Pakai	Tidak
post_7	Micro	0.00	0.00	Ada	Pakai	Tidak
post_100	Micro	0.06	0.03	Ada	Pakai	Tidak
post_286	Midi	0.10	0.09	Tidak	Pakai	Tidak
post_288	Midi	0.22	0.22	Tidak	Tidak	Tidak
post_173	Macro	0.31	0.31	Tidak	Tidak	Tidak
post_174	Macro	0.24	0.24	Tidak	Tidak	Tidak
post_240	Mega	0.10	0.10	Tidak	Tidak	Tidak
post_296	Mega	0.12	0.12	Tidak	Tidak	Tidak

Berdasarkan hasil deteksi menggunakan Isolation Forest, diperoleh delapan postingan yang teridentifikasi sebagai anomali pada lima tingkatan KOL. Hasil analisis menunjukkan bahwa karakteristik anomali tidak muncul dalam bentuk yang seragam. Sebagian postingan memiliki tingkat *engagement* yang jauh lebih tinggi dibanding mayoritas data, sedangkan sebagian lainnya menunjukkan pola distribusi interaksi yang berbeda meskipun jumlah *engagement*-nya relatif rendah. Temuan ini mengindikasikan bahwa deteksi anomali tidak hanya dipengaruhi oleh besarnya nilai *engagement*, tetapi juga oleh pola hubungan antar metrik yang dimiliki setiap postingan.

Untuk memahami karakteristik postingan yang terdeteksi sebagai anomali, dilakukan observasi ulang terhadap beberapa konten yang mewakili hasil deteksi pada berbagai tingkatan KOL. Observasi ini difokuskan pada karakteristik konten, seperti penggunaan caption, hashtag, dan fitur promosi yang ditampilkan

pada postingan. Perlu diperhatikan bahwa jumlah views, likes, comments, dan shares yang terlihat saat observasi ulang dapat berbeda dengan data penelitian karena konten media sosial bersifat dinamis. Oleh karena itu, analisis tetap mengacu pada data yang dikumpulkan selama periode penelitian, sedangkan observasi ulang digunakan sebagai informasi pendukung dalam menginterpretasikan hasil deteksi anomali.




Gambar 4.16: Postingan Terindikasi Anomali Tingkat Nano

Catatan: Jumlah interaksi yang ditampilkan pada konten saat observasi ulang dapat berbeda dengan data penelitian karena konten terus mengalami perubahan setelah periode pengumpulan data.

Berbeda dengan pandangan bahwa postingan anomali selalu memiliki jumlah interaksi yang sangat tinggi, postingan pada tingkat Nano menunjukkan karakteristik yang berbeda. Berdasarkan data penelitian, jumlah views, likes, comments, dan shares yang diperoleh masih berada pada rentang yang relatif rendah dibanding postingan dengan performa tinggi pada dataset. Namun demikian, hubungan antar metrik *engagement* pada postingan tersebut tetap berbeda dibanding mayoritas data pada tingkat yang sama sehingga

terdeteksi sebagai anomali oleh Isolation Forest.

Selain itu, postingan pada tingkat Nano menunjukkan bahwa jumlah interaksi yang rendah tidak selalu mencerminkan pola *engagement* yang normal. Meskipun nilai views, likes, comments, dan shares relatif kecil, hubungan antar metrik *engagement* pada postingan ini berbeda dibandingkan mayoritas data pada tingkatan yang sama. Temuan ini menunjukkan bahwa deteksi anomali tidak hanya dipengaruhi oleh besarnya jumlah interaksi, tetapi juga oleh pola *engagement* yang terbentuk pada suatu postingan.




Gambar 4.17: Postingan Terindikasi Anomali Tingkat Macro

Catatan: Jumlah interaksi yang ditampilkan pada konten saat observasi ulang dapat berbeda dengan data penelitian karena konten terus mengalami perubahan setelah periode pengumpulan data.

Karakteristik serupa juga ditemukan pada postingan tingkat Macro. Meskipun jumlah likes yang diperoleh relatif tinggi, peningkatan tersebut tidak diikuti oleh jumlah komentar maupun share yang sebanding. Akibatnya, pola hubungan antar metrik *engagement* menjadi berbeda dibanding mayoritas postingan pada kelompok yang sama. Hal ini menunjukkan bahwa postingan dengan dominasi satu jenis interaksi dapat membentuk pola

engagement yang tidak umum dan lebih mudah dipisahkan oleh Isolation Forest sebagai anomali.

Jika dilihat lebih lanjut, postingan ini memiliki nilai likes yang cukup tinggi dibandingkan jumlah komentar dan share yang diperoleh. Perbedaan tersebut menyebabkan pola interaksi pengguna menjadi kurang seimbang dibandingkan mayoritas postingan lain pada tingkat Macro. Pada kondisi normal, peningkatan jumlah likes umumnya diikuti oleh peningkatan komentar maupun share meskipun dalam proporsi yang berbeda. Namun pada postingan ini, peningkatan interaksi lebih banyak terkonsentrasi pada likes sehingga membentuk karakteristik *engagement* yang berbeda dari pola umum kelompoknya. Karakteristik tersebut menjadi salah satu faktor yang menyebabkan postingan lebih mudah dipisahkan oleh Isolation Forest sebagai data yang tidak mengikuti distribusi mayoritas.



Gambar 4.18: Postingan Terindikasi Anomali Tingkat Mega

Catatan: Jumlah interaksi yang ditampilkan pada konten saat observasi ulang dapat berbeda dengan data penelitian karena konten terus mengalami perubahan setelah periode pengumpulan data.

Berbeda dengan dua kasus sebelumnya, postingan pada tingkat Mega menunjukkan peningkatan yang tinggi pada hampir seluruh metrik *engagement*. Jumlah views, likes, komentar, dan share yang diperoleh berada jauh di atas mayoritas data lainnya pada kelompok yang sama. Berdasarkan hasil observasi terhadap konten, postingan tersebut memang memperoleh respons yang tinggi dari pengguna sehingga memiliki performa yang lebih baik dibanding mayoritas konten lainnya. Hasil ini menunjukkan bahwa postingan dapat terdeteksi sebagai anomali karena performanya berada jauh di luar distribusi umum dataset meskipun tidak menunjukkan karakteristik interaksi yang tidak seimbang.

Berbeda dengan dua kasus sebelumnya, postingan pada tingkat Mega tidak menunjukkan ketidakseimbangan yang mencolok antar metrik *engagement*. Sebaliknya, seluruh metrik mengalami peningkatan yang relatif tinggi secara bersamaan. Kondisi ini menunjukkan bahwa suatu postingan dapat terdeteksi sebagai anomali bukan hanya karena pola interaksi yang tidak seimbang, tetapi juga karena performanya berada jauh di atas mayoritas data pada kelompok yang sama. Dengan kata lain, keberadaan postingan dengan performa yang sangat menonjol juga dapat membentuk karakteristik yang jarang muncul dalam distribusi data sehingga dianggap berbeda oleh model deteksi anomali.

Untuk memperoleh pemahaman yang lebih jelas mengenai faktor yang mungkin memengaruhi hasil deteksi, dilakukan observasi terhadap karakteristik promosi pada setiap postingan anomali. Hasil observasi menunjukkan bahwa postingan pada tingkat Nano dan Micro menggunakan fitur keranjang kuning serta mencantumkan hashtag yang berkaitan dengan brand. Sementara itu, postingan pada tingkat Macro dan Mega tidak menggunakan fitur tersebut, meskipun beberapa di antaranya tetap menyebutkan nama brand pada caption konten.

Selain itu, tidak ditemukan hashtag yang secara eksplisit

menunjukkan penggunaan iklan berbayar seperti #ads,# sponsored, maupun #paidpartnership pada postingan yang diamati. Proses verifikasi melalui TikTok Creative Center juga memiliki keterbatasan karena hanya menyediakan data iklan dalam rentang waktu tertentu, sehingga tidak seluruh postingan dapat diverifikasi secara langsung. Oleh karena itu, hasil observasi ini tidak dapat digunakan untuk menyimpulkan keberadaan iklan berbayar, namun dapat digunakan sebagai informasi tambahan dalam menginterpretasikan karakteristik postingan yang terdeteksi sebagai anomali.

Berdasarkan hasil observasi, postingan yang terdeteksi sebagai anomali tidak menunjukkan pola yang seragam. Sebagian postingan menampilkan unsur promosi yang lebih eksplisit melalui penggunaan fitur TikTok Shop dan hashtag brand, sedangkan sebagian lainnya memperoleh *engagement* tinggi tanpa karakteristik tersebut. Selain itu, pola *engagement* yang menyimpang juga muncul dalam berbagai bentuk, mulai dari dominasi interaksi pada metrik tertentu hingga performa yang jauh lebih tinggi dibanding mayoritas data pada kelompok yang sama. Hal ini menunjukkan bahwa pola *engagement* yang menyimpang dapat dipengaruhi oleh berbagai faktor dan tidak selalu berkaitan dengan penggunaan iklan berbayar.

Berdasarkan hasil eksplorasi fitur dan deteksi anomali yang dilakukan, pola interaksi pengguna pada konten endorsement menunjukkan bahwa sebagian besar *engagement* didominasi oleh interaksi likes dibanding komentar maupun share. Kondisi tersebut terlihat dari nilai ER dan LVR yang memiliki hubungan paling kuat dibanding kombinasi metrik lainnya. Sementara itu, nilai CVR dan SVR cenderung terkonsentrasi pada rentang yang rendah, sehingga variasi interaksi komentar dan share relatif lebih kecil dibanding interaksi likes.

Hasil penelitian menunjukkan bahwa Isolation Forest mampu mengidentifikasi postingan yang memiliki pola *engagement* berbeda dibanding mayoritas data pada tingkatan KOL yang sama.

Kemampuan tersebut terlihat dari keberhasilan model dalam mendeteksi berbagai karakteristik *engagement* yang tidak seragam, mulai dari postingan dengan distribusi interaksi yang tidak seimbang hingga postingan dengan performa yang jauh lebih tinggi dibanding kelompok datanya. Hal ini menunjukkan bahwa pendekatan *unsupervised learning* dapat digunakan untuk mengidentifikasi pola *engagement* yang menyimpang tanpa memerlukan label anomali pada data pelatihan.

Meskipun demikian, hasil deteksi yang diperoleh tidak dapat digunakan untuk menyimpulkan secara langsung adanya praktik *engagement* boosting. Model hanya mengidentifikasi postingan yang memiliki karakteristik *engagement* berbeda dari mayoritas data, sehingga interpretasi terhadap penyebab kemunculan anomali tetap memerlukan analisis lanjutan terhadap konteks dan karakteristik masing-masing konten.

C. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang berkaitan dengan pendekatan metodologi yang digunakan. Pertama, penelitian menggunakan metode *unsupervised anomaly detection* sehingga proses identifikasi anomali dilakukan tanpa *ground truth* label. Kondisi ini menyebabkan hasil deteksi hanya menunjukkan indikasi pola *engagement* yang menyimpang berdasarkan distribusi data dan karakteristik yang dipelajari oleh model *Isolation Forest*, sehingga belum dapat digunakan untuk memastikan adanya praktik *engagement boosting* secara absolut.

Kedua, penelitian menggunakan pendekatan berbasis distribusi data melalui fitur *Engagement Rate* (ER), *Like View Ratio* (LVR), *Comment View Ratio* (CVR), dan *Share View Ratio* (SVR). Pendekatan ini berfokus pada pola interaksi pada tingkat konten dan belum mempertimbangkan aspek perilaku pengguna yang lebih kompleks seperti pola waktu, jaringan interaksi akun, maupun aktivitas

pengguna secara historis.

Ketiga, hasil deteksi anomali pada Isolation Forest dipengaruhi oleh distribusi data dan parameter model yang digunakan, khususnya nilai contamination. Perubahan parameter maupun karakteristik distribusi dataset dapat memengaruhi jumlah dan karakteristik data yang terdeteksi sebagai anomali.

Keempat, penelitian menggunakan pendekatan *anomaly detection* berbasis statistik distribusi sehingga model lebih efektif dalam mendeteksi pola *engagement* yang berbeda secara signifikan dari mayoritas data. Namun, model memiliki keterbatasan dalam mengidentifikasi pola manipulasi *engagement* yang memiliki karakteristik sangat mirip dengan distribusi normal dataset.

BAB V

SIMPULAN DAN SARAN

A. Simpulan

Berdasarkan hasil penelitian yang telah dilakukan, diperoleh beberapa kesimpulan sebagai berikut :

1. Karakteristik *engagement* yang berpotensi mengindikasikan praktik *engagement boosting* dapat dianalisis menggunakan data interaksi implisit berupa *views*, *likes*, *comments*, dan *shares*. Pada penelitian ini, indikator yang digunakan meliputi *Engagement Rate* (ER), *Like View Ratio* (LVR), *Comment View Ratio* (CVR), dan *Share View Ratio* (SVR). Berdasarkan hasil analisis statistik deskriptif dan distribusi data, fitur ER dan LVR menunjukkan variasi distribusi yang lebih dominan dibanding fitur lainnya sehingga dinilai lebih representatif dalam membedakan pola *engagement* antar konten.
2. Analisis menggunakan metrik ER, LVR, CVR, dan SVR menunjukkan bahwa sebagian besar konten *endorsement* memiliki pola *engagement* yang terkonsentrasi pada rentang nilai tertentu dan membentuk distribusi *right-skewed*. Sementara itu, sebagian kecil konten memiliki rasio interaksi yang jauh berbeda dibanding mayoritas data, baik dalam bentuk tingkat *engagement* yang lebih tinggi maupun pola hubungan antar metrik yang tidak umum. Temuan ini menunjukkan adanya perbedaan karakteristik antara pola *engagement* normal dan pola *engagement* yang menyimpang pada konten *endorsement* TikTok.
3. Berdasarkan hasil eksplorasi kombinasi fitur, pasangan fitur ER dan LVR dipilih sebagai fitur utama dalam proses pemodelan karena menunjukkan pola pemisahan distribusi yang paling jelas dibanding kombinasi fitur lainnya. Selain itu, pengujian terhadap beberapa nilai *contamination* menunjukkan

bahwa perubahan parameter memengaruhi jumlah data yang terdeteksi sebagai anomali, namun model tetap menunjukkan pola deteksi yang relatif konsisten terhadap distribusi data.

4. Model Isolation Forest berhasil digunakan untuk mengidentifikasi pola *engagement* yang menyimpang pada konten *endorsement* TikTok menggunakan pendekatan *unsupervised anomaly detection*. Model dijalankan secara terpisah pada setiap tier KOL untuk mengurangi perbedaan distribusi *engagement* antar kategori influencer. Dengan menggunakan parameter *contamination* sebesar 0.05, model berhasil mendeteksi sejumlah data yang terindikasi sebagai *potential anomaly* berdasarkan karakteristik distribusi *engagement* yang berbeda dibanding mayoritas data lainnya.
5. Hasil evaluasi menunjukkan bahwa distribusi anomaly score mampu memisahkan mayoritas data normal dan sebagian kecil data yang terindikasi anomali. Selain itu, kelompok *potential anomaly* menunjukkan karakteristik nilai ER dan LVR yang relatif lebih tinggi dibanding kelompok normal, sehingga mengindikasikan adanya pola interaksi yang berbeda dibanding distribusi utama data *engagement*.

B. Implikasi

Pendekatan *unsupervised anomaly detection* menggunakan Isolation Forest berpotensi dimanfaatkan sebagai alternatif dalam pemantauan pola *engagement* pada konten *endorsement* media sosial. Tanpa memerlukan *ground truth label*, metode ini dapat digunakan untuk mengidentifikasi konten yang memiliki karakteristik *engagement* berbeda dari mayoritas data, sehingga mendukung proses evaluasi performa konten dan identifikasi indikasi *engagement* yang tidak wajar.

Selain itu, temuan mengenai peran ER dan LVR dalam membedakan pola *engagement* normal dan menyimpang dapat menjadi referensi awal dalam pengembangan sistem monitoring

kualitas *engagement* pada aktivitas *influencer marketing*. Secara praktis, hasil penelitian ini juga menunjukkan bahwa analisis distribusi *engagement* dapat dimanfaatkan sebagai bahan evaluasi performa konten *endorsement* secara lebih berbasis data.

C. Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya :

1. Penelitian selanjutnya dapat menggunakan data dengan cakupan yang lebih luas, baik dari sisi jumlah konten, variasi kategori konten, maupun platform media sosial lainnya untuk memperoleh karakteristik distribusi *engagement* yang lebih beragam.
2. Penelitian selanjutnya dapat menambahkan fitur lain yang lebih kompleks seperti pola temporal interaksi, aktivitas akun pengguna, maupun analisis jaringan interaksi untuk meningkatkan kemampuan model dalam mengidentifikasi indikasi *engagement boosting*.
3. Penelitian selanjutnya dapat membandingkan performa Isolation Forest dengan metode *unsupervised anomaly detection* lainnya seperti Local Outlier Factor (LOF), One-Class SVM, maupun Autoencoder untuk memperoleh pendekatan deteksi yang lebih optimal.
4. Penelitian selanjutnya juga dapat mengembangkan proses evaluasi menggunakan data yang memiliki label validasi sehingga hasil deteksi anomali dapat diukur menggunakan metrik evaluasi klasifikasi secara lebih objektif.

DAFTAR PUSTAKA

- Alika, F., Listiana, E., Afifah, N., Juniwati, J., & Mayasari, E., 2024. Tiktok social media marketing and beauty influencers' impact on skintific purchase decisions through brand awareness. *Journal of Management Science (JMAS)*, 7(1), 165–174.
URL <https://doi.org/10.35335/jmas.v7i1.397>
- Chabchoub, Y., Togbe, M. U., Boly, A., & Chiky, R., 2022. An in-depth study and improvement of isolation forest. *IEEE Access*, 10, 10219–10237.
URL <https://10.1109/ACCESS.2022.3144425>
- Cheng, Z., & Li, Y., 2024. Like, comment, and share on tiktok: Exploring the effect of sentiment and second-person view on the user engagement with tiktok news videos. *Social Science Computer Review*, 42(1), 201–223.
URL <https://10.1177/08944393231178603>
- Chua, W., Pajas, A. L. D., Castro, C. S., Panganiban, S. P., Pasuquin, A. J., Purganan, M. J., Malupeng, R., Pingad, D. J., Orolfo, J. P., Lua, H. H., & Velasco, L. C., 2024. Web traffic anomaly detection using isolation forest. *Informatics*, 11(4).
URL <https://www.mdpi.com/2227-9709/11/4/83>
- David Nevado-Catalán, S. P., dkk., 2023. An analysis of fake social media engagement services. *Computers & Security*, 124(103013).
URL <https://doi.org/10.1016/j.cose.2022.103013>
- Dewi, T. P., & Ekayanthi, D., 2023. Pengaruh penggunaan media sosial tiktok terhadap brand image followers wardah beauty. In *Seminar Nasional Pariwisata dan Kewirausahaan (SNPK)*, vol. 2, (pp. 369–374).
URL <https://10.36441/snpk.vol2.2023.142>
- Fang, Y., Zhang, L., Wang, S., & Li, W., 2022. Anomalous behavior detection based on the isolation forest model with multiple

- perspective business processes. *Electronics*, 11(21), 3640.
URL <https://doi.org/10.3390/electronics11213640>
- Ferrara, E., Varol, O., Davis, C., Menczer, F., & Flammini, A., 2016. The rise of social bots. *Communications of the ACM*, 59(7), 96–104.
URL <https://doi.org/10.1145/2818717>
- Handayani, P., Putri, S. N. R., & Wisudawanto, R., 2024. Peran buzzer media sosial instagram dalam membentuk brand produk susu allesgut. *Jurnal Sosial Humaniora dan Pendidikan (INOVASI)*, 3(1).
URL <https://10.55606/inovasi.v3i1.2908>
- HypeAuditor, 2025. How hypeauditor helps marketers spot and prevent every type of influencer fraud. Accessed: 2025-11-11.
- Khan, W., Ebrahim, N., Alsaadi, M., & Elloumi, M., 2025. Unified representation and scoring framework for anomaly detection in attributed networks with emphasis on structural consistency and attribute integrity. *Scientific Reports*, 15(1), 35753.
URL <https://doi.org/10.1038/s41598-025-19650-y>
- Kumar, S., & Shah, N., 2018. False information on web and social media: A survey. *arXiv preprint arXiv:1804.08559*.
URL <https://doi.org/10.48550/arXiv.1804.08559>
- Levesque, N., & Pons, F., 2023. Influencer engagement on social media: A conceptual model, the development and validation of a measurement scale. *Journal of Theoretical and Applied Electronic Commerce Research*, 18, 1741–1763.
URL <https://10.3390/jtaer18040088>
- Li, Y., Martinez, O., Chen, X., Li, Y., & Hopcroft, J. E., 2016. In a world that counts: Clustering and detecting fake social engagement at scale. In *Proceedings of the 25th International Conference on World Wide Web*, (pp. 111–120).
URL <https://10.1145/2872427.2882972>

- Liang, S., & Wolfe, J., 2022. Getting a feel of instagram reels: The effects of posting format on online engagement. *Journal of Student Research*, 11(4). High School Research Paper.
- Liang, Y., Zheng, X., Zeng, D. D., Zhou, X., Leischow, S. J., & Chung, W., 2015. Characterizing social interaction in tobacco-oriented social networks: An empirical analysis. *Scientific Reports*, 5, 10060. URL <https://doi.org/10.1038/srep10060>
- Liu, F. T., Ting, K. M., & Zhou, Z.-H., 2008. Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, (pp. 413–422). URL <https://doi.org/10.1109/ICDM.2008.17>
- Rachmadina, N., Alhani, H., Putri, T. U., Putra, A. P. T., & Handoko, D., 2025. Etika periklanan di era influencer: Tantangan kejujuran dalam endorsement digital. *Konstitusi: Jurnal Hukum, Administrasi Publik, dan Ilmu Komunikasi*, 2(2), 265–276. URL <https://doi.org/10.62383/konstitusi.v2i2.942>
- Rafiq, A., 2020. Dampak media sosial terhadap perubahan sosial suatu masyarakat. *Global Komunika: Jurnal Ilmu Sosial Dan Ilmu Politik*, 3(1), 18–29. URL <https://doi.org/10.33822/gk.v3i1.1704>
- Ratnasari, E., Rohnulyanti, H., Hafiar, H., & Wada, I., 2024. Exploring momfluencers ethics as social media micro-influencer in indonesia. *Jurnal Kajian Komunikasi*, 12(2), 234–253. URL <https://doi.org/10.24198/jkk.v12i2.57754>
- RivalIQ, 2024. Tiktok benchmark report 2024. <https://www.rivaliq.com/blog/tiktok-benchmark-report/>. Accessed: 2025-11-11.
- Saeidi, S., & Baradari, Z., 2023. Examining the correlation between metrics in the instagram social network to identify fake pages and improve marketing. *Computers in Human Behavior Reports*, 12, 100341. URL <https://doi.org/10.1016/j.chbr.2023.100341>

- Shajari, M., & Agarwal, N., 2025. Developing a network-centric approach for anomalous behavior detection on youtube. *Social Network Analysis and Mining*, 15(1), 17.
URL <https://doi.org/10.1007/s13278-025-01417-y>
- Social, W. A., 2025. Indonesia digital report 2025: Social media use. Accessed: 2025-11-18.
- Trunfio, M., & Rossi, S., 2021. Conceptualising and measuring social media engagement: A systematic literature review. *SN Business & Economics*, 1(3), 1–26.
URL <https://doi.org/10.1007/s43039-021-00035-8>
- Varol, O., & Others, 2017. Online human-bot interactions: Detection, estimation, and characterization. In *Proceedings of the international AAAI conference on web and social media*, (pp. 280–289).
URL <https://doi.org/10.1609/icwsm.v11i1.14871>
- Wang, W., & Wang, G., 2025. A study of improved isolation forest algorithm for data management of transmission line defects and hazards. *Energy Informatics*, 8(1), 130.
URL <https://doi.org/10.1186/s42162-025-00585-7>
- Zouzou, Y., & Varol, O., 2024. Unsupervised detection of coordinated fake-follower campaigns on social media. *EPJ Data Science*, 13(1), 62.
URL <https://doi.org/10.1140/epjds/s13688-024-00499-6>