

**ANALISIS PERBANDINGAN MODEL
RANDOM FOREST DAN XGBOOST
UNTUK KLASIFIKASI TINGKAT
KECANDUAN MEDIA SOSIAL**

SKRIPSI



Oleh
DIAN AYU FAUZIAH
NIM 22031554011

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA SAINS DATA
2026

ANALISIS PERBANDINGAN MODEL RANDOM FOREST DAN XGBOOST UNTUK KLASIFIKASI TINGKAT KECANDUAN MEDIA SOSIAL

SKRIPSI

Diajukan kepada Universitas Negeri Surabaya untuk Memenuhi
Persyaratan Penyelesaian Program Sarjana Matematika

Oleh
DIAN AYU FAUZIAH
NIM 22031554011

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SARJANA SAINS DATA

2026

ABSTRAK

Dian Ayu Fauziah

ANALISIS PERBANDINGAN MODEL RANDOM FOREST DAN XGBOOST UNTUK KLASIFIKASI TINGKAT KECANDUAN MEDIA SOSIAL

Skripsi

Universitas Negeri Surabaya, Fakultas Matematika dan Ilmu
Pengetahuan Alam, 2026

Tingginya intensitas penggunaan media sosial yang tidak terkontrol, khususnya pada remaja dan dewasa muda, dapat menyebabkan kecanduan media sosial yang berdampak pada fungsi kognitif dan prestasi akademik. Penelitian ini bertujuan untuk menganalisis kinerja serta membandingkan performa algoritma Random Forest dan XGBoost dalam klasifikasi tingkat kecanduan media sosial. Dataset yang digunakan adalah Students Social Media Addiction dengan jumlah 705 responden. Tahap pra-pemrosesan mencakup penghapusan atribut yang tidak relevan, pembentukan variabel target menggunakan metode tertile ke dalam kelas Low, Medium, dan High, serta encoding pada variabel kategorikal. Pengujian dilakukan melalui skenario pembagian data 70:30, 80:20, dan 90:10 dengan validasi 10-fold cross validation. Hasil penelitian menunjukkan bahwa kedua algoritma menghasilkan performa tinggi pada seluruh skenario. Pada skenario 80:20, Random Forest memperoleh validation accuracy sebesar 97,52%, test accuracy sebesar 98,58%, F1-score macro sebesar 98,61%, dan generalization gap sebesar 0,0248. Sementara itu, XGBoost memperoleh validation accuracy sebesar 97,31%, test accuracy sebesar 98,58%, F1-score macro sebesar 98,59%, dan generalization gap sebesar 0,0269. Random

Forest memberikan nilai validation accuracy, F1-score, dan generalization gap yang lebih baik, sedangkan XGBoost memiliki standar deviasi lebih rendah yang menunjukkan bahwa model tersebut memiliki performa yang lebih konsisten pada setiap *fold* dalam proses *cross-validation*. Dengan demikian, kedua model dapat dinyatakan efektif dalam mengklasifikasikan tingkat kecanduan media sosial, dengan skenario pembagian data 80:20 sebagai skenario paling optimal.

Kata kunci: Kecanduan Media Sosial, *Random Forest*, *XGBoost*, Klasifikasi, *Machine Learning*

ABSTRACT

Dian Ayu Fauziah

A COMPARATIVE ANALYSIS OF RANDOM FOREST AND XGBOOST MODELS FOR CLASSIFYING SOCIAL MEDIA ADDICTION LEVELS

Undergraduate Thesis

State University of Surabaya, Faculty of Mathematics and Natural
Sciences, 2026

The increasing intensity of uncontrolled social media use, particularly among adolescents and young adults, may lead to social media addiction, which can negatively affect cognitive functioning and academic performance. This study aims to analyze and compare the performance of the Random Forest and XGBoost algorithms in classifying levels of social media addiction. The dataset used in this study was the Students Social Media Addiction dataset, consisting of 705 respondents. The preprocessing stage included the removal of irrelevant attributes, the construction of the target variable using the tertile method to form three classes (Low, Medium, and High), and the encoding of categorical variables. Model evaluation was conducted using three data-splitting scenarios (70:30, 80:20, and 90:10) combined with 10-fold cross-validation. The results indicate that both algorithms achieved high performance across all scenarios. Under the 80:20 data-splitting scenario, Random Forest obtained a validation accuracy of 97.52%, a test accuracy of 98.58%, a macro F1-score of 98.61%, and a generalization gap of 0.0248. Meanwhile, XGBoost achieved a validation accuracy of 97.31%, a test accuracy of 98.58%, a macro F1-score of 98.59%, and a generalization gap of 0.0269. Random Forest demonstrated slightly

better validation accuracy, F1-score, and generalization ability, whereas XGBoost exhibited a lower standard deviation, indicating more consistent performance across the cross-validation folds. Overall, both models were found to be effective in classifying social media addiction levels, with the 80:20 data-splitting scenario identified as the most optimal setting.

Keywords: Social Media Addiction, *Random Forest*, *XGBoost*, Classification, Machine Learning

SURAT PERNYATAAN

Saya yang bertandatangan di bawah ini:

Nama Mahasiswa : Dian Ayu Fauziah

NIM : 22031554011

Program Studi : Sarjana Sains Data

Judul Penelitian : Analisis Perbandingan Model Random Forest dan XGBoost untuk Klasifikasi Tingkat Kecanduan Media Sosial

menyatakan dengan sesungguhnya bahwa:

1. Produk dari penelitian/skripsi yang telah saya kembangkan adalah benar merupakan hasil karya saya bersama pembimbing dan belum diajukan hak cipta/paten oleh saya pribadi atau orang lain ke instansi/lembaga manapun.
2. Menyerahkan sepenuhnya produk penelitian saya ke Program Studi Sarjana Sains Data sebagai produk milik program studi.
3. Tidak menuntut/meminta ganti rugi dalam bentuk apapun atau segala sesuatu yang dilakukan oleh Program Studi Sarjana Sains Data terhadap produk penelitian/skripsi saya ini.
4. Apabila ternyata dikemudian hari produk penelitian/skripsi ini merupakan hasil plagiat atau penjiplakan terhadap karya orang lain, maka saya bersedia menerima sanksi berdasarkan aturan yang berlaku di Negara Kesatuan Republik Indonesia.

Demikianlah surat pernyataan ini saya buat dengan sesungguhnya, untuk dapat dipergunakan sebagaimana mestinya.

Surabaya, 6 Juni 2025

Yang membuat pernyataan,

Dian Ayu Fauziah

NIM. 22031554011

HALAMAN PERSETUJUAN TUGAS AKHIR BENTUK: SKRIPSI

Nama Mahasiswa : Dian Ayu Fauziah
NIM : 22031554011
Judul Penelitian : Analisis Perbandingan Model Random Forest dan XGBoost untuk Klasifikasi Tingkat Kecanduan Media Sosial

ini telah disetujui dan dinyatakan memenuhi syarat untuk diajukan dalam ujian skripsi.

Surabaya, 28 November 2025

Pembimbing I,

Pembimbing II,

Dr. Atik Wintarti, M.Kom.
NIP 1966101219910322002

Yuni Rosita Dewi, S.Si., M.Si
NIP 199506282024062001

HALAMAN PENGESAHAN TUGAS AKHIR BENTUK: SKRIPSI

Nama Mahasiswa : Dian Ayu Fauziah
NIM : 22031554011
Judul Penelitian : Analisis Perbandingan Model Random Forest dan XGBoost untuk Klasifikasi Tingkat Kecanduan Media Sosial

ini telah dipertahankan dihadapan dewan penguji tanggal 6 Juni 2025

Dewan Penguji,	Tanda Tangan	Tanggal Selesai Revisi
----------------	--------------	------------------------

Hasanuddin Al-Habib, M.Si.

NIP. -		
--------	------	-------

Ibnu Febry Kurniawan, S.Kom., M.Sc., Ph.D.

NIP. -		
--------	------	-------

Dr. Atik Wintarti, M.Kom.

NIP. 1966101219910322002		
--------------------------	------	-------

Mengesahkan,
Dekan FMIPA
Universitas Negeri Surabaya

Mengetahui,
Koordinator Program Studi
Sarjana Sains Data

Prof. Dr. Wasis, M.Si.

NIP. 196712031993021001

Yuliani Puji Astuti, M.Si.

NIP. 197807312006042001

PRAKATA

Proses penciptaan karya ini merupakan kolaborasi tak kasat mata. Ada sumber-sumber yang menjadi pijakan, namun ide yang dihasilkan merupakan akumulasi dari berbagai perspektif yang bersinggungan. Ada berbagai sumber inspirasi yang tak terhitung dan karya ini adalah output dari sintesis tersebut. Oleh karena itu, terima kasih pada semua yang sudah membersamai penulis dalam penciptaan karya ini. karya ini disajikan dengan semangat apa adanya. Ia tak berpretensi menjadi sumber kebenaran tunggal, namun lebih sebagai jembatan untuk memicu pemikiran kritis. Terkadang, penemuan terbesar muncul dari interpretasi yang tak terduga.

DAFTAR ISI

SAMPUL	i
ABSTRAK	iii
ABSTRACT	v
SURAT PERNYATAAN KEORISINILAN SKRIPSI	viii
HALAMAN PERSETUJUAN	ix
HALAMAN PENGESAHAN	xi
PRAKATA	xiii
DAFTAR ISI	xiii
DAFTAR TABEL	xvi
DAFTAR GAMBAR	xvii
DAFTAR SIMBOL	xxi
Bab I PENDAHULUAN	1
A. Latar Belakang	1
B. Identifikasi Masalah	4
C. Rumusan Masalah	4
D. Tujuan Penelitian	5
E. Manfaat Penelitian	5
F. Batasan Masalah	6
Bab II KAJIAN PUSTAKA	7
A. Penelitian Terdahulu	7
B. Kajian Teori	8
1. Machine Learning	8
2. Klasifikasi	10
3. <i>Random Forest Classifier</i>	11
4. <i>Extreme Gradient Boosting (XGBoost)</i>	13
5. Kecanduan Media Sosial	14
6. Data Binning	15
Bab III METODE PENELITIAN	17

A.	Dataset	17
1.	Populasi dan Sampel	18
2.	Metode dan Analisis Data	18
B.	Alur Penelitian	19
1.	Studi Literatur	20
2.	Pengambilan Data	20
3.	Pengolahan Data	20
4.	Proses Pemodelan	22
5.	Evaluasi Model	24
6.	Menarik Kesimpulan	26
Bab IV	HASIL PENELITIAN DAN PEMBAHASAN	27
A.	Hasil Penelitian	27
1.	Deskripsi Data	27
2.	Pra-pemrosesan Data	30
3.	Skenario Pengujian	35
4.	Performa Model <i>Random Forest</i>	36
5.	Performa Model <i>XGBoost</i>	37
B.	Pembahasan	39
1.	Analisis Karakteristik Perilaku	39
2.	Analisis Stabilitas dan Penentuan Skenario Terbaik	40
3.	Analisis Kesalahan Klasifikasi	43
4.	Komparasi Model Optimal dengan Skenario Terbaik .	44
5.	Komparasi dengan Penelitian Terdahulu	46
C.	Keterbatasan Penelitian	47
Bab V	Kesimpulan dan Saran	49
A.	Kesimpulan	49
B.	Saran	50
DAFTAR PUSTAKA		51
LAMPIRAN		61
A		61
B	<i>Source code</i>	63
C	Biodata Penulis	65

DAFTAR TABEL

Tabel 2.1	Penelitian Terdahulu	7
Tabel 3.1	Atribut Dataset	17
Tabel 3.2	Kriteria Kategorisasi Tingkat Kecanduan Media Sosial	22
Tabel 4.1	Statistik Deskriptif Atribut Penggunaan Media Sosial	29
Tabel 4.2	Distribusi Frekuensi <i>Addicted_Score</i>	32
Tabel 4.3	Kriteria Kategorisasi Skor Kecanduan	33
Tabel 4.4	Perbandingan Data Sebelum <i>vs</i> Sesudah <i>Encoding</i>	34
Tabel 4.5	Hasil Standardisasi Variabel Numerik	35
Tabel 4.6	Tabel Pembagian Data Latih dan Data Uji	36
Tabel 4.7	Performa <i>Random Forest</i> Pada Tiap Skenario	36
Tabel 4.8	Metrik Evaluasi Per Kelas Model <i>Random Forest</i> ..	37
Tabel 4.9	Performa <i>XGBoost</i> pada Tiap Skenario	38
Tabel 4.10	Metrik Evaluasi Per Kelas Model <i>XGBoost</i>	38
Tabel 4.11	Perbandingan Model Optimal dengan Skenario Terbaik (80:20)	45
Tabel 4.12	Perbandingan Performa	47
Tabel 1.1	Sebagian Data <i>Students Social Media Addiction</i> ...	62

DAFTAR GAMBAR

Gambar 2.1	<i>Training dan Testing</i> Pada Model <i>Machine Learning</i> (Pandey, dkk., 2019).....	9
Gambar 2.2	Struktur Algoritma <i>Random Forest</i> (Khan, dkk., 2021)	12
Gambar 2.3	Struktur Algoritma <i>XGBoost</i> (Ahmed, dkk., 2023)	13
Gambar 3.1	Gambaran Umum Alur Penelitian	19
Gambar 3.2	Diagram Alur Pra-pemrosesan Data	21
Gambar 3.3	Diagram Alur Proses Pemodelan	23
Gambar 3.4	Confusion Matrix Multi-class Classification (Tharwat, 2020)	25
Gambar 4.1	Sebaran Jenis Kelamin Responden	27
Gambar 4.2	Distribusi Usia Responden	27
Gambar 4.3	Distribusi Tingkat Akademik Responden	28
Gambar 4.4	Platform Media Sosial yang Paling Banyak Digunakan.....	28
Gambar 4.5	Distribusi Status Hubungan Responden.....	28
Gambar 4.6	Top 10 Negara Responden	29
Gambar 4.7	Heatmap Korelasi Antar Variabel Numerik.....	30
Gambar 4.8	Perbandingan <i>Confusion Matrix</i> pada Skenario Terbaik	44

DAFTAR SIMBOL

Algoritma *Random Forest*

PE^*	Batas atas kesalahan generalisasi (<i>generalization error</i>) pada <i>Random Forest</i> .
s	Kekuatan (<i>strength</i>) kumpulan pohon berdasarkan nilai ekspektasi fungsi margin.
$\bar{\rho}$	Rata-rata korelasi antar pohon keputusan dalam <i>forest</i> .

Algoritma *XGBoost*

$\mathcal{L}^{(t)}$	Fungsi objektif pada iterasi ke- t .
t	Indeks iterasi yang menunjukkan urutan pembangunan pohon.
$l(y_i, \hat{y}_i)$	Fungsi kerugian (<i>loss function</i>) antara nilai aktual dan prediksi.
$\Omega(f_t)$	Fungsi regularisasi untuk mengontrol kompleksitas pohon.
T	Jumlah daun (<i>leaf</i>) dalam satu pohon keputusan.
ω_j	Bobot pada daun (<i>leaf weight</i>) ke- j .
γ	Parameter penalti untuk jumlah daun dalam regularisasi.
λ	Parameter penalti L2 untuk bobot daun dalam regularisasi.

Evaluasi *Multiclass*

TP_i	<i>True Positive</i> atau jumlah prediksi benar pada kelas ke- i (<i>Low, Medium, High</i>).
E_{ij}	Jumlah kesalahan prediksi (<i>error</i>) di mana data kelas j diprediksi sebagai kelas i .

Kategorisasi dan Validasi Data

Q_i	Nilai kuartil ke- i ($i = 1, 2, 3$) dalam distribusi data.
L_{Q_i}	Letak posisi data pada kuartil ke- i .
n_h	Jumlah sampel pada strata tertentu dalam pembagian data (<i>stratified split</i>).
N_h	Jumlah total anggota pada strata tertentu dalam populasi dataset.
N	Total seluruh data dalam dataset penelitian ($N = 705$).
n	Ukuran sampel yang diinginkan untuk set data tertentu (<i>train</i> atau <i>test</i>).

BAB I

PENDAHULUAN

A. Latar Belakang

Kualitas pendidikan tidak hanya bergantung pada dukungan sistemik, tetapi juga pada kemampuan masyarakat beradaptasi terhadap perkembangan teknologi. Seiring dengan meningkatnya manfaat teknologi, dampak negatif yang muncul juga semakin kompleks. Teknologi membuat perkembangan digitalisasi semakin pesat dan masa ini juga disebut masa perkembangan telepon seluler, mobil listrik, dan kecerdasan buatan yang dimulai pada awal abad 21 (Context Dergi, 2024). Menurut Habermas (1991), umat manusia diberikan kenyamanan oleh media baru itu semua yang muncul akibat digitalisasi. Kondisi ini disebut sebagai invasi terhadap dunia kehidupan.

Khalaf, dkk. (2023) menjelaskan bahwa *Facebook*, *Instagram*, *Twitter*, dan *TikTok* tidak hanya merupakan sebuah cara baru untuk berinteraksi secara sosial tetapi juga pola perilaku yang memerlukan analisis. Penggunaan media sosial memberikan manfaat positif bagi masyarakat terlebih mahasiswa, seperti mempermudah pertukaran informasi dan akses ke literatur *online*. Namun, di balik keuntungan tersebut, media sosial menimbulkan dampak negatif ketergantungan pada penggunaannya (Drakel, dkk., 2018). Teknologi membuat manusia menjadi bergantung dan menimbulkan masalah kesehatan internasional di seluruh dunia karena penggunaan media interaktif yang bermasalah (*Problematic Interactive Media Use / PIMU*). Penelitian lain menyatakan bahwa (PIMU) menimbulkan dampak yang lebih spesifik, yaitu hubungan antara penggunaan media sosial yang berlebihan dan rasa keterhubungan remaja di sekolah, yang dapat mengganggu fungsi kognitif dan mengakibatkan

penurunan hasil akademik (Digital Wellness Lab, 2024).

Fungsi kognitif seseorang dapat dipengaruhi oleh penggunaan media yang tidak terkendali, khususnya di kalangan remaja. Penelitian yang dilakukan oleh Shalash, dkk. (2024) menunjukkan bahwa paparan layar pada malam hari berpengaruh signifikan terhadap penurunan kemampuan kognitif dan fokus perhatian. Selain itu, Context Dergi (2024) mengaitkan kondisi serupa dengan kelelahan mental yang dapat mengganggu konsentrasi akibat penggunaan teknologi secara berlebihan.

Data dari Kemp (2023) menunjukkan bahwa rata-rata masyarakat Indonesia menghabiskan waktu 7 jam 42 menit per hari untuk menggunakan media sosial yang mencerminkan tingginya intensitas interaksi digital dalam kehidupan sehari-hari. Fenomena ini dalam konteks populer sering disebut sebagai istilah *“brain rot”* yang digunakan untuk menggambarkan kekhawatiran masyarakat terhadap dampak penggunaan media digital secara berlebihan terhadap kemampuan mental (Oxford University Press, 2024). Beberapa penelitian menunjukkan bahwa terdapat hubungan negatif antara tingkat kecanduan media sosial dan fungsi kognitif, di mana semakin tinggi tingkat adiksi terhadap media sosial, semakin rendah kemampuan konsentrasi dan daya ingat seseorang (Yazgan, 2025; Shalash, dkk., 2024).

Kecanduan media sosial dalam berbagai penelitian dikaitkan dengan beragam konsekuensi negatif, salah satunya yaitu penurunan fungsi kognitif. Penting untuk memahami bagaimana media sosial dapat memengaruhi individu dalam aspek kesehatan mental, fungsi kognitif, dan sifat sosialnya serta mengidentifikasi upaya untuk mengurangi dampak negatif tersebut. Kompleksitas data perilaku penggunaan media sosial mendorong perlunya pendekatan analisis berbasis data untuk mengidentifikasi pola-pola perilaku digital.

Di sisi lain, fenomena ini relevan untuk dikaji menggunakan metode analisis data karena perilaku penggunaan media sosial dapat dimodelkan secara prediktif. Meski telah terdapat beberapa

studi yang membahas tingkat kecanduan media sosial, sebagian besar penelitian tersebut masih berfokus pada analisis hubungan (korelasi) dengan kesehatan mental atau hasil belajar. Sementara itu, penelitian ini berfokus pada optimasi model klasifikasi menggunakan algoritma *Random Forest* dan *XGBoost* untuk mengidentifikasi tingkat adiksi secara otomatis melalui berbagai skenario pembagian data. Oleh karena itu, data perilaku pengguna media sosial yang diperoleh dari repositori data publik *Kaggle* digunakan sebagai dasar analisis, karena memuat variabel-variabel relevan seperti durasi penggunaan harian, jam tidur, skor kesehatan mental, hingga tingkat adiksi.

Beberapa penelitian yang dilakukan sebelumnya, telah berupaya untuk mendeteksi kecanduan media sosial menggunakan pendekatan pembelajaran mesin. Salah satunya penelitian yang dilakukan oleh Ehsan & Basit (2024) melakukan klasifikasi tingkat adiksi media sosial berdasarkan perilaku pengguna dan faktor psikologis dengan menggunakan model *Random Forest classifier* dan diperoleh akurasi sebesar 88,6%. Selanjutnya, penelitian Izhari (2025) melakukan pemodelan perilaku penggunaan media sosial pada mahasiswa menggunakan algoritma *XGBoost* yang menghasilkan tingkat akurasi sebesar 97,9%. Penelitian lainnya, yaitu oleh Lee & Kim (2021) yang memprediksi kecanduan penggunaan *smartphone* menggunakan *Random Forest* dan *XGBoost* dengan akurasi paling tinggi diperoleh *Random Forest* dengan 82,5%.

Walaupun pada ketiga penelitian tersebut menunjukkan performa tinggi, evaluasi yang dilakukan umumnya masih terbatas pada satu skenario pembagian data atau satu kali proses pelatihan dan pengujian. Oleh karena itu, diperlukan kajian lanjutan yang mengevaluasi konsistensi dan stabilitas performa algoritma *Random Forest* dan *XGBoost* melalui beberapa skenario pembagian data. *Random Forest classifier* dipilih karena keunggulan yang dimiliki dari metode klasifikasi lainnya, yaitu *robust* terhadap *outlier*, waktu komputasi yang kecil, serta hasil yang akurat (Syukron, dkk., 2020). Selain itu, algoritma *XGBoost* digunakan sebagai pembanding ka-

rena memiliki keunggulan dalam mengelola fitur campuran, *missing value*, serta memiliki mekanisme yang *robust* terhadap potensi *class imbalance* karena bekerja dengan prinsip *boosting* pada pohon keputusan (Chen & Guestrin, 2016). Dengan demikian, studi ini difokuskan untuk analisis perbandingan performa algoritma *Random Forest* dan *XGBoost* dalam klasifikasi tingkat kecanduan media sosial pada generasi muda berdasarkan beberapa skenario pembagian data.

B. Identifikasi Masalah

1. Intensitas penggunaan media sosial yang tinggi di kalangan generasi muda berpotensi menghasilkan perilaku adiktif yang berdampak pada penurunan fungsi kognitif, seperti kemampuan konsentrasi dan daya ingat.
2. Tingkat kecanduan media sosial sebagai salah satu bentuk *Problematic Interactive Media Use* (PIMU) perlu diidentifikasi secara objektif berdasarkan data perilaku digital.
3. Penelitian sebelumnya telah menerapkan berbagai algoritma *machine learning* untuk mengklasifikasikan tingkat kecanduan media sosial, namun menunjukkan variasi performa antar model.
4. Evaluasi performa model klasifikasi tingkat kecanduan media sosial pada sebagian penelitian masih terbatas pada satu skenario pembagian data, sehingga konsistensi dan stabilitas model belum tergambarkan secara menyeluruh.
5. Diperlukan kajian komparatif yang mengevaluasi performa algoritma *Random Forest* dan *XGBoost* dalam mengklasifikasikan tingkat kecanduan media sosial berdasarkan beberapa skenario pembagian data.

C. Rumusan Masalah

1. Bagaimana kinerja algoritma *Random Forest* dan *XGBoost* dalam mengidentifikasi tingkat kecanduan media sosial pada

mahasiswa berdasarkan data perilaku digital?

2. Bagaimana perbandingan performa algoritma *Random Forest* dan *XGBoost* pada tiga skenario pembagian data?

D. Tujuan Penelitian

1. Mengetahui kinerja algoritma *Random Forest* dan *XGBoost* dalam mengidentifikasi tingkat kecanduan media sosial pada mahasiswa berdasarkan data perilaku digital.
2. Melihat perbandingan performa algoritma *Random Forest* dan *XGBoost* pada tiga skenario pembagian data untuk menguji konsistensi hasil model.

E. Manfaat Penelitian

1. Manfaat Teoretis

- (a) Memberikan kontribusi empiris dalam kajian ilmu *Data Science* melalui analisis perbandingan performa algoritma *Random Forest* dan *XGBoost* pada data perilaku digital.
- (b) Menjadi referensi tambahan dalam studi mengenai analisis tingkat kecanduan media sosial pada generasi muda menggunakan pendekatan pembelajaran mesin.
- (c) Menunjukkan penerapan metode klasifikasi *Random Forest* dan *XGBoost* pada data perilaku pengguna media sosial, yang dapat menjadi dasar bagi penelitian lanjutan di bidang serupa.

2. Manfaat Praktis

- (a) Memberikan gambaran bagi mahasiswa dan masyarakat umum mengenai tingkat kecanduan media sosial berdasarkan pola perilaku penggunaan media sosial.
- (b) Menjadi referensi bagi lembaga pendidikan dalam merancang program literasi digital yang memperhatikan

keseimbangan penggunaan media sosial dan kesehatan kognitif.

- (c) Memberikan masukan bagi peneliti atau pengembang sistem kesejahteraan digital dalam mengembangkan model deteksi dini tingkat kecanduan media sosial berbasis perilaku pengguna.

F. Batasan Masalah

Mengingat luasnya ruang lingkup permasalahan, penelitian ini dibatasi pada aspek-aspek berikut agar pembahasan lebih terfokus:

1. Penelitian ini menggunakan dataset publik *Students Social Media Addiction* yang difokuskan pada generasi muda bersumber dari repositori data publik *Kaggle*.
2. Variabel yang digunakan terbatas pada fitur-fitur perilaku digital seperti durasi penggunaan media sosial, jam tidur, kesehatan mental, dan konflik sosial.
3. Model yang digunakan hanya algoritma *Random Forest* dan *XGBoost* tanpa membandingkan dengan metode *Deep Learning*.
4. Evaluasi model dilakukan dengan tiga skenario pembagian data (70:30, 80:20, dan 90:10), dan tidak mencakup validasi eksternal dengan dataset lain maupun analisis fitur model.

BAB II

KAJIAN PUSTAKA

A. Penelitian Terdahulu

Penelitian yang berkaitan dengan pembelajaran mesin menggunakan algoritma *Random Forest* dan *XGBoost* telah banyak dilakukan oleh beberapa peneliti sebelumnya. Literatur dari penelitian sebelumnya dengan ruang lingkup yang relevan dengan topik penelitian ini dapat digunakan sebagai bahan pertimbangan dalam penyusunan tugas akhir ini. Setelah melakukan kajian penelitian terdahulu maka dapat diperoleh hasil penelitian yang dirangkum dalam tabel berikut ini:

Tabel 2.1: Penelitian Terdahulu

Studi	Fokus Penelitian	Metode Utama	Hasil Utama
Ehsan & Basit (2024) <i>Machine Learning for Detecting Social Media Addiction Patterns: Analyzing User Behavior and Mental Health Data</i>	Klasifikasi tingkat kecanduan media sosial. Dataset: 10.000 responden (<i>Kaggle Dataset</i>)	<i>Random Forest classifier</i> . Rasio pembagian data (70:30)	<i>Accuracy</i> = 88,6%
Bersambung ke halaman berikutnya...			


Tabel Tabel 2.1: Penelitian Terdahulu (Sambungan)			
Studi	Fokus Penelitian	Metode Utama	Hasil Utama
Izhari (2025) Pemodelan Perilaku Penggunaan Media Sosial Mahasiswa dengan Algoritma XGBoost	Identifikasi tingkat kecanduan media sosial. Dataset: 705 mahasiswa (Kaggle Dataset)	XGBoost. Rasio pembagian data (80:20)	Accuracy = 97,9%
Lee & Kim (2021) <i>Prediction of Problematic Smartphone Use: A Machine Learning Approach</i>	Prediksi tingkat kecanduan penggunaan <i>smartphone</i> . Dataset: 29.712 responden (KISA Survey)	Random Forest, XGBoost, & Decision Tree. Rasio pembagian data (70:30)	Accuracy: RF=82,59%, XGB=80,77%, DT=74,56%

B. Kajian Teori

1. Machine Learning

Machine learning adalah aplikasi komputer yang menggunakan algoritma matematika, di mana program tersebut belajar dari data dan dapat menghasilkan prediksi di masa depan (Goldberg & Holland, 1988). Konsep utama *Machine Learning* adalah pengembangan sistem cerdas yang mampu melakukan pengambilan keputusan secara mandiri melalui proses pembelajaran data, sehingga tidak lagi bergantung pada instruksi program eksternal (Munoz, 2012). Proses belajar ini terdiri dari dua tahap, yaitu latihan (*training*) dan pengujian (*testing*) Ehsan & Basit (2024).

Gambar 2.1 menunjukkan dua jenis *dataset* yaitu data latih dan data uji. Chauhan & Singh (2018) menjelaskan bahwa data pelatihan digunakan untuk mengajarkan model dengan proses pra-pemrosesan data dan mengekstrak fitur sebelum model tersebut dilatih. Setelah model selesai dilatih, model tersebut kemudian digunakan untuk memprediksi hasil dari data yang belum diketahui, yang disebut sebagai data uji. Tingkat akurasi model juga dapat diukur dengan membandingkan hasil prediksi pada data uji dengan hasil sebenarnya, karena hasil tersebut sudah dike-



Gambar 2.1: *Training dan Testing Pada Model Machine Learning* (Pandey, dkk., 2019)

tahui. Metode *machine learning* secara umum diklasifikasikan menjadi tiga jenis metode pembelajaran, yaitu *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. Berikut pembagian dari jenis-jenis penerapan *Machine Learning*:

a. Supervised Learning

Metode *supervised learning* merupakan algoritma yang membutuhkan supervisi (pengawasan) dalam proses memprediksi atau *decision making*. *Dataset* masukan dibagi menjadi data latih (*training data*) dan data uji (*testing data*). Dalam membantu model belajar pada metode *supervised learning*, nilai target atau *output* sudah diberikan pada data latih. Metode ini biasanya digunakan untuk klasifikasi dan regresi. Klasifikasi digunakan ketika dihadapkan masalah dengan nilai keluaran diskrit (kategori). Sedangkan regresi digunakan ketika melakukan pengambilan keputusan dengan keluaran kontinu (Kotsiantis, 2007).

b. Unsupervised Learning

Unsupervised learning adalah jenis metode *machine learning* yang melakukan tugas memahami (menyimpulkan sesuatu) untuk menemukan pola yang tersembunyi dalam sekumpulan data yang tidak memiliki label. Dalam metode ini, model dilatih hanya menggunakan karakteristik dari data yang tidak memiliki label, kemudian model tersebut digunakan untuk membuat keputusan terhadap data uji yang sudah tersedia. Secara umum, *unsupervised learning* memfokuskan pada dua masalah utama, yaitu *clustering* (pengelompokan) dan *dimensional reduction* (reduksi dimensi) (Alsabti, dkk., 1997; Trisal & Mandloi, 2021).

c. Reinforcement Learning

Reinforcement learning adalah metode campuran antara *supervised* dan *unsupervised learning* (Kaelbling, dkk., 1996). Hiregoudar, dkk. (2014) menjelaskan bahwa model *reinforcement learning* sepenuhnya bergantung pada dua prinsip utama, yaitu *trial and error finding* dan *delayed outcome*. Dalam model ini, agen menciptakan perilaku berdasarkan *input* dari lingkungan. Akibat perilaku tersebut, agen mengambil sebuah tindakan yang kemudian mengubah kondisi lingkungan. Model *neuron reinforcement* tidak memiliki pengetahuan awal tentang target, melainkan belajar sepenuhnya dari umpan balik yang diberikan oleh lingkungan.

Pada penelitian ini menggunakan penerapan *machine learning* jenis *supervised learning* karena data yang digunakan sudah memiliki target atau label pada setiap sampel untuk melatih model dengan mempelajari hubungan antara fitur *input* dan kelas *output*. Metode ini juga dipilih karena masalah yang diteliti merupakan masalah klasifikasi dengan nilai keluaran diskrit (berbentuk kategori), yaitu tingkat kecanduan media sosial yang diklasifikasikan berdasarkan fitur perilaku penggunaan media sosial.

2. Klasifikasi

Menurut Nasution, dkk. (2019) klasifikasi adalah proses mengelompokkan atau memberi label pada data atau objek baru berdasarkan kriteria tertentu. Teknik ini melibatkan analisis variabel yang diperoleh dari data yang sudah ada. Tujuannya adalah untuk memprediksi kelas dari objek yang belum diketahui. Klasifikasi terdiri dari tiga tahap, yaitu pembuatan model, penerapan model, dan evaluasi. Pada tahap konstruksi model, data


pelatihan yang sudah memiliki atribut dan kelas digunakan untuk menciptakan model. Model ini kemudian digunakan untuk memprediksi kelas dari data baru. Setelah itu, model dievaluasi untuk mengetahui seberapa akurat hasilnya ketika diterapkan pada data lain. Klasifikasi juga dapat dilihat sebagai proses menilai objek dan memasukkan objek tersebut ke dalam salah satu kelompok yang sudah ditentukan (Prasetyo, 2012). Sedangkan menurut Han & Kamber (2006) klasifikasi adalah upaya mencari model-model yang dapat menggambarkan dan membedakan setiap kelas data sehingga objek dengan kelas yang belum diketahui dapat diprediksi.

3. *Random Forest Classifier*

Random Forest merupakan pengembangan dari algoritma *Decision Tree* (Nugroho, 2022). Penelitian oleh Dan, dkk. (2015) menjelaskan *Decision Tree* adalah metode yang mengubah data menjadi struktur pohon keputusan serta menghasilkan aturan-aturan keputusan. *Decision Tree* memiliki tiga jenis *node*, yaitu *root node* yang berada pada bagian paling atas dari pohon dan tidak memiliki *input*, *internal node* yang merupakan titik percabangan dalam pohon, serta *leaf node* atau *terminal node* yang merupakan *node* terakhir dalam pohon.

Dinata, dkk. (2021) menyatakan algoritma ini disebut 'forest' yang berarti kumpulan dari pohon keputusan. *Random Forest* akan membangun beberapa pohon menggunakan data sampel, di mana setiap pohon yang dibuat saat proses pelatihan tidak tergantung pada pohon sebelumnya. Keputusan akhir diambil berdasarkan hasil *voting* yang paling banyak. Dua konsep utama dalam *Random Forest* adalah *bagging* (*bootstrap aggregating*) yang menggabungkan beberapa pohon dengan pengambilan data secara acak dan penggunaan fitur yang dipilih secara acak untuk setiap pohon. *Random Forest* memiliki dua parameter utama, yaitu parameter m yang menunjukkan persentase jumlah pohon yang digunakan dan parameter k yang mewakili jumlah maksimal fitur yang dipertimbangkan saat proses percabangan pada pohon.

Gambar 2.2 menunjukkan cara kerja algoritma *Random Forest*, yang terdiri atas sekumpulan pohon keputusan (*decision tree*). Setiap pohon dibangun menggunakan *subset* data dan *subset* fitur yang dipilih secara acak Breiman (2001). Setelah seluruh pohon terbentuk, masing-masing menghasilkan prediksi kelas secara independen. Hasil akhir ditentukan melalui proses *majority voting* (untuk klasifikasi) atau *averaging* (untuk regresi), di



Gambar 2.2: Struktur Algoritma *Random Forest* (Khan, dkk., 2021)

mana kelas yang paling banyak dipilih menjadi keluaran model (Liaw & Wiener, 2002; Han, dkk., 2011).

Pendekatan ini membuat *Random Forest* mampu mengurangi variansi dan meningkatkan akurasi prediksi dibandingkan dengan penggunaan satu pohon keputusan tunggal. Menurut Breiman (2001), kekuatan masing-masing pohon (*strength*) dan tingkat korelasi antar pohon (*correlation*) menentukan performa dari algoritma *Random Forest classifier*. Secara matematis, batas atas untuk kesalahan generalisasi pada *random forest* didefinisikan oleh Breiman sebagai berikut:

$$PE^* \leq \frac{\bar{\rho}(1 - s^2)}{s^2} \quad (2.1)$$


Di mana $\bar{\rho}$ adalah rata-rata korelasi antar pohon dan s menunjukkan *strength* (kekuatan) dari kumpulan pohon tersebut. Nilai s didefinisikan secara matematis sebagai nilai ekspektasi dari fungsi margin, yaitu:

$$s = E_{X,Y} mr(X, Y) \quad (2.2)$$

Fungsi margin $mr(X, Y)$ mengukur seberapa besar selisih suara rata-rata untuk kelas yang benar dibandingkan dengan kelas lainnya. Semakin tinggi nilai kekuatan (s) dan semakin rendah rata-rata korelasinya ($\bar{\rho}$), maka batas atas peluang kesalahan prediksi model (PE^*) akan semakin kecil.

4. *Extreme Gradient Boosting (XGBoost)*

XGBoost merupakan salah satu metode *boosting* yang terdiri dari beberapa pohon keputusan (*decision tree*), di mana setiap pohon diperkuat oleh pohon sebelumnya dan pohon berikutnya yang saling tergantung satu sama lain (Syukron, dkk., 2020). Ketika melakukan klasifikasi, *XGBoost* akan memperbarui bobot pada setiap pohon yang dibangun sehingga diperoleh pohon klasifikasi yang kuat (Salam Patrous, 2018).



Gambar 2.3: Struktur Algoritma *XGBoost* (Ahmed, dkk., 2023)

Gambar 2.3 menunjukkan struktur algoritma *XGBoost* di mana algoritma ini bekerja secara aditif dengan membangun pohon keputusan secara bertahap ($Tree_1, Tree_2, \dots, Tree_n$). Nilai target tidak secara langsung dapat diprediksi oleh setiap pohon baru, tetapi mempelajari *residual* atau kesalahan prediksi dari model sebelumnya. Proses pelatihan *XGBoost* berfokus pada minimisasi fungsi objektif (*objective function*) yang terdiri dari dua komponen, yaitu nilai kesalahan prediksi (*loss function*) dan regularisasi model. Fungsi objektif tersebut dirumuskan sebagai berikut:

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (2.3)$$

Di mana t menunjukkan iterasi saat ini dalam proses *boosting*, sehingga $L^{(t)}$ adalah fungsi objektif yang diminimalkan untuk melatih pohon ke- t . Nilai $\hat{y}_i^{(t-1)}$ representasi dari prediksi akumulatif iterasi sebelumnya, sedangkan $f_t(x_i)$ adalah fungsi dari pohon baru yang ditambahkan pada iterasi tersebut. Komponen $\Omega(f_t)$ adalah fungsi regularisasi untuk mengontrol kompleksitas pohon, yang didefinisikan sebagai:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.4)$$

Dalam hal ini, T menunjukkan jumlah *leaf* dalam pohon, yang berbeda dengan indeks iterasi t . Penambahan T dalam fungsi regularisasi bertujuan untuk memberikan penalti pada pohon yang memiliki terlalu banyak cabang guna mencegah *overfitting*.

5. Kecanduan Media Sosial

Trisnani & Wardani (2018) menyatakan, kecanduan media sosial ialah mereka merasa tertarik untuk terus mengunggah konten tanpa tujuan yang jelas, sehingga menghabiskan waktu berjam-jam di depan layar. Kecanduan ini membuat mereka menghabiskan lebih sedikit waktu untuk kegiatan seperti belajar atau berolahraga, serta mengganggu interaksi sosial di dunia nyata. Remaja yang kecanduan media sosial cenderung lebih suka berada sendirian dan lebih nyaman berkomunikasi melalui internet (Aribowo & Bagaskara, 2025). Menurut Griffiths dalam Silitonga (2023), kecanduan teknologi memang memiliki dampak psikologis yang mirip dengan kecanduan zat, karena seseorang kesulitan mengurangi atau berhenti menggunakan media sosial meskipun sudah menyadari dampak negatifnya.

Pv (2025) menyatakan bahwa media sosial kini menjadi instrumen fundamental yang memengaruhi cara individu memproses informasi dan berinteraksi secara sosial. Namun, masifnya penggunaan platform ini menimbulkan kekhawatiran terkait penurunan fungsi kognitif dan kesehatan mental. Paparan terhadap konten berbasis algoritma dan mekanisme gratifikasi instan telah terbukti memperpendek rentang perhatian (*attention span*) serta memperlemah kapasitas memori kerja (*working memory*). Selain itu, penggunaan yang berlebihan berkorelasi pada disregulasi emosi, pe-

ningkatan kecemasan, serta potensi perubahan struktural pada otak akibat stimulasi digital yang berlebih.

6. Data Binning

Data binning adalah salah satu teknik pra-pemrosesan data yang digunakan untuk membagi nilai numerik ke dalam beberapa interval atau kategori tertentu (Han, dkk., 2011). Beberapa metode binning yang sering digunakan antara lain *Equal Width Binning*, yaitu pembagian rentang nilai ke dalam interval dengan lebar yang sama. Selain itu *Equal Frequency Binning*, yaitu pembagian data ke dalam interval dengan jumlah observasi yang relatif seimbang berdasarkan kuantil distribusi data (Han, dkk., 2011; Putri, 2023).

Equal Frequency Binning yang diterapkan untuk membagi data ke dalam tiga kelompok dengan ukuran yang sama, disebut pendekatan *Tertile*. Berbeda dari kuartil yang membagi data menjadi empat kelompok dengan tiga titik potong (Q_1, Q_2, Q_3), *Tertile* hanya menggunakan dua titik potong (T_1 dan T_2) sehingga terbentuk tiga kelompok dengan proporsi yang relatif seimbang, yaitu sekitar 33% pada setiap kelompok (Han, dkk., 2011). Dalam konteks klasifikasi, pendekatan *Tertile* pernah digunakan oleh Yan, dkk. (2021) melalui diskritisasi tiga *equal-frequency bins*. Penelitian tersebut menetapkan kuantil $1/3$ dan $2/3$ sebagai batas pemisah untuk memperoleh tiga kategori target dengan proporsi yang seimbang. Secara matematis, letak *Tertile* ke- i pada data tunggal dengan n sampel didefinisikan sebagai:

$$L_{T_i} = \frac{i(n+1)}{3} \quad (2.5)$$

Di mana L_{T_i} adalah letak *Tertile* ke- i ($i = 1, 2$) dan n adalah jumlah sampel penelitian.

Pendekatan *quantile-based binning* juga digunakan oleh Ehsan & Basit (2024) dengan Q_1 (25%) dan Q_3 (75%) sebagai batas untuk membagi skor kecanduan media sosial ke dalam kategori *Low*, *Medium*, dan *High*. Pada penelitian ini, pembagian tersebut diadaptasi dengan metode *Tertile*, yaitu T_1 pada posisi 33,3% dan T_2 pada posisi 66,7%, agar distribusi kelas menjadi lebih seimbang dibandingkan pendekatan Q_1 – Q_3 yang cenderung membuat kelas *Medium* mendominasi data.

BAB III METODE PENELITIAN

A. Dataset

Dataset yang digunakan dalam penelitian ini adalah data *Student Social Media Addiction* yang diambil dari repositori data publik *Kaggle*. Data tersebut berisi 705 jawaban responden yang berasal dari berbagai negara, termasuk Indonesia. ?? pada lampiran menampilkan sebagian isi dari data *Student Social Media Addiction* yang mencakup 13 variabel, dengan penjelasan pada Tabel 3.1 berikut:

Tabel 3.1: Atribut Dataset

Nama Atribut	Tipe Data	Deskripsi	Nilai
Student_ID	Integer	ID unik responden	Bilangan bulat unik
Age	Integer	Usia responden	18–24
Gender	String	Jenis kelamin	<i>Male, Female</i>
Academic_Level	String	Tingkat pendidikan	<i>High School, Undergrad, Grad</i>
Country	String	Negara asal	<i>USA, UK, Canada, dll</i>
Avg_Daily_Usage_Hours	Float	Durasi rata-rata penggunaan media sosial per hari (jam)	≥ 0
Most_Used_Platform	String	Platform media sosial yang paling sering digunakan	<i>Instagram, TikTok, YouTube, dsb</i>
<i>Bersambung ke halaman berikutnya...</i>			

Tabel 3.1: Atribut Dataset (Sambungan)

Nama Atribut	Tipe Data	Deskripsi	Nilai
Affect_Academic_Performance	String	Pengaruh penggunaan media sosial terhadap akademik	Yes, No
Mental_Health_Score	Integer	Skor kondisi kesehatan mental	Skala numerik (1–10)
Sleep_Hours_Per_Night	Float	Durasi tidur responden dalam jam	0–24
Relationship_Status	String	Status hubungan yang dijalani responden	<i>In Relationship, Single, Complicated</i>
Conflict_Over_Social_Media	Integer	Tingkat konflik akibat aktivitas di media sosial	≥ 0
Addiction_Score	String	Skor Tingkat Kecanduan	2-9

1. Populasi dan Sampel

Populasi dari penelitian ini, yaitu seluruh pengguna media sosial pada rentang usia remaja sampai dewasa awal, khususnya pada mahasiswa yang aktif dalam menggunakan media sosial dalam kegiatan sehari-harinya. Sampel yang digunakan berupa 705 data dari *Student Social Media Addiction* berupa jawaban responden yang diambil dari repositori data publik *Kaggle*. Responden dalam dataset tersebut berada pada rentang usia remaja hingga dewasa awal dan berasal dari berbagai negara, sehingga penelitian ini tidak dibatasi pada konteks wilayah geografis tertentu. Dataset ini dipilih karena memuat variabel-variabel yang relevan dengan perilaku penggunaan media sosial.


2. Metode dan Analisis Data

Metode analisis data dalam penelitian ini menggunakan pendekatan *machine learning* dengan algoritma *Random Forest* dan *XGBoost* sebagai pembanding. Algoritma tersebut digunakan untuk membangun model klasifikasi yang bertujuan mengidentifikasi tingkat kecanduan media sosial. Analisis dilakukan dengan membandingkan hasil akurasi masing-masing model pada tiga skenario pembagian data, yaitu 70:30, 80:20, dan 90:10.

Tujuan dari perbandingan ini adalah untuk mengetahui pengaruh rasio pembagian data terhadap kinerja model serta menilai seberapa stabil dan baik generalisasi model dalam memprediksi tingkat kecanduan media sosial. Hasil dari tahapan ini diharapkan dapat membantu menentukan rasio data latih dan data uji yang paling optimal untuk menghasilkan performa model terbaik.

B. Alur Penelitian

Alur penelitian ini disusun untuk menggambarkan tahapan-tahapan penelitian yang dilakukan secara sistematis dan terstruktur dalam mencapai tujuan penelitian. Penyusunan alur penelitian bertujuan agar proses analisis dapat berjalan secara terarah, konsisten, dan sesuai dengan fokus penelitian. Setiap tahapan saling berkaitan, mulai dari tahap awal hingga tahap akhir penelitian, sebagaimana ditunjukkan pada Gambar 3.1.



Gambar 3.1: Gambaran Umum Alur Penelitian

1. Studi Literatur

Pencarian literatur yang relevan dilakukan untuk mendukung dan menjadi acuan dalam penelitian. Sumber literatur diperoleh dari berbagai buku, artikel, dan jurnal yang berkaitan dengan topik media sosial, kecanduan media sosial, hubungan kecanduan media sosial dengan fungsi kognitif, serta penerapan algoritma *machine learning*, khususnya *Random Forest* dan *XGBoost*. Melalui studi literatur, peneliti mempelajari konsep-konsep dasar yang menjadi landasan penelitian, melihat hasil penelitian sebelumnya, dan mengidentifikasi celah penelitian yang belum banyak dibahas.


2. Pengambilan Data

Dataset dalam penelitian ini merupakan data sekunder yang diambil dari repositori data publik *Kaggle*. Dataset ini dipublikasikan oleh Shamim (2025) pada tahun 2022. Dataset ini dikumpulkan melalui survei daring terhadap mahasiswa dan generasi muda dari berbagai negara, termasuk Indonesia, sehingga merepresentasikan karakteristik pengguna media sosial pada rentang usia remaja hingga dewasa awal. Data yang digunakan pada penelitian ini bersifat kuantitatif dan berbentuk tabular, dengan jumlah total sebanyak 705 responden. Selain itu, dataset ini juga menyediakan variabel *Addicted_Score* yang merepresentasikan tingkat kecanduan media sosial dalam bentuk skor numerik hasil pengukuran survei.

3. Pengolahan Data

Setelah proses pengambilan data *Student Social Media Addiction*, data ini tidak dapat langsung digunakan. Diperlukan adanya pengolahan data atau pra-pemrosesan data agar data siap digunakan pada proses selanjutnya. Oleh karena itu, berikut ini merupakan diagram alur pra-pemrosesan data.

Pada tahap awal dilakukan input data *Student Social Media Addiction*, lalu dilakukan *Exploratory Data Analysis* untuk melihat informasi awal data seperti pengecekan *missing value*, *unique value*, dan melihat tipe data. Selanjutnya, kolom yang tidak relevan seperti *Student_ID* dan *Country* dihapus agar tidak mengganggu hasil analisis. Berikutnya melakukan *binning target* pada kolom *Addicted_Score* untuk mengubah skor numerik diskrit menjadi tiga kategori kecanduan (*Low*, *Medium*, dan *High*) dengan metode tertile.



Gambar 3.2: Diagram Alur Pra-pemrosesan Data

Untuk menentukan tingkat kecanduan media sosial responden, penelitian ini menggunakan metode *data binning* dengan pendekatan *Equal Frequency* atau tertile. Metode tertile digunakan agar data dapat dibagi secara objektif menjadi tiga kategori yaitu Rendah, Sedang, dan Tinggi berdasarkan distribusi nilai dari sampel yang diteliti. Penentuan ambang batas (*cut-off point*) dilakukan dengan mencari nilai Tertile 1 (T_1) dan Tertile 2 (T_2) menggunakan rumus data tunggal sebagai berikut:

$$L_{T_i} = \frac{i(n+1)}{3} \quad (3.1)$$

Keterangan:

L_{T_i} : letak Tertile ke- i ($i = 1, 2$),

n : jumlah sampel penelitian ($n = 705$).

Kriteria yang disajikan pada Tabel 3.2 disusun menggunakan metode *Equal Frequency Binning* berdasarkan distribusi nilai tertile. Nilai Tertile 1 (T_1) dan Tertile 2 (T_2) berfungsi sebagai titik potong (*cut-off point*) untuk membagi responden ke dalam tiga kelompok secara objektif. Penentuan

Tabel 3.2: Kriteria Kategorisasi Tingkat Kecanduan Media Sosial

Kategori	Kriteria Skor
Rendah (<i>Low</i>)	$\text{Skor} \leq T_1$
Sedang (<i>Medium</i>)	$T_1 < \text{Skor} \leq T_2$
Tinggi (<i>High</i>)	$\text{Skor} > T_2$


nilai ambang batas ini dilakukan secara empiris dengan membagi sebaran frekuensi data ke dalam tiga bagian yang sama besar, berdasarkan frekuensi kumulatif tempat kelas (T_1) dan (T_2) sehingga setiap kategori mencerminkan proporsi populasi yang seimbang berdasarkan kondisi aktual. Selanjutnya kolom kategorikal juga diubah menggunakan *label encoding* agar dapat dibaca oleh algoritma sedangkan proses standardisasi atau normalisasi dilakukan dengan metode *StandardScaler* agar skala antarvariabel menjadi seragam.

4. Proses Pemodelan

Setelah melakukan tahapan pra-pemrosesan data, dihasilkan data yang sudah bersih. Selanjutnya data siap untuk dilakukan proses pemodelan data. Berikut diagram alur dari proses pemodelan data.

Proses pemodelan data diawali dengan memasukkan dataset bersih hasil pra-pemrosesan data, setelah itu memasuki tahapan pembagian data. Pada penelitian ini, pembagian data dilakukan dengan menjalankan tiga skenario (70:30, 80:20, dan 90:10) bertujuan untuk mengetahui pengaruh perbandingan data latih dan data uji terhadap kemampuan model. Serta tahapan ini dilakukan untuk memperoleh hasil akurasi terbaik pada dataset yang akan digunakan.

Dari penelitian yang sudah dilakukan sebelumnya oleh Nugroho (2022) yang membandingkan tiga teknik *splitting criteria* dimulai dari 90% : 10% s/d 70% : 30% (Kahlout & Ekler, 2021). Penelitian ini menggunakan dua model algoritma *machine learning* untuk proses klasifikasinya, yaitu *Decision Tree* dan *Random Forest* lalu diperoleh hasil akurasi tertinggi pada 90% *data training* dan 10% *data testing*. Hasil akurasi cenderung menurun ketika presentase *data training* berkurang. Hal ini membuktikan bahwa semakin besar *data training*, akurasi akan semakin tinggi, karena semakin banyak *data training* yang digunakan, model akan semakin banyak



Gambar 3.3: Diagram Alur Proses Pemodelan

mengenali pola dari data. Selain itu, Anjani, dkk. (2023) menggunakan empat proporsi pembagian data (60 : 40, 70 : 30, 80 : 20, dan 90 : 10) untuk mengetahui hasil proporsi terbaik pada model *Random Forest*. Proporsi 90 : 10 menghasilkan performa terbaik dengan akurasi 98,9% dan AUC 99,2%.

Penelitian lain yang dilakukan Kahloot & Ekler (2021) yang menunjukkan bahwa variasi rasio pembagian data dapat memengaruhi representativitas *subset* dan stabilitas hasil evaluasi model. Mereka mengusulkan metode *algorithmic splitting* untuk mengurangi bias akibat pembagian acak, serta menunjukkan bahwa rasio sekitar 70 : 30 sering memberikan keseimbangan terbaik antara kemampuan generalisasi dan efisiensi model. Mengacu pada studi terdahulu, proporsi data latih yang lebih besar cende-

rung meningkatkan akurasi, namun ukuran set uji yang terlalu kecil dapat menurunkan reliabilitas evaluasi. Kemudian proses pemodelan data dengan algoritma *Random Forest classifier* dan *XGBoost* pada masing-masing rasio pembagian data.

5. Evaluasi Model

Evaluasi model dilakukan agar mengetahui seberapa baik algoritma dapat membedakan data berdasarkan tingkat kecanduan media sosial. Dalam penelitian ini, pengujian dilakukan menggunakan algoritma *Random Forest* dan *XGBoost* yang digunakan untuk mengklasifikasikan tingkat kecanduan media sosial. Evaluasi kemampuan model dilakukan dengan melihat beberapa ukuran umum dalam pembelajaran mesin, seperti *accuracy*, *precision*, *recall*, *f1-score* dari *confusion matrix*.

Metrik evaluasi diperoleh dari hasil evaluasi berulang menggunakan teknik *Stratified k-Fold Cross Validation*. Teknik ini membagi dataset menjadi k lipatan (*folds*) dengan tetap mengacu pada prinsip *Proportionate Stratified Random Sampling* Sugiyono (2018) untuk memastikan tiap tingkatan (Rendah, Sedang, Tinggi) memiliki proporsi yang identik dengan dataset asli di setiap lipatannya. Rumus pembagian sampel pada setiap strata didefinisikan sebagai berikut:

$$n_h = \frac{N_h}{N} \times n \quad (3.2)$$

Dalam proses ini, dataset dibagi menjadi k bagian, di mana model dilatih pada $k - 1$ lipatan dan diuji pada satu lipatan sisanya secara bergantian sebanyak k kali. Pendekatan ini digunakan untuk memperoleh estimasi performa model yang lebih stabil melalui nilai rata-rata (*mean*) dan standar deviasi (*standard deviation*), sehingga mengurangi bias akibat pemilihan data uji secara acak (Kohavi, 1995).

Hasil akhir dari pengujian model dilaporkan dalam bentuk nilai rata-rata (μ) dan standar deviasi (σ) dari seluruh iterasi k . Nilai standar deviasi sangat krusial dalam penelitian ini untuk menunjukkan tingkat varians atau konsistensi model dalam melakukan klasifikasi pada subset data yang berbeda. Tujuan dari pengukuran ini adalah untuk mengevaluasi hasil klasifikasi secara menyeluruh, baik dalam hal ketepatan prediksi, keseimbangan antar kelas, maupun kemampuan model dalam mengenali data aktual.

Salah satu cara utama untuk mengevaluasi hasil klasifikasi adalah dengan menggunakan *confusion matrix*. Matriks ini menunjukkan hubungan antara hasil yang diprediksi oleh model dengan nilai sesungguhnya. Gambar 3.4 menunjukkan confusion matrix untuk permasalahan *multi-class classification* dengan tiga kelas (A, B, dan C). Komponen dalam matriks tersebut adalah:

1. TP_A, TP_B, TP_C (*True Positive*): Jumlah data yang berhasil diprediksi dengan benar untuk masing-masing kelas.
2. E_{ij} (*Error*): Jumlah kesalahan klasifikasi di mana data yang seharusnya termasuk kelas j (kolom) diprediksi sebagai kelas i (baris).
3. Sebagai contoh, E_{BA} menunjukkan jumlah data yang sebenarnya merupakan kelas B, namun salah diprediksi sebagai kelas A.

		True Class		
		A	B	C
Predicted Class	A	TP_A	E_{BA}	E_{CA}
	B	E_{AB}	TP_B	E_{CB}
	C	E_{AC}	E_{BC}	TP_C

Gambar 3.4: Confusion Matrix Multi-class Classification (Tharwat, 2020)

Berdasarkan nilai-nilai pada *confusion matrix multiclass* tersebut, kinerja model dihitung menggunakan metrik evaluasi sebagai berikut:

- a. **Accuracy**, mengukur rasio prediksi benar terhadap keseluruhan data.

$$Accuracy = \frac{TP_A + TP_B + TP_C}{N} \quad (3.3)$$

- b. **Precision**, mengukur sejauh mana positif nyata diprediksi dengan benar sebagai positif.

$$Precision = \frac{TP}{TP + FP} \quad (3.4)$$

- c. *Recall*, dihitung sebagai rata-rata kemampuan model dalam memanggil kembali informasi yang benar:

$$Recall = \frac{TP}{TP + FN} \quad (3.5)$$

- d. *F1-Score*, nilai keseimbangan antara presisi dan recall

$$F1 = \frac{2 \times (Precision \times Recall)}{Precision + Recall} \quad (3.6)$$

6. Menarik Kesimpulan

Metode yang digunakan dalam penelitian ini dirancang untuk menjawab tujuan utama, yaitu mengidentifikasi tingkat kecanduan media sosial berdasarkan data perilaku digital, dengan pendekatan *machine learning* menggunakan algoritma *random forest* dan *XGBoost* sebagai algoritma pembandingan. Penggunaan algoritma *random forest* dan *XGBoost*, karena keduanya memiliki kemampuan yang baik dalam menangani data klasifikasi dan telah terbukti efektif dalam penelitian sebelumnya. Untuk mengevaluasi hasil model, penelitian ini membandingkan akurasi, presisi, *recall*, dan *f1-score* pada beberapa rasio pembagian data, yaitu 70:30, 80:20, dan 90:10.


BAB IV

HASIL PENELITIAN DAN PEMBAHASAN


A. Hasil Penelitian

1. Deskripsi Data

Sebagai langkah awal analisis diperlukan statistik deskriptif untuk melihat karakteristik responden, khususnya distribusi persebaran jenis kelamin, usia, dan juga platform yang sering digunakan. Tujuan dari hal ini adalah agar data yang akan diproses memiliki representasi yang tepat sesuai dengan fenomena kecanduan media sosial yang terjadi di kalangan mahasiswa sekarang. Pada Gambar 4.1 - Gambar 4.6 merupakan sebaran data kategorikal, sementara data numerik disajikan dalam Tabel 4.1




Gambar 4.1: Sebaran Jenis Kelamin Responden




Gambar 4.2: Distribusi Usia Responden

Berdasarkan Gambar 4.1 distribusi jenis kelamin responden dalam penelitian ini hampir seimbang dengan jumlah 353 responden laki-laki dan 352 responden perempuan. Sementara itu Gambar 4.2 menunjukkan distribusi usia responden dari sampel penelitian yang akan digunakan. Penelitian ini mengambil sampel pengguna media sosial dengan rentang usia 18 – 24 tahun yang merepresentasikan remaja sampai dewasa muda.

Berdasarkan Gambar 4.3, sebagian besar responden berada pada jen-




Gambar 4.3: Distribusi Tingkat Akademik Responden



Gambar 4.4: Platform Media Sosial yang Paling Banyak Digunakan


jang pendidikan sarjana (*undergraduate*), kemudian diikuti oleh responden dengan jenjang pendidikan pascasarjana (*graduate*), dan hanya sedikit responden yang berada pada jenjang sekolah menengah atas (*high school*). Gambar 4.4 menunjukkan platform media sosial yang paling banyak digunakan oleh responden. Tren menempatkan Instagram di urutan pertama dengan jumlah 249 pengguna, disusul oleh TikTok dengan 154 pengguna, selanjutnya Facebook digunakan oleh sekitar 123 responden, diikuti oleh WhatsApp yang digunakan oleh 54 responden. Selebihnya diikuti platform lain seperti Twitter, LinkedIn, WeChat, Snapchat, VKontakte, LINE, KakaoTalk, dan Youtube.



Gambar 4.5: Distribusi Status Hubungan Responden

Berikutnya, Gambar 4.5 menunjukkan profil responden berdasarkan status hubungan. Terlihat bahwa sebanyak 384 responden menjalani status lajang (*single*), 289 responden sedang menjalani hubungan (*in relationship*), sedangkan 32 lainnya berada dalam status hubungan yang kompleks (*com-*

plicated relationship). Informasi mengenai status hubungan ini memberikan konteks tambahan dalam memahami perilaku penggunaan media sosial.



Gambar 4.6: Top 10 Negara Responden


Selain variabel demografis dan tingkat pendidikan, dataset ini juga mencakup penyebaran responden dari berbagai wilayah geografis yang sangat luas. Berdasarkan hasil analisis data, responden berasal dari 110 negara yang berbeda. Meskipun data tersebar luas di berbagai negara di dunia, beberapa negara memiliki jumlah responden yang lebih banyak, yaitu India dengan 53 responden, Amerika Serikat dengan 40 responden, dan Kanada dengan 34 responden.

Tabel 4.1: Statistik Deskriptif Atribut Penggunaan Media Sosial

	Durasi Media Sosial	Durasi Tidur	Skor Mental
<i>Mean</i>	4.918723	6.868936	6.226950
<i>Min</i>	1.500000	3.800000	4.000000
<i>Max</i>	8.500000	9.600000	9.000000

Tabel 4.1 menampilkan statistik deskriptif untuk atribut penggunaan media sosial dan kesehatan mental responden. Berdasarkan data tersebut, rata-rata waktu penggunaan media sosial setiap hari oleh responden adalah 4,92 jam, dan ada yang menggunakan hingga 8,5 jam per hari. Penggunaan tersebut berdampak pada durasi tidur responden dengan rata-rata 6,87 jam per malam, di mana terdapat responden yang hanya tidur selama 3,8 jam. Selain itu, rata-rata skor kesehatan mental para responden

mencapai angka 6,23 dari skala 10.



Gambar 4.7: Heatmap Korelasi Antar Variabel Numerik

Gambar 4.7 menunjukkan visualisasi korelasi antarvariabel numerik dalam dataset penelitian. Hasil tersebut menjadi acuan untuk melihat pola hubungan antarvariabel sebelum dibahas lebih lanjut pada subbab pembahasan.

2. Pra-pemrosesan Data

Tahap pra-pemrosesan data dilakukan setelah melihat bagaimana kondisi aktual data melalui proses *Exploratory Data Analysis* (EDA). Tahapan ini bertujuan untuk mempersiapkan data sebelum memasuki proses pemodelan. Tahapan ini meliputi pembersihan data, transformasi variabel, hingga pembagian dataset.

(a) Penghapusan Kolom yang Tidak Relevan

Penghapusan kolom yang tidak relevan dilakukan dengan eliminasi fitur manual. Kolom *Student_ID* tidak dihapus, melainkan diatur menjadi indeks sehingga tidak ada data duplikat pada

saat pengecekan duplikasi data dikarenakan indeks diikutsertakan dalam proses pengecekan. Kolom *Country* dihapus karena tidak memberikan pengaruh signifikan terhadap variabel target dan memiliki kardinalitas yang sangat tinggi. Merujuk Pargent, dkk. (2022), kardinalitas merupakan jumlah nilai unik dalam sebuah variabel kategorikal. Mengacu pada penelitian terdahulu Ehsan & Basit (2024), beberapa variabel yang tidak diperlukan dihapus untuk membuat analisis lebih efisien.

Sejalan dengan laporan dari Lee & Kim (2021) bahwa informasi dasar pengguna, seperti usia, jenis pekerjaan, dan jenis kelamin, tidak terlalu memberikan pengaruh signifikan dalam memprediksi tingkat ketergantungan *smartphone*. Namun penelitian tersebut tetap memanfaatkan fitur-fitur tersebut dalam pemodelan untuk menjaga keutuhan informasi perilaku pengguna. Walaupun variabel seperti *Age*, *Gender*, dan *Relationship Status* tidak memberikan pengaruh signifikan terhadap variabel target seperti halnya variabel *Country*, ketiga fitur tersebut tetap dipertahankan karena memiliki kardinalitas yang rendah dibandingkan variabel *Country*. Fitur dengan kardinalitas rendah dapat ditangani dengan metode *encoding* yang lebih sederhana, sedangkan fitur dengan kardinalitas tinggi justru menimbulkan masalah pada metode *encoding* konvensional manapun (Pargent, dkk., 2022, 2023). Di sisi lain, fitur *Country* bersifat kategorikal yang berisi 110 kategori unik.

Pada skala kardinalitas setinggi itu, baik *Label Encoder* maupun *One-Hot Encoding* menimbulkan masalah tersendiri. Pargent, dkk. (2022) secara eksplisit menyatakan bahwa *traditional encoding* yang membuat asumsi tidak masuk akal dalam memetakan kategori ke bilangan bulat, seperti *integer encoding* tidak efektif pada fitur dengan kardinalitas tinggi karena menghasilkan representasi ordinal yang tidak mencerminkan hubungan sebenarnya antar kategori. Sedangkan penggunaan *One-Hot Encoding* menimbulkan tantangan praktis seiring meningkatnya kardinalitas. Fitur dengan 100 kategori akan menghasilkan 100 kolom baru yang secara signifikan memperluas ruang fitur, menyebabkan *curse of dimensionality*, membutuhkan lebih banyak data untuk menghindari *overfitting*, meningkatkan biaya komputasi, dan memperlambat proses pelatihan model (Liang, 2025).

(b) *Binning Target*

Binning target dilakukan pada variabel target skor kecanduan (*Addicted_Score*) menggunakan metode persamaan *Equal Frequency Binning* dengan pendekatan *tertile*. Hal ini bertujuan untuk mengubah skor numerik diskrit menjadi tiga kategori kecanduan *Low*, *Medium*, dan *High* kedalam variabel baru bernama (*Addicted_Level*). Hasil dari pengklasifikasian tingkat kecanduan media sosial kedalam tiga kategori melalui penentuan ambang batas (*cut-off point*) yang dilakukan dengan mencari nilai *tertile* 1 (T_1) dan *tertile* 2 (T_2) menggunakan rumus 3.1 adalah sebagai berikut:

$$L_{T_1} = \frac{1 \times (705 + 1)}{3} = 235,3 \Rightarrow T_1 = 5 \quad (4.1)$$

$$L_{T_2} = \frac{2 \times (705 + 1)}{3} = 470,7 \Rightarrow T_2 = 7 \quad (4.2)$$

Tabel 4.2: Distribusi Frekuensi *Addicted_Score*

<i>Addicted_Score</i>	Frekuensi	Kumulatif
2	1	1
3	16	17
4	83	100
5	136	236
6	61	297
7	209	506
8	144	650
9	55	705
Total	705	

Berdasarkan perhitungan menggunakan rumus letak *tertile* pada rumus 3.1, diperoleh posisi data T_1 ke-235,3 dan T_2 ke-470,7. Nilai $T_1 = 5$ ditetapkan karena posisi data ke-235,3 berada dalam kelompok skor 5, dengan frekuensi kumulatif mencapai 236 sebagaimana tersaji pada Tabel 4.2. Hal ini menunjukkan bahwa seluruh data hingga posisi tersebut memiliki nilai *Addicted_Score* ≤ 5 .

Selanjutnya, nilai $T_2 = 7$ ditetapkan karena posisi data ke-470,7 berada dalam kelompok skor 7, di mana frekuensi kumulatif pada kelompok tersebut mencapai 506. Mengingat rentang data pada posisi 297 hingga 506 memiliki nilai *Addicted_Score* sebesar 7, maka ambang batas *tertile* kedua (T_2) diputuskan sebesar 7.

Tabel 4.3: Kriteria Kategorisasi Skor Kecanduan

Kategori	Kriteria (T)	%
<i>Low</i>	$Score \leq 5$	33,5%
<i>Medium</i>	$5 < Score \leq 7$	38,3%
<i>High</i>	$Score > 7$	28,2%

Berdasarkan Tabel 4.3 kecanduan pada kategori rendah (*low*) mencakup 38 % responden dari total sampel, kategori sedang (*medium*) mencakup 33 % responden dari total sampel, sedangkan kategori tinggi (*high*) mencakup 28 % responden dari total sampel. Hasil ini menunjukkan bahwa distribusi frekuensi antar kategori kecanduan cukup seimbang. Keseimbangan ini sangat penting agar model klasifikasi dapat mempelajari karakteristik dari setiap tingkat kecanduan dengan baik, tanpa salah satu tingkat terlalu mendominasi.

(c) *Encoding*

Encoding dilakukan untuk mengubah variabel kategorikal menjadi variabel numerik agar dapat dibaca oleh algoritma. Berdasarkan kode yang sudah diterapkan, teknik yang digunakan adalah *Label Encoding* dengan menggunakan pustaka *LabelEncoder*. Proses ini diterapkan pada kolom yang bertipe data kategorikal seperti jenis kelamin, tingkat akademik, platform yang paling sering digunakan, pengaruh performa akademik, dan status hubungan. Setiap nilai unik dalam kolom kategorikal diberikan representasi angka unik secara berurutan (misalnya 0, 1, 2, dst).

Tabel 4.4: Perbandingan Data Sebelum *vs* Sesudah *Encoding*

Variabel	Data Asli (Kategorikal)	Encoding
<i>Gender</i>	<i>Male, Female</i>	0, 1
<i>Academic Level</i>	<i>Graduate, High School, Undergraduate</i>	0, 1, 2
<i>Platform</i>	Facebook, Instagram, YouTube, dll.	0, 1, 11
<i>Performance</i>	<i>Yes, No</i>	1, 0
<i>Relationship</i>	<i>Complicated, In Relationship, Single</i>	0, 1, 2

Tabel 4.4 menunjukkan bahwa seluruh data kategorikal telah ditransformasikan ke dalam format numerik. Sebagai contoh pada variabel *Academic_Level*, kategori *Graduate* direpresentasikan dengan angka 0, kategori *High School* dengan angka 1, serta angka 2 merepresentasikan kategori *Undergraduate*. Sedangkan pada variabel *Most_Used_Platform*, data dikonversi menjadi rentang angka 0 hingga 11 sesuai dengan jumlah platform yang ada. Hal ini bertujuan untuk memastikan seluruh fitur dalam dataset memiliki tipe data numerik yang seragam agar memungkinkan algoritma *Random Forest* dan *XGBoost* dalam melakukan perhitungan matematis pada variabel-variabel tersebut.

(d) **Normalisasi/Standardisasi**

Proses standardisasi dilakukan menggunakan metode *StandardScaler*. Proses ini bertujuan untuk membuat persamaan antar variabel numerik berada pada nilai rata-rata (*mean*) nol dan standar deviasi satu. Hal ini penting dilakukan karena variabel seperti durasi penggunaan media sosial memiliki rentang angka yang tidak terlalu besar, sedangkan variabel skor adiksi memiliki rentang angka yang lebih besar. Standardisasi menjadikan model memproses setiap fitur dengan bobot yang sama, sehingga tidak ada variabel yang mendominasi perhitungan karena besaran angkanya.

Tabel 4.5: Hasil Standardisasi Variabel Numerik

Variabel	Data Asli	Standardisasi
Age	19,0	-1, 19
Gender	0,0	-1, 00
Academic Level	2,0	0, 98
Avg Daily Usage Hours	5,2	0, 22
Most Used Platform	1,0	-0, 74
Affects Academic Performance	1,0	0, 75
Sleep Hours Per Night	6,5	-0, 33
Mental Health Score	6,0	-0, 21
Relationship Status	1,0	-0, 86
Conflicts Over Social Media	3,0	0, 16

Berdasarkan Tabel 4.5 menampilkan contoh hasil standarisasi pada satu sampel data untuk tujuan ilustrasi. Pada proses pemodelan yang sebenarnya, *StandardScaler* hanya di-fit pada data latih dan kemudian diterapkan pada data uji untuk menghindari kebocoran data (*data leakage*).

3. Skenario Pengujian

Penelitian ini membandingkan tiga teknik pembagian data dimulai dari 70:30, 80:20, dan 90:10 sebagai skenario pengujian. Hal ini bertujuan untuk melihat konsistensi performa model dalam mengklasifikasikan tingkat kecanduan media sosial. Selain dengan menggunakan tiga skenario pengujian, masing-masing skenario dilakukan pelatihan sebanyak 10 kali untuk mendapatkan hasil yang valid dan risiko bias pada pembagian data menggunakan *10-Fold Cross Validation*.

Tabel 4.6: Tabel Pembagian Data Latih dan Data Uji

Skenario	Data Latih	Data Uji	Total Data
70:30	494	211	705
80:20	564	141	705
90:10	635	70	705

Tabel 4.6 menunjukkan proporsi pembagian data latih dan data uji pada masing-masing skenario pengujian. Pada pengujian menggunakan rasio pembagian data 70:30, dataset dibagi menjadi 70% data latih (494 baris) dan 30% data uji (211 baris). Skenario kedua menggunakan rasio 80:20 dengan 80% data latih (564 baris) dan 20% data uji (141 baris). Skenario pengujian terakhir yang digunakan adalah rasio 90:10, dengan 90% data latih (635 baris) dan 10% data uji (70 baris). Penggunaan tiga rasio pembagian data yang berbeda ini bertujuan untuk mengevaluasi stabilitas dan kemampuan generalisasi model dalam mengenali pola kecanduan media sosial, terutama pada berbagai tingkat jumlah data latih yang tersedia.

4. Performa Model *Random Forest*

Model *Random Forest* dalam penelitian ini menggunakan parameter bawaan dari *library scikit-learn* dengan menetapkan *random_state=42* untuk menjaga konsistensi hasil pengujian pada setiap skenario pembagian data. Evaluasi performa model dilakukan menggunakan *10-fold cross validation* pada data pelatihan untuk memperoleh nilai *validation accuracy* dan *standard deviation*. Selain itu, kinerja model juga dievaluasi menggunakan *test accuracy*, *generalization gap*, serta waktu komputasi. Hasil pengujian model *Random Forest* dapat dilihat pada Tabel 4.7

Tabel 4.7: Performa *Random Forest* Pada Tiap Skenario

Rasio	Train Acc	Val Acc	Std Dev	Test Acc	Generalization Gap	Waktu (det)
70:30	1.000	0.971	0.018	0.981	0.028	3.55
80:20	1.000	0.975	0.028	0.985	0.024	2.10
90:10	1.000	0.971	0.019	1.000	0.028	2.10

Tabel 4.7 menampilkan hasil pengujian model *Random Forest* pada tiga skenario pembagian data. Setiap skenario memuat nilai *train accuracy*, *validation accuracy*, *standard deviation*, *test accuracy*, *generalization gap*, dan waktu komputasi. Uraian mengenai stabilitas model serta pemilihan skenario terbaik dibahas lebih lanjut pada subbab pembahasan. Selain penilaian kinerja secara umum, kemampuan *Random Forest* dalam mengenali setiap tingkat kecanduan media sosial juga dianalisis melalui metrik per kelas, yaitu *precision*, *recall*, dan *F1-score*. Ringkasan hasil evaluasi tersebut ditampilkan pada Tabel 4.8.

Tabel 4.8: Metrik Evaluasi Per Kelas Model *Random Forest*

Skenario	Kelas	Precision	Recall	F1-Score
70:30	Low	1.00	0.98	0.99
	Medium	0.96	1.00	0.98
	High	0.99	0.96	0.97
80:20	Low	1.00	0.97	0.99
	Medium	0.98	1.00	0.99
	High	0.98	0.98	0.98
90:10	Low	1.00	1.00	1.00
	Medium	1.00	1.00	1.00
	High	1.00	1.00	1.00

Tabel 4.8 menunjukkan hasil evaluasi tiap kelas pada model *Random Forest* untuk setiap skenario pembagian data. Secara umum, seluruh kelas memperoleh nilai *precision*, *recall*, dan *F1-score* yang tinggi pada ketiga skenario pengujian. Stabilitas performa model dan konsistensi hasil klasifikasi akan dibahas lebih lanjut pada subbab pembahasan.

5. Performa Model *XGBoost*

Pada model *XGBoost*, konfigurasi yang digunakan mengacu pada parameter bawaan pustaka *XGBoost*, dengan beberapa penyesuaian, yaitu *random_state=42*, *use_label_encoder=False*, dan *eval_metric='mlogloss'*. Sama halnya pada *Random Forest* performa model *XGBoost* juga dihitung meng-

gunakan *10 fold cross validation*. Hasil pengujian *XGBoost* pada tiap skenario dapat dilihat pada Tabel 4.9

Tabel 4.9: Performa *XGBoost* pada Tiap Skenario

Rasio	Train Acc	Val Acc	Std Dev	Test Acc	Generalization Gap	Waktu (det)
70:30	1.000	0.969	0.020	0.976	0.030	1.31
80:20	1.000	0.973	0.025	0.985	0.026	0.66
90:10	1.000	0.973	0.017	1.000	0.026	0.65

Tabel 4.9 menampilkan hasil pengujian model *XGBoost* pada tiga skenario pembagian data. Setiap skenario memuat nilai *train accuracy*, *validation accuracy*, *standard deviation*, *test accuracy*, *generalization gap*, dan waktu komputasi. Uraian mengenai stabilitas model serta pemilihan skenario terbaik dibahas lebih lanjut pada subbab pembahasan. Selain penilaian kinerja secara umum, kemampuan *XGBoost* dalam mengenali setiap tingkat kecanduan media sosial juga dianalisis melalui metrik per kelas, yaitu *precision*, *recall*, dan *F1-score*. Ringkasan hasil evaluasi tersebut ditampilkan pada Tabel 4.10.

Tabel 4.10: Metrik Evaluasi Per Kelas Model *XGBoost*

Skenario	Kelas	Precision	Recall	F1-Score
70:30	Low	0.98	0.98	0.98
	Medium	0.96	1.00	0.98
	High	0.99	0.95	0.97
80:20	Low	0.98	1.00	0.99
	Medium	0.98	1.00	0.99
	High	1.00	0.96	0.98
90:10	Low	1.00	1.00	1.00
	Medium	1.00	1.00	1.00
	High	1.00	1.00	1.00

Tabel 4.10 menunjukkan hasil evaluasi tiap kelas pada model *XGBoost* untuk setiap skenario pembagian data. Seluruh kelas memperoleh nilai

precision, *recall*, dan *F1-score* yang tinggi, terutama pada skenario 90:10 yang mencapai performa sempurna pada seluruh metrik evaluasi. Stabilitas model dan perbandingan performa antarskenario akan dibahas lebih lanjut pada subbab pembahasan.

B. Pembahasan

1. Analisis Karakteristik Perilaku

Berdasarkan hasil data eksplorasi, pada Gambar 4.1 distribusi jenis kelamin responden yang hampir seimbang mengurangi risiko bias terhadap jenis kelamin tertentu dalam klasifikasi. Sebaran usia responden pada Gambar 4.2 menggambarkan kondisi nyata usia yang rentan mengalami kecanduan media sosial. Sejalan dengan statistik SQ Magazine (2022) menyebutkan tingkat kecanduan media sosial berdasarkan kelompok usia peringkat tertinggi diduduki kelompok usia 18-22 tahun sebanyak 32% lalu posisi kedua terbanyak pada kelompok usia 23-38 tahun sebanyak 30%. Hal tersebut menjadi acuan sampel data *Student Social Media Addiction* digunakan. Rentang usia 18-24 tahun merupakan usia produktif dan aktif dalam menggunakan teknologi.

Hal ini dipertegas dengan mayoritas responden pada Gambar 4.3 memiliki latar belakang pendidikan strata satu yang sangat relevan untuk menggambarkan pola adiksi remaja muda yang dinamis dan memiliki akses teknologi luas, di mana media sosial sering dijadikan sarana pelarian dari tekanan akademik. Pola ini diperkuat dengan Instagram dan TikTok yang mendominasi di kalangan mahasiswa karena jenis konten pada platform tersebut dirancang menggunakan algoritma *intermittent reinforcement* dengan tujuan mempertahankan atensi pengguna dalam durasi yang lama, sehingga berpotensi menimbulkan perilaku adiktif (Kuss & Griffiths, 2017). Seperti yang terlihat pada Gambar 4.4 menunjukkan tren platform yang sering digunakan pada data *Student Social Media Addiction* menempatkan Instagram di urutan pertama dengan jumlah 249 pengguna, disusul oleh TikTok dengan 154 pengguna, selanjutnya Facebook sekitar 123 pengguna, kemudian WhatsApp dengan jumlah 54 pengguna diikuti oleh platform lainnya.

Selain itu, status hubungan responden pada Gambar 4.5 menunjukkan mayoritas responden belum berpasangan (*single*). Hal ini selaras dengan penelitian yang menyatakan bahwa individu berstatus *single* cenderung mengalokasikan lebih banyak waktu pada platform media sosial seba-

gai sarana untuk mencari dukungan sosial, interaksi interpersonal, atau kompensasi atas rasa kesepian, yang secara tidak langsung meningkatkan intensitas penggunaan harian mereka (Andreassen, dkk., 2016). Cakupan data internasional memberikan perspektif luas terhadap pola adiksi, meskipun variabel negara akan direduksi untuk menyederhanakan kompleksitas model.

Gambar 4.7 menunjukkan korelasi positif yang kuat (0,83) antara *Avg_Daily_Usage* dengan *Addiction_Score*, mengindikasikan bahwa semakin lama seseorang menghabiskan waktunya di sosial media semakin tinggi juga skor kecanduannya. Tingginya skor kecanduan seseorang dapat berdampak pada kondisi kesehatan mentalnya, hal ini dibuktikan dengan adanya korelasi negatif yang kuat (-0,95) antara *Addicted_Score* dengan *Mental_Health_Score*. Hal tersebut menyatakan bahwa semakin tinggi skor kecanduan media sosial seseorang maka semakin kecil skor kesehatan mentalnya.

Hal ini dapat disebabkan karena adanya korelasi negatif antara *Avg_Daily_Usage* dengan *Sleep_Hours_Per_Night* sebesar -0,79. Semakin lama seseorang menghabiskan waktunya untuk bermedia sosial, semakin berkurang jam tidur per malamnya. Rata-rata waktu tidur responden hanya 6,87 jam setiap malam, dan beberapa hanya tidur selama 3,8 jam akibat penggunaan yang berlebihan.

Waktu tidur yang tidak mencukupi ini menjadi faktor utama penurunan kesehatan mental, karena gangguan pola tidur dapat menyebabkan ketidakstabilan emosi dan penurunan kemampuan berpikir (Khairat, dkk., 2021). Hal ini berkorelasi dengan yang menunjukkan rata-rata waktu penggunaan media sosial cukup tinggi, yakni 4,92 jam hingga 8,5 jam per hari yang berdampak langsung pada penurunan waktu istirahat dengan rata-rata tidur hanya 6,87 jam per malam serta skor kesehatan mental sebesar 6,23 dari skala 10. Fenomena tersebut memperkuat indikasi awal adanya hubungan antara penggunaan media sosial yang intensif dengan penurunan kualitas kesehatan mental responden.

2. Analisis Stabilitas dan Penentuan Skenario Terbaik

a. Random Forest

Tabel 4.7 menampilkan hasil pengujian model Random Forest pada tiap skenario. Nilai *Train Accuracy (CV)* pada ketiga skenario mencapai

angka 1.00. Hal ini menunjukkan bahwa model mampu mempelajari pola pada data latih dengan sangat baik. Kondisi tersebut dipengaruhi oleh penggunaan parameter bawaan *max_depth=None* pada algoritma *Random Forest*, sehingga pohon keputusan dapat dibangun secara penuh sehingga tiap *node* mampu memisahkan data latih secara optimal (scikit-learn developers, 2024). Namun, hal ini tidak otomatis menunjukkan adanya *overfitting* karena kemampuan generalisasi model masih harus dinilai lebih lanjut melalui *Test Accuracy* dan *Generalization Gap*.

Pada skenario 70:30, menunjukkan *Validation Accuracy* sebesar 0.971 dengan *Test Accuracy* 0,981 dan *Generalization Gap* sebesar 0.000. Skenario 80:20 menghasilkan *Validation Accuracy* 0.975 dengan *Test Accuracy* 0.985 dan *Generalization Gap* sebesar 0.024. Terakhir, skenario 90:10 menghasilkan *Validation Accuracy* sebesar 0.971 dengan *Test Accuracy* mencapai angka 1.00 dan *Generalization Gap* sebesar 0.028.

Skenario 80:20 menghasilkan nilai *Generalization Gap* paling kecil, sehingga model pada skenario ini dapat dikatakan memiliki kemampuan generalisasi yang lebih baik dibandingkan skenario lainnya (Valdenegro-Toro & Sabatelli, 2022). Sementara itu, skenario 90:10 memperoleh *Test Accuracy* tertinggi sebesar 1.00, tetapi hasil tersebut perlu ditafsirkan secara hati-hati karena data uji yang digunakan hanya berjumlah 70 sampel. Jumlah data uji yang lebih sedikit dapat meningkatkan peluang model menghasilkan prediksi yang sangat tinggi. Di sisi lain, bertambahnya jumlah data latih membantu model mengenali pola data dengan lebih baik, sehingga performa klasifikasi dapat meningkat (Nugroho, 2022).

Berdasarkan hasil *cross-validation*, nilai *standard deviation* pada setiap skenario tergolong rendah. Hal ini menunjukkan bahwa performa model cenderung konsisten pada setiap *fold* pengujian (Tibshirani & Tibshirani, 2009). Selain stabil pada proses *cross-validation*, model juga menghasilkan performa klasifikasi yang baik pada setiap kelas. Berdasarkan Tabel 4.8, model *Random Forest* menunjukkan performa klasifikasi yang baik pada seluruh tingkat kecanduan media sosial. Pada kelas *Low*, seluruh skenario memperoleh nilai *precision* sebesar 1.00. Namun, masih terdapat sebagian kecil data yang tidak terdeteksi pada skenario 70:30 dan 80:20, yang ditunjukkan oleh nilai *recall* sebesar 0.98 dan 0.97.

Pada kelas *Medium*, seluruh skenario memperoleh nilai *recall* sebesar 1.00, yang berarti semua data pada kelas tersebut berhasil dikenali. Namun, nilai *precision* pada skenario 70:30 dan 80:20 masih berada di bawah

1.00 karena terdapat beberapa data dari kelas lain yang diklasifikasikan sebagai *Medium*. Pada kelas *High*, nilai *precision*, *recall*, dan *F1-score* tetap tinggi di seluruh skenario. Skenario 90:10 menunjukkan hasil sempurna pada semua metrik, tetapi tetap perlu dicermati karena jumlah data ujinya lebih sedikit. Secara keseluruhan, model *Random Forest* mampu mengklasifikasikan tingkat kecanduan media sosial secara konsisten.

Dengan mempertimbangkan nilai *Validation Accuracy* tertinggi, *Generalization Gap* terkecil, dan jumlah data uji yang tetap representatif, skenario 80:20 dipilih sebagai konfigurasi terbaik pada model *Random Forest* dengan *Test Accuracy* sebesar 0.985. Waktu komputasi pada setiap skenario diperoleh dari satu kali eksekusi di *Google Colaboratory*, sehingga nilainya dapat bervariasi sesuai kondisi server dan penggunaan memori. Secara umum, skenario 70:30 membutuhkan waktu komputasi lebih lama dibandingkan skenario 80:20 dan 90:10.

b. XGBoost

Tabel 4.9 menyajikan hasil pemodelan *XGBoost* pada tiga skenario pembagian data. Seperti pada *Random Forest*, nilai *Train Accuracy* model *XGBoost* mencapai 1.00 pada seluruh skenario. Hasil ini berkaitan dengan mekanisme *boosting*, yaitu pembentukan pohon keputusan secara bertahap untuk memperbaiki kesalahan prediksi dari pohon sebelumnya. Melalui iterasi yang memadai, model mampu mempelajari data latih secara akurat (Chen & Guestrin, 2016).

Pada skenario 70:30, model memperoleh *Validation Accuracy* sebesar 0.969, *Test Accuracy* sebesar 0.976, dan *Generalization Gap* sebesar 0.030. Skenario 80:20 dan 90:10 menunjukkan nilai *Validation Accuracy* serta *Generalization Gap* yang sama, yaitu 0.973 dan 0.026. Skenario 90:10 menghasilkan *Test Accuracy* tertinggi sebesar 1.00, tetapi hasil ini perlu ditafsirkan secara hati-hati karena jumlah data ujinya lebih sedikit dibandingkan skenario lain.

Seperti pada *Random Forest*, standar deviasi *XGBoost* pada ketiga skenario tergolong rendah, yaitu 0.017–0.025. Nilai tersebut menunjukkan performa model yang relatif konsisten pada setiap *fold* pengujian (Tibshirani & Tibshirani, 2009). Selain stabil pada proses *cross-validation*, model juga menunjukkan kemampuan klasifikasi yang baik pada setiap tingkat kecanduan media sosial. Pada kelas *Low*, nilai *precision* sebesar 0.98 pada skenario 70:30 dan 80:20 menunjukkan adanya sebagian kecil data dari

kelas lain yang diklasifikasikan sebagai *Low*. Sementara itu, skenario 90:10 mencatat nilai *precision*, *recall*, dan *F1-score* sebesar 1.00 pada kelas tersebut.

Pada kelas *Medium*, nilai *recall* sebesar 1.00 pada seluruh skenario menunjukkan bahwa seluruh data kelas tersebut berhasil dikenali. Namun, *precision* sebesar 0.96 pada skenario 70:30 mengindikasikan adanya beberapa data dari kelas lain yang diklasifikasikan sebagai *Medium*. Pada kelas *High*, nilai *precision*, *recall*, dan *F1-score* juga tetap tinggi di seluruh skenario. Dengan demikian, model *XGBoost* menunjukkan kemampuan klasifikasi multikelas yang konsisten pada setiap tingkat kecanduan media sosial.


Dengan mempertimbangkan *Validation Accuracy* tertinggi, *Generalization Gap* terkecil, serta jumlah data uji yang memadai (141 sampel), skenario 80:20 dipilih sebagai konfigurasi terbaik untuk *XGBoost* dengan *Test Accuracy* sebesar 0.985. Dari sisi waktu komputasi, skenario 70:30 memerlukan durasi lebih lama dibandingkan skenario 80:20 dan 90:10, yaitu 1.31 detik berbanding 0.65–0.66 detik.

3. Analisis Kesalahan Klasifikasi

Analisis Kesalahan Klasifikasi dilakukan menggunakan *confusion matrix* untuk melihat seberapa baik model dalam mengklasifikasikan data tingkat kecanduan media sosial ke dalam setiap kategori. Selain menunjukkan jumlah prediksi yang benar, *confusion matrix* juga membantu mengidentifikasi kesalahan prediksi yang terjadi pada masing-masing kelas. Berikut merupakan visualisasi *confusion matrix* model *Random Forest* dan *XGBoost* pada skenario terbaik:

Berdasarkan Gambar 4.8a, model *Random Forest* pada skenario terbaik 80:20 menunjukkan kinerja klasifikasi yang baik pada setiap kategori tingkat kecanduan media sosial. Hal ini terlihat dari dominasi prediksi pada diagonal utama *confusion matrix*, yang menandakan sebagian besar data diklasifikasikan secara tepat. Namun, masih terdapat dua kesalahan prediksi, yaitu satu data kelas *Low* diklasifikasikan sebagai *High* dan satu data kelas *High* diklasifikasikan sebagai *Medium*.

Sementara itu, Gambar 4.8b menunjukkan bahwa model *XGBoost* juga memiliki kinerja klasifikasi yang sangat baik pada skenario 80:20. Sebagian besar data berhasil diklasifikasikan secara tepat pada masing-masing kelas. Namun, masih terdapat dua kesalahan klasifikasi, yaitu satu data kelas *High* diprediksi sebagai *Low* dan satu data kelas *High* diprediksi sebagai *Medium*.



Gambar 4.8: Perbandingan *Confusion Matrix* pada Skenario Terbaik

Secara umum, kedua model menunjukkan kemampuan klasifikasi yang sangat baik dengan jumlah kesalahan prediksi yang relatif sedikit. Namun, kesalahan klasifikasi pada kelas *High* tetap perlu diperhatikan karena dapat menyebabkan tingkat kecanduan tinggi diprediksi sebagai kategori yang lebih rendah. Kesalahan klasifikasi yang masih terjadi kemungkinan disebabkan oleh kemiripan karakteristik data antarkelas, sehingga model mengalami kesulitan dalam membedakan beberapa kategori tingkat kecanduan media sosial (Huang dkk., 2023). Untuk meningkatkan performa model, penelitian selanjutnya dapat mempertimbangkan penggunaan *hyperparameter tuning*, penambahan jumlah data, serta pengembangan fitur agar pola antarkelas dapat dikenali dengan lebih baik (Fauzi dkk., 2025; Suryadi dkk., 2024).

4. Komparasi Model Optimal dengan Skenario Terbaik

Komparasi model optimal dilakukan untuk membandingkan performa terbaik model *Random Forest* dan *XGBoost* berdasarkan skenario pembagian data yang menghasilkan kinerja paling optimal. Berdasarkan hasil analisis sebelumnya, kedua model menunjukkan performa terbaik pada skenario 80:20. Perbandingan akurasi data latih, akurasi data uji, standard deviation dan *generalization gap* disajikan pada Tabel 4.11.

Tabel 4.11: Perbandingan Model Optimal dengan Skenario Terbaik (80:20)

Model	Train Accuracy	Test Accuracy	Standard Deviation	Generalization Gap
<i>Random Forest</i>	1.0000	0.9858	0.0286	0.0248
<i>XGBoost</i>	1.0000	0.9858	0.0253	0.0269

Berdasarkan Tabel 4.11, model *Random Forest* dan *XGBoost* sama-sama memperoleh nilai *Train Accuracy* sebesar 1.00. Pada data uji, kedua model juga menghasilkan *Test Accuracy* yang sama, yaitu 0.9858. Namun, *Random Forest* memiliki nilai *Generalization Gap* yang sedikit lebih kecil dibandingkan *XGBoost*, yaitu 0.0248 berbanding 0.0269.

Valdenegro-Toro & Sabatelli (2022) menyatakan bahwa *Generalization Gap* digunakan untuk melihat kemampuan generalisasi model dalam menilai apakah model mengalami *overfitting*. Perhitungan *Generalization Gap* didapat dari selisih antara *train accuracy* dan *Validation Accuracy*. Selisih *Generalization Gap* yang sangat kecil menunjukkan bahwa kedua model memiliki kemampuan generalisasi yang baik, karena perbedaan performa antara data pelatihan dan data validasi tidak terlalu besar.

Hal tersebut sejalan dengan penelitian Loreggia, dkk. (2021) yang menyebutkan bahwa *Random Forest* memperoleh *Generalization Gap* yang lebih kecil dikarenakan model ini menerapkan teknik *Bagging*. Metode ini membangun sejumlah pohon keputusan (*decision trees*) dari bagian data yang berbeda melalui proses *subsampling* dengan pengambilan sampel kembali (*sampling with replacement*). Dengan adanya unsur keacakan (*randomness*), *Random Forest* cenderung memiliki generalisasi yang lebih baik dibandingkan satu pohon keputusan tunggal karena dapat menekan *overfitting* dan mengurangi varians model.

Selain *Generalization Gap*, nilai standar deviasi antar *fold* juga penting guna menilai stabilitas nilai performa yang dihasilkan (Pekar, dkk., 2026). Selisih nilai *Standard Deviation* yang diperoleh kedua model juga tidak berbeda jauh, tetapi *XGBoost* memperoleh nilai *Standard Deviation* lebih kecil dibandingkan *Random Forest* (0.0253 untuk *XGBoost* dan 0.0286 untuk *Random Forest*). Hal ini dikarenakan *XGBoost* bekerja dengan menerapkan *Boosting*. *Boosting* menangani permasalahan pengurangan kesalahan dengan cara yang berlawanan dengan *Bagging*.

Baker, dkk. (2020), *Random Forest* menekan kesalahan prediksi dengan mengurangi varians pada model dasar yang kompleks, yaitu model dengan bias rendah tetapi varians tinggi. Sementara itu, *boosting* bekerja dengan menyusun model-model lemah (*weak learners*) secara berurutan (*sequential*). Model lemah tersebut biasanya berupa pohon keputusan dangkal dengan bias tinggi dan varians rendah, sehingga bias model dapat dikurangi secara bertahap. *Extreme Gradient Boosting (XGBoost)* mengembangkan pendekatan ini dengan menambahkan regularisasi pada fungsi kerugian (*loss function*) dalam *stochastic gradient boosting*. Regularisasi tersebut digunakan untuk membatasi kompleksitas model, sedangkan teknik optimasi diterapkan untuk mempercepat proses pelatihan.

Secara umum, model *Random Forest* dan *XGBoost* menunjukkan kemampuan klasifikasi yang baik pada dataset *Students Social Media Addiction*. Meskipun selisihnya relatif kecil, nilai *Standard Deviation* yang lebih rendah pada *XGBoost* menunjukkan bahwa model tersebut memiliki performa yang lebih konsisten pada setiap *fold* dalam proses *cross-validation*. Sedangkan *Random Forest* memiliki kemampuan generalisasi yang lebih baik. Dengan demikian, kedua model dapat dinyatakan efektif dalam mengklasifikasikan tingkat kecanduan media sosial, dengan skenario pembagian data 80:20 sebagai skenario paling optimal.

5. Komparasi dengan Penelitian Terdahulu

Pada bagian ini dilakukan analisis perbandingan performa antara hasil penelitian yang telah dilakukan dengan beberapa penelitian terdahulu. Perbandingan ini bertujuan mengukur seberapa baik model *Random Forest* dan *XGBoost* dalam mengklasifikasikan tingkat kecanduan media sosial dibandingkan dengan hasil penelitian yang sudah ada sebelumnya. Perlu diperhatikan bahwa meskipun hasil evaluasi dibandingkan secara kuantitatif, setiap penelitian memiliki data yang berbeda, jumlah fitur yang berbeda, dan kelompok subjek yang berbeda. Tabel 4.12 memperlihatkan perbandingan metrik kinerja model terbaik dalam penelitian ini dengan penelitian sebelumnya yang telah ditinjau.

Berdasarkan Tabel 4.12, performa model dalam penelitian ini lebih unggul dibandingkan beberapa penelitian terdahulu. Model *Random Forest* dan *XGBoost* sama-sama mencapai akurasi sebesar 0.99, disertai nilai *precision*, *recall*, dan *F1-score* yang tinggi pada skenario terbaik. Temuan ini menunjukkan bahwa kedua model efektif dalam mengklasifikasikan

Tabel 4.12: Perbandingan Performa

Peneliti	Tahun Terbit	Model	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Lee & Kim	2021	<i>XGBoost</i>	0.80	-	0.81	-
		<i>Random Forest</i>	0.82	-	0.80	-
Ehsan dkk	2024	<i>Random Forest</i>	0.88	0.88	0.88	0.88
Izhari	2025	<i>XGBoost</i>	0.97	0.99	0.98	0.99
Penelitian ini	2026	<i>Random Forest</i>	0.99	0.99	0.99	0.99
		<i>XGBoost</i>	0.99	0.98	0.99	0.99

tingkat kecanduan media sosial pada dataset yang digunakan. Jika dibandingkan dengan penelitian Lee & Kim (2021), performa pada penelitian ini menunjukkan peningkatan yang cukup signifikan.

Perbedaan tersebut dapat dipengaruhi oleh karakteristik dataset, jumlah data, distribusi kelas, serta fitur yang digunakan dalam masing-masing penelitian. Selain itu, hasil penelitian ini juga lebih tinggi dibandingkan penelitian Ehsan & Basit (2024) dan sedikit lebih baik dibandingkan penelitian Izhari (2025). Secara umum, hasil penelitian ini menunjukkan bahwa model *Random Forest* dan *XGBoost* memiliki kemampuan yang baik dalam mengklasifikasikan tingkat kecanduan media sosial pada dataset yang digunakan. Meskipun demikian, perbedaan hasil evaluasi dengan penelitian sebelumnya tetap perlu dipahami dengan mempertimbangkan karakteristik dataset, metode pra-pemrosesan, dan skenario pengujian yang digunakan.

C. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan. Pertama, data yang digunakan bersumber dari dataset publik pada repositori Kaggle dengan jumlah 705 responden. Kondisi tersebut membuat kemampuan generalisasi model masih bergantung pada karakteristik data yang tersedia. Selain itu, data dikumpulkan dari jawaban responden

di berbagai negara melalui metode *self-report*, sehingga potensi subjektivitas dan bias dalam pengisian data masih mungkin terjadi.

Kedua, pemodelan dalam penelitian ini masih terbatas pada dua algoritma berbasis *tree-based*, yaitu *Random Forest* dan *XGBoost*. Evaluasi model dilakukan melalui tiga skenario pembagian data, sehingga cakupan pengujian belum mencakup perbandingan dengan algoritma lain maupun penerapan teknik validasi tambahan yang lebih kompleks.

Ketiga, pengaturan parameter pada masing-masing model masih menggunakan parameter bawaan (*default parameter*). Dengan demikian, performa yang dihasilkan belum dapat dipastikan sebagai performa paling optimal. Selain itu, penelitian ini masih berfokus pada evaluasi performa klasifikasi dan belum mencakup analisis interpretabilitas model untuk menelusuri kontribusi setiap fitur terhadap hasil prediksi.

BAB V

KESIMPULAN DAN SARAN

A. Kesimpulan

Berdasarkan temuan penelitian, model *Random Forest* dan *XGBoost* menunjukkan kemampuan yang baik dalam mengklasifikasikan tingkat kecanduan media sosial pada dataset *Students Social Media Addiction*. Pengujian dengan metode *10-fold cross-validation* memperlihatkan bahwa kedua model mampu menghasilkan akurasi yang tinggi pada setiap skenario pembagian data yang digunakan, yaitu 70:30, 80:20, dan 90:10. Pada model *Random Forest*, pembagian data 80:20 memberikan hasil paling baik, dengan *Validation Accuracy* sebesar 0.975, *Test Accuracy* sebesar 0.985, serta nilai *Generalization Gap* terendah, yaitu 0.024.

Temuan serupa juga diperoleh pada model *XGBoost*, yang mencapai performa terbaik pada skenario 80:20 dengan *Validation Accuracy* sebesar 0.973, *Test Accuracy* sebesar 0.985, dan *Generalization Gap* sebesar 0.026. Meskipun skenario 90:10 untuk kedua model mencapai akurasi sebesar 1.00 perlu ditafsirkan secara cermat, mengingat ukuran data uji pada skenario tersebut lebih terbatas dibandingkan dengan skenario pembagian data lainnya. Evaluasi berdasarkan metrik *precision*, *recall*, dan *F1-score* mengindikasikan bahwa kedua model memiliki kemampuan yang konsisten dalam melakukan klasifikasi multikelas pada setiap kategori tingkat kecanduan media sosial.

Selain itu, hasil *confusion matrix* memperlihatkan bahwa kesalahan klasifikasi yang dihasilkan oleh kedua model tergolong rendah. Hasil perbandingan antar model menunjukkan bahwa *Random Forest* dan *XGBoost* memiliki kinerja yang sama-sama baik dalam mengklasifikasikan tingkat kecanduan media sosial. Ditinjau dari hasil *10-fold cross-validation*, *XGBoost* memperlihatkan tingkat stabilitas yang sedikit lebih unggul, sedangkan *Random Forest* menunjukkan kecenderungan generalisasi yang lebih baik melalui nilai *Generalization Gap* yang lebih rendah. Dengan mempertimbangkan aspek akurasi dan generalisasi model, skenario pembagian data

80:20 dapat dinilai sebagai pilihan yang paling sesuai bagi kedua model.

B. Saran

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan, beberapa hal dapat menjadi pertimbangan untuk penelitian berikutnya. Pertama, penelitian selanjutnya disarankan menggunakan dataset dengan jumlah responden yang lebih besar atau memanfaatkan data primer yang dikumpulkan secara langsung. Dengan demikian, hasil penelitian diharapkan memiliki daya generalisasi yang lebih baik dan mampu merepresentasikan karakteristik populasi secara lebih spesifik.

Kedua, perbandingan model dapat diperluas dengan melibatkan algoritma klasifikasi lain, seperti *Support Vector Machine*, *LightGBM*, maupun metode *deep learning*. Langkah ini diperlukan agar gambaran performa model pada klasifikasi tingkat kecanduan media sosial menjadi lebih menyeluruh. Ketiga, penelitian berikutnya dapat menerapkan teknik validasi tambahan serta optimasi parameter, misalnya *Grid Search* atau *Random Search*, untuk memperoleh konfigurasi model yang lebih tepat dan meningkatkan kinerja klasifikasi. Keempat, analisis interpretabilitas model juga dapat ditambahkan, misalnya melalui *feature importance* atau SHAP (*SHapley Additive exPlanations*). Analisis tersebut dapat membantu mengidentifikasi dan menjelaskan faktor-faktor yang paling berpengaruh terhadap tingkat kecanduan media sosial secara lebih mendalam.

DAFTAR PUSTAKA

- Ahmed, S., Raza, B., Hussain, L., Aldweesh, A., Omar, A., Khan, M. S., Eldin, E. T., & Nadim, M. A., 2023. The deep learning resnet101 and ensemble xgboost algorithm with hyperparameters optimization accurately predict the lung cancer. *Applied Artificial Intelligence*, 37(1), 2166222. URL <https://doi.org/10.1080/08839514.2023.2166222>
- Alsabti, K., Ranka, S., & Singh, V., 1997. An efficient k-means clustering algorithm.
- Andreassen, C. S., Billieux, J., Griffiths, M. D., Kuss, D. J., Demetrovics, Z., Mazzoni, E., & Pallesen, S., 2016. The relationship between addictive use of social media and video games and symptoms of psychiatric disorders: A large-scale cross-sectional study. *Psychology of Addictive Behaviors*, 30(2), 252–262.
- Anjani, A. F., Anggraeni, D., & Tirta, I. M., 2023. Implementasi random forest menggunakan smote untuk analisis sentimen ulasan aplikasi sister for students unej. *Jurnal Nasional Teknologi dan Sistem Informasi*, 9(2), 163–172. URL <https://teknosi.fti.unand.ac.id/index.php/teknosi/article/view/2325>
- Aribowo, P., & Bagaskara, M. I., 2025. Dampak penggunaan media sosial "brain rot" terhadap kesehatan mental remaja. *Jurnal Sosial Teknologi*, 5(3), 350–357. URL <https://sostech.greenvest.co.id/index.php/sostech/article/view/32020>
- Baker, H., Hallowell, M. R., & Tixier, A. J.-P., 2020. Ai-based prediction of independent construction safety outcomes from universal attributes. *Automation in Construction*, 118, 103146. URL <https://doi.org/10.1016/j.autcon.2020.103146>

- Breiman, L., 2001. Random forests. *Machine Learning*, 45(1), 5–32.
URL <https://doi.org/10.1023/A:1010933404324>
- Cambria, E., Huang, G.-B., Kasun, L., Zhou, H., Vong, C.-M., Lin, J., Yin, J., Cai, Z., Liu, Q., Li, K., Feng, L., Ong, Y., Lim, M.-H., Akusok, A., Lendasse, A., Corona, F., Nian, R., Miche, L., & Liu, J., 2013. Extreme learning machines. *IEEE Intelligent Systems*, 28, 30–59.
- Chauhan, N. K., & Singh, K., 2018. A review on conventional machine learning vs deep learning. In *2018 International Conference on Computing, Power and Communication Technologies (GUICON)*, (pp. 347–352).
- Chen, T., & Guestrin, C., 2016. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '16, (p. 785–794). New York, NY, USA: Association for Computing Machinery.
URL <https://doi.org/10.1145/2939672.2939785>
- Context Dergi, 2024. Dijital Çağın sessiz tehdidi: Brainrot. Erişim Tarihi: 15 Ocak 2026.
URL <https://contextdergi.com/dijital-cagin-sessiz-tehdidi-brainrot/>
- Dan, T. T. B., Sihwi, S. W., & Anggrainingsih, R., 2015. Implementasi iterative dichotomiser 3 pada data kelulusan mahasiswa s1 di universitas sebelas maret. *ITSMART: Jurnal Teknologi dan Informasi*, 4(2), 84–91.
URL https://www.researchgate.net/publication/309545218_IMPLEMENTASI_ITERATIVE_DICHOTOMISER_3_PADA_DATA_KELULUSAN_MAHASISWA_S1_DI_UNIVERSITAS_SEBELAS_MARET
- Digital Wellness Lab, 2024. Family guide to problematic interactive media use (pimu).
url <https://digitalwellnesslab.org/family-guides/family-guide-to-problematic-interactive-media-use-pimu/>. Accessed: 2026-01-13.
- Dinata, R. K., Hasdyna, N., & Alif, M., 2021. Applied of information gain algorithm for culinary recommendation system in lhokseumawe. *Journal of Informatics and Telecommunication Engineering*, 5(1).
- Drakel, W. J., Pratiknjo, M. H., & Mulianti, T., 2018. Perilaku mahasiswa dalam menggunakan media sosial di universitas sam ratulangi manado. *HOLISTIK, Journal of Social and Culture*.

- Ehsan, T., & Basit, J., 2024. Machine learning for detecting social media addiction patterns: Analyzing user behavior and mental health data. *International Journal of Innovations in Science and Technology*, 6, 1789–1807.
- Fauzi, N., dkk., 2025. Penerapan feature engineering dan hyperparameter tuning pada random forest untuk peningkatan akurasi klasifikasi. *Jurnal Teknologi Informasi dan Ilmu Komputer*.
- Goldberg, D. E., & Holland, J. H., 1988. Genetic algorithms and machine learning. *Machine Learning*, 3, 95–99.
URL <https://api.semanticscholar.org/CorpusID:2043246>
- Habermas, J., 1991. *The structural transformation of the public sphere: An inquiry into a category of bourgeois society*. MIT press.
- Han, J., & Kamber, M., 2006. Data mining: Concepts and techniques, second edition. In *The Morgan Kaufmann series in data management systems*.
URL <https://api.semanticscholar.org/CorpusID:195837802>
- Han, J., Kamber, M., & Pei, J., 2011. *Data Mining: Concepts and Techniques*. Waltham, MA: Morgan Kaufmann, 3 ed.
URL <https://hanj.cs.illinois.edu/bk3/>
- Hiregoudar, S., Manjunath, K., & Patil, K. S., 2014. A survey: Research summary on neural networks. *International Journal of Research in Engineering and Technology (IJRET)*, 3(15), 385–389.
URL <https://ijret.org/volumes/2014v03/i15/IJRET20140315076.pdf>
- Huang, Z., dkk., 2023. Class-specific distribution alignment for semi-supervised medical image classification. *arXiv preprint arXiv:2307.15987*.
- Izhari, F., 2025. Pemodelan perilaku penggunaan media sosial mahasiswa dengan algoritma xgboost. *Jurnal Minfo Polgan*, 14(1), 1303–1308.
URL <https://jurnal.polgan.ac.id/index.php/jmp/article/view/15030>
- Kaelbling, L. P., Littman, M. L., & Moore, A. W., 1996. Reinforcement learning: A survey. *Journal of artificial intelligence research*, 4, 237–285.

Kahlout, K. M., & Ekler, P., 2021. Algorithmic splitting: A method for dataset preparation. *IEEE Access*, 9, 125229–125237.

Kapoor, S., & Narayanan, A., 2023. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*.

Kemp, S., 2023. Digital 2023: Global overview report. DataReportal. In partnership with Meltwater and We Are Social.

URL <https://datareportal.com/reports/digital-2023-global-overview-report>

Khairat, K., Nurhayani, N., & Rahmi, A., 2021. Hubungan intensitas penggunaan media sosial dengan kualitas tidur dan kesehatan mental pada mahasiswa. *Jurnal Psikologi dan Kesehatan Mental*, 5(2), 110–122.

URL <https://e-journal.unair.ac.id/JPKM>

Khalaf, A. M., Alubied, A. A., Khalaf, A. M., & Rifaey, A. A., 2023. The impact of social media on the mental health of adolescents and young adults: A systematic review. *Cureus*, 15(8), e42990.

URL <https://www.cureus.com/articles/176889-the-impact-of-social-media-on-the-mental-health-of-adolescents-and->

Khan, M. Y., Qayoom, A., Nizami, M. S., Siddiqui, M. S., Wasi, S., & Raazi, S. M. K.-u.-R., 2021. Automated prediction of good dictionary examples (gdex): A comprehensive experiment with distant supervision, machine learning, and word embedding-based deep learning techniques. *Complexity*, 2021(1), 2553199.

URL <https://onlinelibrary.wiley.com/doi/abs/10.1155/2021/2553199>

Kohavi, R., 1995. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the Fourteenth International Joint Conference on Artificial Intelligence*, (pp. 1137–1145).

Kotsiantis, S., 2007. Supervised machine learning: A review of classification techniques. *Informatica*, 31(3).

Kuss, D. J., & Griffiths, M. D., 2017. Social networking sites and addiction: Ten lessons learned. *International Journal of Environmental Research and Public Health*, 14(3), 311.

- Lee, J., & Kim, W., 2021. Prediction of problematic smartphone use: A machine learning approach. *International Journal of Environmental Research and Public Health*, 18(12).
URL <https://www.mdpi.com/1660-4601/18/12/6458>
- Liang, Z., 2025. Efficient representations for high-cardinality categorical variables in machine learning.
- Liaw, A., & Wiener, M., 2002. Classification and regression by randomforest. *R News*, 2(3), 18–22. <https://journal.r-project.org/articles/RN-2002-022/>.
- Loreggia, A., Passarelli, A., & Pini, M. S., 2021. The effects of air quality on the spread of the COVID-19 pandemic in Italy: An artificial intelligence approach. *arXiv preprint arXiv:2104.12546*.
- Munoz, A., 2012. Machine learning and optimization.
URL <https://api.semanticscholar.org/CorpusID:262228627>
- Nasution, D. A., Khotimah, H. H., & Chamidah, N., 2019. Perbandingan normalisasi data untuk klasifikasi wine menggunakan algoritma k-nn. *CESS (Journal of Computer Engineering, System and Science)*, 4(1), 78–82.
URL <https://jurnal.unimed.ac.id/2012/index.php/cess/article/view/11458>
- Nugroho, A., 2022. Analisa splitting criteria pada decision tree dan random forest untuk klasifikasi evaluasi kendaraan. *JSITIK: Jurnal Sistem Informasi dan Teknologi Informasi Komputer*, 1, 41–49.
URL <https://jurnal.ciptamediaharmoni.id/index.php/jsitik/article/view/154>
- Oxford University Press, 2024. 'brain rot' named oxford word of the year 2024.
[urlhttps://corp.oup.com/news/brain-rot-named-oxford-word-of-the-year-2024/](https://corp.oup.com/news/brain-rot-named-oxford-word-of-the-year-2024/). Accessed: 2026-01-13.
- Pandey, D., Niwaria, K., & Chourasia, B., 2019. Machine learning algorithms: A review. *International Research Journal of Engineering and Technology (IRJET)*, 6(2), 916–922.
URL <https://www.irjet.net/archives/V6/i2/IRJET-V6I2176.pdf>

Pargent, F., Pfisterer, F., Thomas, J., & Bischl, B., 2022. Regularized target encoding outperforms traditional methods in supervised machine learning with high cardinality features. *Computational Statistics*, 37(5), 2671–2692.

Pargent, F., Pfisterer, F., Thomas, J., & Bischl, B., 2023. Encoding categorical data: Is there yet anything ‘hotter’ than one-hot encoding?
URL <https://arxiv.org/abs/2312.16930>

Pekar, A., Plny, R., & Hynek, K., 2026. Tutorial on flow-based network traffic classification using machine learning. Under review.
URL <https://arxiv.org/abs/2601.04089>

Prasetyo, E., 2012. *Data Mining: Konsep dan Aplikasi Menggunakan MATLAB*. Yogyakarta: CV Andi Offset.

Putri, d., 2023. The performance of the equal-width and equal-frequency discretization methods on data features in classification process.
URL <https://www.researchgate.net/publication/374377033>

Pv, F., 2025. The impact of social media on cognitive function and brain health. *Volume 6*.

Saeed, M., 2008. Bernoulli mixture models for markov blanket filtering and classification. *Journal of Machine Learning Research - Proceedings Track*, 3, 77–91.

Salam Patrous, Z., 2018. Evaluating xgboost for user classification by using behavioral features extracted from smartphone sensors.

scikit-learn developers, 2024. RandomForestClassifier — scikit-learn documentation.
URL <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

Shalash, R. J., Arumugam, A., Qadah, R. M., & Al-Sharman, A., 2024. Night screen time is associated with cognitive function in healthy young adults: A cross-sectional study. *Journal of Multidisciplinary Healthcare*, 17, 2093–2104.

URL <https://www.dovepress.com/night-screen-time-is-associated-with-cogniti>

- Shamim, A., 2025. Students' social media addiction: A cross-country survey of usage patterns, academic impact, and relationship. <https://www.kaggle.com/datasets/adilshamim8/social-media-addiction-vs-relationships>. Kaggle dataset, CC BY 4.0.
- Silitonga, P., 2023. Pengaruh positif dan negatif media sosial terhadap perkembangan sosial, psikologis, dan perilaku remaja yang tidak terbiasa dengan teknologi sosial media di Indonesia. *Jurnal Pendidikan Sosial Dan Humaniora*, 2(4), 13077–13089.
- SQ Magazine, 2022. Gen z social media statistics: What you need to know. <https://sqmagazine.co.uk/gen-z-social-media-statistics/>. Diakses pada: 22 Mei 2024.
- Sugiyono, 2018. *Metode Penelitian Pendidikan: Pendekatan Kuantitatif, Kualitatif, dan RD*. Bandung: Alfabeta.
- Suryadi, M., dkk., 2024. Comparative study of various hyperparameter tuning on random forest classification. *Journal of Electrical Engineering, Electronics, Information, and Informatics*.
- Syukron, M., Santoso, R., & Widiyarih, T., 2020. Perbandingan metode smote random forest dan smote xgboost untuk klasifikasi tingkat penya-kit hepatitis c pada imbalance class data. *Jurnal Gaussian*, 9(3), 227–236.
- Tharwat, A., 2020. Classification assessment methods. *Applied Computing and Informatics*, 17(1), 168–192.
URL <https://doi.org/10.1016/j.aci.2018.08.003>
- Tibshirani, R., & Tibshirani, R., 2009. A bias correction for the minimum error rate in cross-validation. *The Annals of Applied Statistics*, 3(2), 822–829.
- Trisal, A., & Mandloi, D., 2021. Machine learning: An overview. *International Journal of Research -GRANTHAALAYAH*, 9(7), 343–348.
URL <https://www.granthaalayahpublication.org/journals/granthaalayah/article/view/4120>

- Trisnani, R. P., & Wardani, S. Y., 2018. Stop kecanduan game online mengenal dampak ketergantungan pada game online serta cara menguranginya.
- Valdenegro-Toro, M., & Sabatelli, M., 2022. Machine learning students overfit to overfitting. *Proceedings of the 2nd Teaching in Machine Learning Workshop*.
- Yan, H., dkk., 2023. Emphasizing feature inter-class separability for improving semi-supervised imbalanced classification. *Knowledge-Based Systems*, 278, 110882.
- Yan, L., Ruan, S., & Marwan, S., 2021. Early performance prediction using interpretable patterns in programming process data.
- Yazgan, A. M., 2025. The problem of the century: Brain rot. *OPUS Journal of Society Research*, 22(2), 211–221.

LAMPIRAN A

Tabel 1.1: Sebagian Data *Students Social Media Addiction*

Student ID	Age	Gender	Academic Level	Country	Avg. Daily Usage Hours	Most Used Platform	Affects Academic Performance	Sleep Hours Per Night	Mental Health Score	Relationship Status	Conflicts Over Social Media	Addicted Score
1	19	Female	Under graduate	Bangladesh	5.2	Instagram	Yes	6.5	6	In Relationship	3	8
2	22	Male	Graduate	India	2.1	Twitter	No	7.5	8	Single	0	3
3	20	Female	Under graduate	USA	6.0	TikTok	Yes	5.0	5	Complicated	4	9
4	18	Male	High School	UK	3.0	YouTube	No	7.0	7	Single	1	4
5	21	Male	Graduate	Canada	4.5	Facebook	Yes	6.0	6	In Relationship	2	7
...												
703	21	Female	Under graduate	China	5.6	WeChat	Yes	6.7	6	In Relationship	3	7
704	24	Male	Graduate	Japan	4.3	Twitter	No	7.5	8	Single	2	4
705	19	Female	Under graduate	Poland	6.2	Facebook	Yes	6.3	5	Single	4	8

LAMPIRAN B

Source code

```

import numpy as np
2 from scipy.integrate import odeint
import matplotlib.pyplot as plt

4
#SIS Model
6 t = np.linspace(0,50)
i0 = 0.4
8 beta = 0.5

10 def model(i,t,beta,gamma):
    didt = (beta-gamma-beta*i)*i
12     return didt

14 gamma = 0.05
y1 = odeint(model,i0,t,args=(beta,gamma))
16 gamma = 0.6
y2 = odeint(model,i0,t,args=(beta,gamma))

18
fig=plt.figure()
20 plt.plot(t,y1,'r',label='$beta > gamma$')
plt.plot(t,y2,'g',label='$beta < gamma$')
22 plt.xlim([0,50])
plt.xlabel('Time')
24 plt.ylabel('Infected people')
plt.grid(b=True, which='both',c='k',lw=1,ls=':')
26 legend = plt.legend()
legend.get_frame().set_alpha(0.5)

```


LAMPIRAN C

Biodata Penulis